

模式识别 (Pattern Recognition)

期末复习笔记

整理人: Your Name

2026 年 1 月 16 日

目录

1 绪论 (3 学时向世明)	5
1.1 模式识别基础	5
1.2 模式识别系统流程	5
1.3 模式识别系统设计	5
1.4 模式识别方法分类	6
1.5 本课程内容体系	6
2 贝叶斯决策理论 (3 学时向世明)	7
2.1 核心公式	7
2.2 最小错误率贝叶斯决策	7
2.3 最小风险贝叶斯决策	7
2.4 带拒识的贝叶斯决策 (Reject Option)	8
2.5 开放集识别 (Open Set Recognition)	8
2.6 分类器设计	9
2.7 高斯密度下的判别函数	9
2.7.1 情形一: $\Sigma_i = \sigma^2 I$ (各特征独立且方差相等)	10
2.7.2 情形二: $\Sigma_i = \Sigma$ (协方差矩阵相等)	10
2.7.3 情形三: $\Sigma_i \neq \Sigma_j$ (协方差矩阵任意)	11
2.8 错误率分析	11
2.9 离散特征贝叶斯分类	12
2.9.1 独立二值特征 (Independent Binary Features)	12
2.10 复合模式分类 (Compound Decision)	13
2.11 多分类器融合 (Multi-classifier Fusion)	13
2.12 模式分类与特征的关系	14
3 概率密度函数估计 (6 学时张燕明)	15
3.1 基本概念	15
3.2 最大似然估计 (Maximum Likelihood Estimation, MLE)	15

3.3	贝叶斯估计 (Bayesian Estimation)	15
	补充笔记：贝叶斯估计公式详解	16
3.4	正态分布下的贝叶斯估计	18
3.5	贝叶斯学习 (Bayesian Learning)	18
3.5.1	1. 迭代更新公式	18
3.5.2	2. 实例：均匀分布边界的估计	18
3.6	特征维数问题	20
3.7	期望最大化 (EM) 算法	20
3.7.1	1. 经典案例：三硬币模型 (The Three Coins Example)	20
3.7.2	2. EM 算法在高斯混合模型 (GMM) 中的应用	21
3.7.3	3. EM 算法总结	22
3.8	隐马尔可夫模型 (HMM) 详解与实例	22
3.8.1	1. 具体的模型定义与矩阵实例	22
3.8.2	2. 状态转移图 (State Transition Diagram)	23
3.8.3	3. HMM 的三个核心问题推导	23
4	非参数法 (Non-parametric Methods) (3 学时张燕明)	25
4.1	1. 引言：为什么要用非参数法？	25
4.2	2. 概率密度估计的基本原理	25
4.3	3. Parzen 窗估计 (核密度估计)	25
4.4	4. k_n -近邻估计 (k-NN Estimation)	26
4.5	5. 最近邻分类器 (Nearest Neighbor Rule)	27
4.6	6. 计算复杂度的优化	27
4.7	7. 距离度量与切距离	28
5	线性分类器设计 (3 学时张燕明)	29
5.1	引言	29
5.2	线性判别函数与决策面	29
5.3	广义线性判别函数	29
5.4	感知准则函数 (Perceptron)	30
5.5	松弛方法 (Relaxation Procedures)	30
5.6	线性最小二乘方法 (MSE)	31
5.7	多类线性判别函数	31
6	神经网络和深度学习 (9 学时张燕明)	33
6.1	人工神经网络发展历程	33
6.2	人工神经网络基础	33
6.3	单层前馈神经网络 (Perceptron)	34
6.4	多层感知器与误差反向传播算法 (MLP & BP)	34
6.5	BP 算法讨论与优化	34
6.6	反馈神经网络 (Hopfield Network)	35

6.7	径向基函数网络 (RBF)	35
6.8	自组织映射 (SOM)	36
6.9	深度学习简介	36
6.10	波尔兹曼机 (Boltzmann Machine)	36
6.11	自编码器 (Autoencoder)	37
6.12	卷积神经网络 (CNN)	37
6.13	循环神经网络 (RNN) 与 LSTM	37
6.14	注意力机制与 Transformer	38
6.15	图神经网络 (GNN)	38
7	特征提取与选择 (6 学时张燕明)	39
7.1	维数灾难 (Curse of Dimensionality)	39
7.2	特征提取 (Feature Extraction)	39
7.3	线性方法	39
7.3.1	1. 主成分分析 (PCA)	39
7.3.2	2. 线性判别分析 (Fisher LDA)	40
7.3.3	3. 多维缩放 (MDS)	40
7.4	非线性方法 (流形学习)	40
7.5	特征选择 (Feature Selection)	40
8	模型选择 (3 学时张燕明)	42
8.1	模型选择原则	42
8.2	模型评价标准	42
8.3	基于偏差和方差的分类器设计准则	42
8.4	分类器集成 (Ensemble Learning)	43
8.5	Adaboost 学习方法及其应用	43
8.5.1	1. Adaboost 算法流程	43
8.5.2	2. 理论性质	44
8.5.3	3. 应用: Viola-Jones 人脸检测	44
9	聚类分析 (6 学时张燕明)	45
9.1	基本概念	45
9.2	K 均值聚类 (K-Means)	45
9.3	模糊 K 均值聚类 (GMM & EM)	45
9.4	层次聚类 (Hierarchical Clustering)	46
9.5	谱聚类 (Spectral Clustering)	46
9.6	在线聚类与竞争学习	47
9.7	集成聚类 (Ensemble Clustering)	47

10 支持向量机与核方法 (6 学时向世明)	48
10.1 统计学习理论基础	48
10.2 线性可分支持向量机 (Hard Margin SVM)	48
10.3 线性支持向量机 (Soft Margin SVM)	48
10.4 对偶理论与核技巧	49
10.4.1 对偶问题 (Dual Problem)	49
10.4.2 核技巧 (Kernel Trick)	49
10.4.3 算法实现: SVM 预测流程	49
10.5 SVM 的扩展	50
11 决策树方法 (3 学时向世明)	51
11.1 特征选择准则	51
11.2 决策树生成算法	51
11.3 决策树剪枝 (Pruning)	52
11.4 随机森林 (Random Forests)	52
12 模式识别前沿趋势 (3 学时向世明)	54
12.1 课程内容总体回顾	54
12.2 模式识别发展现状与新常态	54
12.3 模式识别中的挑战性问题	54
13 考核 (6 学时向世明)	55
13.1 考试 + 答疑	55
附录: 常用 LaTeX 模板	56

1 绪论 (3 学时向世明)

1.1 模式识别基础

- 基本定义：
 - 模式 (**Pattern**): 对客体 (Object) 或事件 (Event) 的描述, 通常是向量形式。
 - 模式类 (**Pattern Class**): 具有共同属性的模式集合。
 - 模式识别: 利用机器 (计算机) 自动将特定模式映射到特定类别的过程。
- 经典实例:
 - 硬币分类: 利用尺寸、重量等特征区分不同面值的硬币。
 - 鱼的分类 (Duda 教材经典例子): 区分“三文鱼 (Salmon)”和“鲈鱼 (Sea Bass)”。单一特征 (如长度) 往往重叠严重, 需要多特征 (如长度 + 光泽度) 组合以寻找最佳决策边界。

1.2 模式识别系统流程

一个典型的模式识别系统包含以下五个核心环节:

1. 数据获取 (**Data Acquisition**): 通过传感器将物理变量转换为数字信号 (如摄像头采集图像、麦克风采集声音)。
2. 预处理 (**Preprocessing**): 去噪、分割、平滑、归一化, 旨在提高信噪比, 简化后续处理。
3. 特征提取与选择 (**Feature Extraction & Selection**):
 - 提取: 从原始数据中计算新的特征 (变换)。
 - 选择: 从一组特征中挑选出最具区分力的子集 (降维), 避免“维数灾难”。
4. 分类决策 (**Classification/Decision**): 利用训练好的模型 (分类器) 对输入特征进行分类判定。
5. 后处理 (**Post-processing**): 利用上下文信息 (Context)、先验知识或代价函数对分类结果进行修正 (例如在 OCR 中利用语言模型纠错)。

1.3 模式识别系统设计

设计周期通常是一个不断迭代的反馈过程:

- 数据收集: 划分训练集 (Training Set)、验证集 (Validation Set) 和测试集 (Test Set)。
- 特征选择: 寻找具有不变性 (**Invariance**) 的特征 (如对平移、旋转、缩放不敏感)。
- 模型选择: 决定使用统计模型、神经网络模型还是句法模型; 决定模型的复杂度。
- 训练 (**Training**): 利用样本进行学习, 估计模型参数。

- **评价 (Evaluation):** 核心指标是泛化能力 (**Generalization**), 即在未见过的测试数据上的表现, 需警惕过拟合 (**Overfitting**)。

1.4 模式识别方法分类

基于数据形式 :

- **统计模式识别 (Statistical PR):** 基于特征向量, 利用概率论和统计学理论 (本课程重点)。
- **句法/结构模式识别 (Syntactic/Structural PR):** 将模式分解为基元 (Primitives), 利用形式语言和语法规则描述结构关系 (适合汉字、染色体等结构性强的对象)。

基于学习方式 :

- **监督学习 (Supervised Learning):** 训练数据带有类别标签 (Label)。
- **无监督学习 (Unsupervised Learning):** 训练数据无标签, 旨在发现数据内部结构 (如聚类)。
- **强化学习 (Reinforcement Learning):** 通过与环境交互, 基于奖励/惩罚机制进行学习。

1.5 本课程内容体系

- **基础:** 贝叶斯决策理论 (统计模式识别的基石)。
- **估计:** 概率密度函数估计 (参数法与非参数法)。
- **分类器:** 线性分类器、非线性分类器 (神经网络、SVM、决策树)。
- **工程:** 特征提取与选择、聚类分析。

2 贝叶斯决策理论 (3 学时向世明)

2.1 核心公式

首先, 我们需要充分理解先验、似然、后验的意义。在贝叶斯决策理论中, 最重要的公式是贝叶斯公式:

$$P(\omega_i|x) = \frac{p(x|\omega_i)P(\omega_i)}{p(x)} \quad (1)$$

其中, $P(\omega_i)$ 是类别 ω_i 的先验概率, $p(x|\omega_i)$ 是在类别 ω_i 下观测到样本 x 的似然概率密度, $P(\omega_i|x)$ 是在观测到样本 x 后类别 ω_i 的后验概率。

一个典型案例是 HIV 检测, 假设某种检测方法对 HIV 阳性患者的检测准确率为 99.9%, 对 HIV 阴性患者的检测准确率为 99.5%。如果一个人被检测为阳性, 我们需要计算他实际患有 HIV 的概率。假设总体中 HIV 阳性率为 0.1%, 则可以利用贝叶斯公式计算后验概率。概率计算为:

$$P(\text{HIV}^+|\text{Test}^+) = \frac{P(\text{Test}^+|\text{HIV}^+)P(\text{HIV}^+)}{P(\text{Test}^+)} \quad (2)$$

2.2 最小错误率贝叶斯决策

已知先验概率以及类条件概率密度函数, 最小错误率贝叶斯决策等价于最大后验概率决策:

$$\text{Decide } \omega_i \text{ if } P(\omega_i|x) > P(\omega_j|x), \forall j \neq i \quad (3)$$

这比较容易理解, 因为大多数情况下我们总是希望在当前特征下做出最有可能的决策。

2.3 最小风险贝叶斯决策

在实际应用中, 不同类型的错误造成的后果严重程度不同 (例如误诊癌症), 因此引入损失函数 (Loss Function) 的概念。定义 $\lambda(\alpha_i|\omega_j)$ 为当真实类别为 ω_j 时采取决策 α_i 所带来的损失。

我们的目标是**最小化期望风险 (Expected Risk)**。对于观测样本 x , 采取决策 α_i 的**条件风险**定义为:

$$E_{\omega|x}[\lambda(\alpha_i|\omega)] = \sum_{j=1}^c \lambda(\alpha_i|\omega_j) \underbrace{P(\omega_j|x)}_{\text{在该条件下}\omega\text{发生的概率}} \quad (4)$$

决策规则: 选择风险最小的决策 a :

$$a = \arg \min_{j=1, \dots, a} R(\alpha_j|x) \quad (5)$$

特例: 0-1 损失函数如果损失函数定义为“对则无损, 错则罚 1”:

$$\lambda(\alpha_i|\omega_j) = \begin{cases} 0, & i = j \\ 1, & i \neq j \end{cases} \quad (6)$$

此时, 最小风险决策完全等价于**最小错误率贝叶斯决策** (即最大后验概率决策 MAP)。

2.4 带拒识的贝叶斯决策 (Reject Option)

在某些高风险应用（如医疗诊断、指纹识别）中，如果分类器对某个样本的判断信心不足，为了避免做出严重的错误决策，可以选择“拒绝识别”（Reject），交由人工处理。

- **动作空间扩展**：定义决策集合为 $\{\alpha_1, \dots, \alpha_c, \alpha_{c+1}\}$ ，其中 α_{c+1} 表示“拒识”。
- **损失函数定义**：设 λ_s 为误分带来的损失（Substitution cost）， λ_r 为拒识带来的损失（Rejection cost）。通常要求 $0 < \lambda_r < \lambda_s$ （否则没必要拒识）。

$$\lambda(\alpha_i|\omega_j) = \begin{cases} 0, & i = j \quad (\text{正确}) \\ \lambda_s, & i \neq j, i \leq c \quad (\text{误分}) \\ \lambda_r, & i = c + 1 \quad (\text{拒识}) \end{cases} \quad (7)$$

- **条件风险**：

– 做出分类决策 α_i ($i \leq c$) 的风险：

$$R(\alpha_i|x) = \sum_{j \neq i} \lambda_s P(\omega_j|x) = \lambda_s [1 - P(\omega_i|x)]$$

– 做出拒识决策 α_{c+1} 的风险：

$$R(\alpha_{c+1}|x) = \lambda_r$$

- **决策规则**：当且仅当拒识的风险小于分类的最小风险时，选择拒识。

$$\lambda_r < \min_{i \leq c} R(\alpha_i|x) = \lambda_s (1 - \max_i P(\omega_i|x))$$

整理得拒识条件为：

$$\max_i P(\omega_i|x) < 1 - \frac{\lambda_r}{\lambda_s} \quad (8)$$

即：只有当最大后验概率低于阈值 $T = 1 - \frac{\lambda_r}{\lambda_s}$ 时，才拒绝识别。

2.5 开放集识别 (Open Set Recognition)

传统的模式识别通常假设**闭集 (Closed Set)**环境，即测试样本一定属于训练集中定义的 c 个类别之一。然而在实际应用中，可能会出现训练集中从未见过的**未知类别 (Unknown Classes)**。

- **问题定义**：

- **训练集**：包含 c 个已知类别的样本。
- **测试集**：包含已知类别的样本 + 未知类别的样本。
- **目标**：正确分类已知类别样本，同时将未知类别样本识别为“未知”或“第 $c+1$ 类”。

- **与拒识的区别**：

- **拒识**：是在已知类别中“拿不准”（位于决策边界附近），属于**模糊区**。
- **开放集**：是完全不属于已知类别（位于特征空间远离已知分布的区域），属于**未知区**。

- **简单解决方案（基于阈值）**：

引入距离阈值或概率阈值。

$$\text{Decision}(x) = \begin{cases} \arg \max_i g_i(x), & \text{if } \max_i g_i(x) > \tau \\ \text{Unknown}, & \text{otherwise} \end{cases} \quad (9)$$

其中 $g_i(x)$ 可以是后验概率，也可以是样本到类中心的距离的负值（如 $1/d(x, \mu_i)$ ）。这实际上限制了每个类别的决策区域必须是紧致的（Bounded），而非延伸至无穷远。

2.6 分类器设计

分类器可以看作是一个计算一组**判别函数（Discriminant Functions）** $g_i(x)$ 并选择最大值的机器。

决策规则：如果 $g_i(x) > g_j(x), \forall j \neq i$ ，则将 x 归类为 ω_i 。

判别函数的形式：

1. **基础形式**：常用的判别函数形式有：

- $g_i(x) = P(\omega_i|x)$ （直接使用后验概率）
- $g_i(x) = p(x|\omega_i)P(\omega_i)$ （去掉分母 $p(x)$ ）
- $g_i(x) = \ln p(x|\omega_i) + \ln P(\omega_i)$ （取对数，变乘法为加法）

2. **更一般形式（General Case）**：PPT 中给出了判别函数的更一般定义：

$$g_i(x) = f(p(x|\omega_i)) + h(x, \omega_i) \quad (10)$$

其中：

- $f(\cdot)$ 是单调函数（通常取 $\ln$ ），用于变换似然度。
- $h(x, \omega_i)$ 是包含先验概率 $P(\omega_i)$ 和损失 λ 的项。

3. **注：与神经网络的联系**这与现代神经网络最后的判别器（**Discriminator**）设计本质一致。神经网络最后一层（Logits）输出的值 $z_i = w_i^T x + b_i$ ，实际上就是在拟合这个 $g_i(x)$ 。其中 $w_i^T x$ 对应特征的似然度部分，而偏置 b_i 往往隐含了先验概率 $P(\omega_i)$ 的信息。

2.7 高斯密度下的判别函数

当类条件概率密度 $p(x|\omega_i)$ 服从多元正态分布 $N(\mu_i, \Sigma_i)$ 时，判别函数具有解析解。

多元正态分布概率密度公式：

$$p(x) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right) \quad (11)$$

取对数形式的判别函数 $g_i(x)$ 为：

$$g_i(x) = -\frac{1}{2} (x - \mu_i)^T \Sigma_i^{-1} (x - \mu_i) - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i) \quad (12)$$

根据协方差矩阵 Σ_i 的不同，分为三种情形：

2.7.1 情形一： $\Sigma_i = \sigma^2 I$ （各特征独立且方差相等）

此时各类协方差矩阵相同且为对角阵，几何上数据分布呈正球体，大小相同。判别函数可简化。

1. 先验概率相等 ($P(\omega_i) = P(\omega_j)$):

- 判别依据：此时 $\ln P(\omega_i)$ 项为常数可忽略，决策规则简化为最小化欧氏距离平方：

$$g_i(x) \propto -\|x - \mu_i\|^2$$

- 分类器名称：最小距离分类器 (Minimum Distance Classifier)。
- 决策边界：连接两类均值向量 μ_i 和 μ_j 线段的垂直平分面，经过中点 $x_0 = \frac{1}{2}(\mu_i + \mu_j)$ 。

2. 先验概率不相等 ($P(\omega_i) \neq P(\omega_j)$):

- 判别依据：依然是线性判别函数，但包含偏置项：

$$g_i(x) = \frac{1}{\sigma^2} \mu_i^T x - \frac{1}{2\sigma^2} \mu_i^T \mu_i + \ln P(\omega_i)$$

- 决策边界：决策面依然与 $\mu_i - \mu_j$ 正交，但不再经过连线中点。
- 偏移规律：决策面会向先验概率较小的一侧偏移（即先验概率大的类别占据更大的决策区域）。偏移量为：

$$x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\sigma^2}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)} (\mu_i - \mu_j)$$

2.7.2 情形二： $\Sigma_i = \Sigma$ （协方差矩阵相等）

此时各类数据分布呈超椭球体，形状和方向相同（平行），但中心不同。

1. 先验概率相等 ($P(\omega_i) = P(\omega_j)$):

- 判别依据：最小化马氏距离 (Mahalanobis Distance) 平方：

$$r^2 = (x - \mu_i)^T \Sigma^{-1} (x - \mu_i) \quad (13)$$

- 决策边界：经过均值连线中点的超平面。但由于 Σ 不再是单位阵，决策面通常不与均值连线正交。

2. 先验概率不相等 ($P(\omega_i) \neq P(\omega_j)$):

- 判别依据：线性判别函数 $g_i(x) = w_i^T x + w_{i0}$ ，其中 $w_i = \Sigma^{-1} \mu_i$ 。
- 决策边界：决策面 x_0 同样会偏离中点，向先验概率较小的一方偏移。

2.7.3 情形三: $\Sigma_i \neq \Sigma_j$ (协方差矩阵任意)

- 几何意义: 各类数据的分布形状、方向、大小都不一样。
- 判别函数: 无法消除二次项, 形式为 $x^T W_i x + w_i^T x + w_{i0}$, 是二次判别函数。其中 $\mathbf{W}_i = -\frac{1}{2} \Sigma_i^{-1}$, $\mathbf{w}_i = \Sigma_i^{-1} \boldsymbol{\mu}_i$, $w_{i0} = -\frac{1}{2} \boldsymbol{\mu}_i^T \Sigma_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \ln(|\Sigma_i|) + \ln(P(\omega_i))$
- 决策边界: 超二次曲面。根据协方差矩阵的差异, 可能表现为超球面、超椭球面、超双曲面或超平面等多种形态。

• 一个具体例子

— 2类, 2D $P(\omega_1) = P(\omega_2) = 0.5$

$$\boldsymbol{\mu}_1 = \begin{bmatrix} 3 \\ 6 \end{bmatrix}; \quad \Sigma_1 = \begin{pmatrix} 1/2 & 0 \\ 0 & 2 \end{pmatrix} \quad \Sigma_1^{-1} = \begin{pmatrix} 2 & 0 \\ 0 & 1/2 \end{pmatrix}$$

$$\boldsymbol{\mu}_2 = \begin{bmatrix} 3 \\ -2 \end{bmatrix}; \quad \Sigma_2 = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \quad \Sigma_2^{-1} = \begin{pmatrix} 1/2 & 0 \\ 0 & 1/2 \end{pmatrix}$$

— 决策面 $g_1(\mathbf{x}) = g_2(\mathbf{x})$

$$x_2 = 3.514 - 1.125x_1 + 0.1875x_1^2$$




图 1: 贝叶斯判别例子

2.8 错误率分析

贝叶斯错误率 (Bayes Error) 是理论上分类器能达到的最低错误率。

$$P(\text{error}) = \int P(\text{error}|x)p(x)dx \quad (14)$$

对于两类问题, 错误率如下:

$$\begin{aligned} P(\text{error}) &= P(\mathbf{x} \in R_2, \omega_1) + P(\mathbf{x} \in R_1, \omega_2) \\ &= \int_{R_2} p(\mathbf{x} | \omega_1) P(\omega_1) d\mathbf{x} + \int_{R_1} p(\mathbf{x} | \omega_2) P(\omega_2) d\mathbf{x} \\ &= P(\mathbf{x} \in R_2 | \omega_1) P(\omega_1) + P(\mathbf{x} \in R_1 | \omega_2) P(\omega_2) \end{aligned} \quad (15)$$

多类情形如下:

$$P(\text{error}) = \sum_{i=1}^c \sum_{j \neq i} P(\mathbf{x} \in R_j, \omega_i) \quad (16)$$

2.9 离散特征贝叶斯分类




图 2: 离散分布图

当特征向量 $x = [x_1, \dots, x_d]^T$ 的分量是离散值（如性别、血型、二值化图像）而非连续值时，我们需要使用概率质量函数（PMF）而非概率密度函数。

- **维数灾难:** 如果每个特征 x_j 有 L 个可能的取值，那么 d 维特征空间的总状态数为 L^d 。要估计每个状态的条件概率 $P(x|\omega_i)$ ，需要的样本量呈指数级增长。
- **朴素贝叶斯假设 (Naïve Bayes Assumption):** 为了简化估计，假设在给定类别 ω_i 的条件下，各个特征分量 x_j 之间是相互独立的。

$$P(x|\omega_i) = \prod_{j=1}^d P(x_j|\omega_i) \quad (17)$$

虽然这个假设在现实中往往不成立，但朴素贝叶斯分类器在实际应用中（如文本分类）常表现出惊人的有效性。

2.9.1 独立二值特征 (Independent Binary Features)

这是一个特例，假设每个特征 $x_j \in \{0, 1\}$ （伯努利分布）。设 $p_{ij} = P(x_j = 1|\omega_i)$ ，即在 ω_i 类中第 j 个特征为 1 的概率。

- **似然函数:**

$$P(x|\omega_i) = \prod_{j=1}^d p_{ij}^{x_j} (1 - p_{ij})^{1-x_j} \quad (18)$$

- **判别函数推导:** 取对数似然比 $g(x) = \ln \frac{P(x|\omega_1)}{P(x|\omega_2)} + \ln \frac{P(\omega_1)}{P(\omega_2)}$ 。代入后可整理为线性判别函数形式:

$$g(x) = \sum_{j=1}^d w_j x_j + w_0 \quad (19)$$

其中权重 w_j 和偏置 w_0 分别为:

$$w_j = \ln \frac{p_{1j}(1 - p_{2j})}{p_{2j}(1 - p_{1j})}, \quad w_0 = \sum_{j=1}^d \ln \frac{1 - p_{1j}}{1 - p_{2j}} + \ln \frac{P(\omega_1)}{P(\omega_2)} \quad (20)$$

- **结论：**对于独立二值特征，贝叶斯分类器的决策边界是一个**超平面**（线性分类器）。

下面是一个三维二值分布的例子。

- **一个例子: 3D binary data**

- $P(\omega_1)=0.5, P(\omega_2)=0.5$

- $p_i=0.8, q_i=0.5, \quad i=1,2,3$

$$P(\mathbf{x}|\omega_1) = \prod_{i=1}^d p_i^{x_i} (1-p_i)^{1-x_i} \quad P(\mathbf{x}|\omega_2) = \prod_{i=1}^d q_i^{x_i} (1-q_i)^{1-x_i}$$

$$g(\mathbf{x}) = \sum_{i=1}^d w_i x_i + w_0$$

$$w_i = \ln \frac{.8(1-.5)}{.5(1-.8)} = 1.3863$$

$$w_0 = \sum_{i=1}^3 \ln \frac{1-.8}{1-.5} + \ln \frac{.5}{.5} = -2.7489$$




图 3: 3D binary example

2.10 复合模式分类 (Compound Decision)

当我们不仅是对单个样本分类，而是要对一连串相关的样本 $X = (x_1, \dots, x_n)$ 进行分类（例如语音识别、手写体识别）时，需要考虑上下文信息。

- **目标：**找到最优的类别序列 $\omega = (\omega_1, \dots, \omega_n)$ 使得后验概率 $P(\omega|X)$ 最大。
- **马尔可夫假设：**

1. 观测独立性: $p(X|\omega) = \prod p(x_t|\omega_t)$

2. 状态转移（一阶马尔可夫链）: $P(\omega_t|\omega_{t-1}, \dots) = P(\omega_t|\omega_{t-1})$

这构成了隐马尔可夫模型 (HMM) 的基础。

2.11 多分类器融合 (Multi-classifier Fusion)

当对于同一个分类问题有 K 个不同的分类器时，我们可以利用贝叶斯方法将它们的结果进行融合，以期获得比单一分类器更好的性能。

- **基本思路：**将 K 个分类器的输出 $e_1, e_2, \dots, e_K$ 看作是样本 x 的一个新的特征向量 $\mathbf{e} = [e_1, e_2, \dots, e_K]^T$ 。

- **融合决策**：在新的特征空间中应用贝叶斯公式计算后验概率：

$$P(\omega_i|\mathbf{e}) = \frac{p(\mathbf{e}|\omega_i)P(\omega_i)}{p(\mathbf{e})} \quad (21)$$

其中 $p(\mathbf{e}|\omega_i) = p(e_1, \dots, e_K|\omega_i)$ 是联合类条件概率密度。

- **独立性假设**：直接估计联合概率 $p(e_1, \dots, e_K|\omega_i)$ 需要的样本量随分类器数量指数级增加。通常假设各分类器在给定类别下是条件独立的（Naïve Bayes 假设）：

$$p(e_1, \dots, e_K|\omega_i) \approx \prod_{k=1}^K p(e_k|\omega_i) \quad (22)$$

这样可以将复杂的高维估计问题简化为一维估计问题。

2.12 模式分类与特征的关系

- **贝叶斯错误率 (Bayes Error Rate)**：

- 对于给定的特征空间，贝叶斯错误率是分类错误率的**理论下界**。它由特征空间中类条件概率密度的重叠程度决定，与具体的分类器设计无关。
- 想要降低贝叶斯错误率，唯一的方法是**改进特征空间**（如寻找更有区分力的特征、增加新特征）。

- **特征维数的影响**：

- **理想情况**：增加特征维数通常会增加类间距离（如高斯分布下的马氏距离 r^2 ），从而降低贝叶斯错误率。例如，数据在 1D 投影上重叠，但在 3D 空间中可能完全可分。
- **实际情况**：在训练样本有限的情况下，增加特征维数并不总能降低错误率。

- **过拟合 (Overfitting)**：

- **现象**：模型在训练集上表现完美（如用高阶多项式拟合），但在测试集上误差很大。
- **原因**：特征维数过高相对于样本数过少，导致参数估计（如协方差矩阵）不准确。例如，估计 d 维协方差矩阵至少需要 $d+1$ 个样本，要获得准确估计则需要更多。
- **对策**：
 1. **特征降维**：特征提取（PCA, LDA）或特征选择。
 2. **正则化 (Regularization / Shrinkage)**：对参数估计进行平滑。例如正则化判别分析 (RDA)，将协方差矩阵向单位阵或公共协方差矩阵收缩：

$$\hat{\Sigma}_i(\alpha) = (1 - \alpha)\hat{\Sigma}_i + \alpha\mathbf{I} \quad (23)$$

3 概率密度函数估计 (6 学时张燕明)

3.1 基本概念

- **参数估计 (Parametric Estimation):** 假设概率密度函数 $p(x|\theta)$ 的形式已知 (如正态分布), 但其中的参数 θ 未知。任务是利用样本集估计这些参数。
- **非参数估计 (Non-parametric Estimation):** 不假设概率密度函数的数学形式, 直接由样本估计概率密度函数本身。
- **统计量 (Statistic):** 样本的某种函数 $d(x_1, \dots, x_n)$, 用于推断总体信息 (如样本均值)。
- **估计类型:**
 - **点估计 (Point Estimation):** 构造一个统计量作为参数的估计值 (如 $\hat{\mu}$)。
 - **区间估计 (Interval Estimation):** 确定参数的一个可能取值范围 (置信区间)。

3.2 最大似然估计 (Maximum Likelihood Estimation, MLE)

- **基本原理:** 假设样本 $D = \{x_1, \dots, x_n\}$ 是独立同分布 (i.i.d.) 的。最大似然估计的目标是找到参数 $\hat{\theta}$, 使得观测到当前样本集的概率 (似然) 最大。

- **似然函数:**

$$l(\theta) = p(D|\theta) = \prod_{i=1}^n p(x_i|\theta) \quad (24)$$

- **对数似然函数:** 为了计算方便 (将乘法转为加法), 通常最大化对数似然:

$$H(\theta) = \ln l(\theta) = \sum_{i=1}^n \ln p(x_i|\theta) \quad (25)$$

- **求解方法:** 令梯度为 0: $\nabla_{\theta} H(\theta) = 0$ 。
- **高斯分布下的 MLE:** 对于 $N(\mu, \Sigma)$, 其参数估计为:

- 均值: $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$ (样本均值)
- 协方差: $\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})(x_i - \hat{\mu})^T$ (样本协方差, 注意分母为 n 而非 $n-1$)

3.3 贝叶斯估计 (Bayesian Estimation)

- **核心思想:** 与极大似然估计不同, 贝叶斯估计将参数 θ 视为一个随机变量。
- **如何使用 $p(\theta|D)$ 获得关于数据的分布?** PPT 中给出了以下两种主要方法:

方法一：最大后验估计 (Maximum A Posteriori, MAP)

- 基本原理：选择使后验概率 $p(\theta|D)$ 取值最大的参数 θ 作为估计值。
- 数学表达式：

$$\hat{\theta}_{MAP} = \arg \max_{\theta} p(\theta|D) = \arg \max_{\theta} [p(D|\theta)p(\theta)] \quad (26)$$

通过取对数，可以转化为：

$$\hat{\theta}_{MAP} = \arg \max_{\theta} [\ln p(D|\theta) + \ln p(\theta)] \quad (27)$$

- 物理意义：在似然函数的基础上引入了先验信息。
- 联系：机器学习中普遍使用的 L_2 正则化（权重衰减），在统计学上等价于假设参数 θ 服从高斯先验 $N(0, I)$ 后的 MAP 估计。

方法二：数据的后验分布 (The Posterior Distribution of Data)

这是完整的贝叶斯方法，不把参数固定为某一个点，而是考虑参数的所有可能性。

- 基本原理：利用全概率公式，对给定参数 θ 下的概率密度进行加权平均，权重即为参数的后验概率 $p(\theta|D)$ 。
 - 预测公式：
- $$p(x|D) = \int_{\theta} p(x|\theta, D)p(\theta|D)d\theta = \int_{\theta} p(x|\theta)p(\theta|D)d\theta \quad (28)$$
- （注：假设给定参数 θ 时， x 的分布与训练集 D 无关）。
- 物理意义：这是不同参数下的密度函数的加权平均。
 - 近似计算：当积分难以直接计算时，常用 M 个采样点的平均来近似：

$$p(x|D) \approx \frac{1}{M} \sum_{i=1}^M p(x|\theta_i) \quad (29)$$

考点/重点: 重点对比

- MAP 最终得到的是一个确定的参数值 $\hat{\theta}$ ，预测时使用 $p(x|\hat{\theta})$ 。
- 数据的后验分布最终得到的是一个完整的概率分布 $p(x|D)$ ，它综合了参数空间中所有可能的模型。

补充笔记：贝叶斯估计公式详解

贝叶斯估计的核心预测公式为：

$$p(x|D) = \int \underbrace{p(x|\theta)}_{\text{第一项}} \underbrace{p(\theta|D)}_{\text{第二项}} d\theta \quad (30)$$

这两项的物理意义和获取方式完全不同，详细辨析如下：

1. 第一项 $p(x|\theta)$ ——模型假设（已知形式）

这一项代表“在参数 θ 确定的情况下，样本 x 服从什么分布”。

- 来源：人为假设 / 先验知识。在做贝叶斯估计之前，必须先选定一个概率模型（如正态分布、指数分布等）。
- 获取方式：直接写出概率密度函数的数学公式。
- 例子：若假设数据服从正态分布 $N(\mu, \sigma^2)$ （设 σ^2 已知， $\theta = \mu$ ），则第一项就是正态分布的密度公式：

$$p(x|\mu) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (31)$$

注意：在此处 x 是自变量， μ 被视为暂时的常数。

2. 第二项 $p(\theta|D)$ ——参数后验（计算核心）

这一项代表“在观察到训练集 D 之后，参数 θ 取各种值的可能性是多少”。这是贝叶斯估计计算最繁琐的一步。

- 来源：通过 贝叶斯公式 计算得出。

- 计算公式：

$$p(\theta|D) = \frac{p(D|\theta)P(\theta)}{p(D)} = \frac{(\prod_{k=1}^n p(x_k|\theta)) P(\theta)}{\int (\prod_{k=1}^n p(x_k|\theta)) P(\theta) d\theta} \quad (32)$$

- 计算步骤：

1. 确定先验分布 $P(\theta)$ ：根据经验假设 θ 的分布（例如：假设均值 μ 本身也服从一个正态分布 $N(\mu_0, \sigma_0^2)$ ）。
2. 计算联合似然 $p(D|\theta)$ ：利用独立同分布 (i.i.d.) 假设，将训练集中所有样本的概率乘起来：

$$p(D|\theta) = \prod_{k=1}^n p(x_k|\theta)$$

（这里用到的 $p(x_k|\theta)$ 就是第一项里的那个公式）。

3. 相乘并归一化：

$$\text{后验} \propto \text{似然} \times \text{先验}$$

计算乘积后，除以归一化因子（分母），得到最终的参数分布函数。

考点/重点: 总结

- $p(x|\theta)$ ：是你选的（模型假设，直接写公式）。
- $p(\theta|D)$ ：是你算的（利用数据 D 更新先验 $P(\theta)$ 得到的参数分布）。

3.4 正态分布下的贝叶斯估计

以一维正态分布为例，假设方差 σ^2 已知，估计均值 μ 。设 μ 的先验分布为 $N(\mu_0, \sigma_0^2)$ 。

- 参数后验分布： $p(\mu|D)$ 仍为正态分布 $N(\mu_n, \sigma_n^2)$ 。

$$\mu_n = \frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2} \hat{\mu}_n + \frac{\sigma^2}{n\sigma_0^2 + \sigma^2} \mu_0 \quad (33)$$

$$\sigma_n^2 = \frac{\sigma_0^2 \sigma^2}{n\sigma_0^2 + \sigma^2} \quad (34)$$

其中 $\hat{\mu}_n$ 是样本均值。可以看出，后验均值 μ_n 是样本均值和先验均值的加权和。

- 性质：

- 当 $n \rightarrow \infty$ 时， $\mu_n \rightarrow \hat{\mu}_n$ ， $\sigma_n^2 \rightarrow 0$ 。参数分布收敛于一个尖峰（Dirac delta 函数），贝叶斯估计趋近于最大似然估计。
- 概率密度估计结果 $p(x|D)$ 是 $N(\mu_n, \sigma^2 + \sigma_n^2)$ ，方差包含了数据噪声 σ^2 和参数估计的不确定性 σ_n^2 。

3.5 贝叶斯学习 (Bayesian Learning)

贝叶斯估计的一个重要特性是支持**增量学习 (Incremental Learning)**。随着样本逐个到来，参数的后验分布可以不断更新，且不需要重新计算之前的所有数据。

3.5.1 1. 迭代更新公式

记 $D^n = \{x_1, x_2, \dots, x_n\}$ 为包含 n 个样本的集合。根据贝叶斯公式，参数 θ 的后验分布可以表示为（注意这个表示需要一定的技巧，可以稍微背一背）：

$$p(\theta|D^n) = \frac{p(x_n|\theta)p(\theta|D^{n-1})}{\int p(x_n|\theta)p(\theta|D^{n-1})d\theta} \quad (35)$$

即：

$$\underbrace{p(\theta|D^n)}_{\text{当前后验}} \propto \underbrace{p(x_n|\theta)}_{\text{当前似然}} \cdot \underbrace{p(\theta|D^{n-1})}_{\text{当前先验 (即上一时刻的后验)}} \quad (36)$$

这意味着，上一时刻的后验分布 $p(\theta|D^{n-1})$ 直接作为当前时刻的先验分布。随着 $n \rightarrow \infty$ ，后验分布 $p(\theta|D^n)$ 通常会越来越尖锐，最终收敛于参数真值附近的 Dirac δ 函数。

3.5.2 2. 实例：均匀分布边界的估计

问题描述：假设样本 x 服从均匀分布 $U(0, \theta)$ ，即 $p(x|\theta) = 1/\theta$ ($0 \leq x \leq \theta$)，否则为 0。已知先验分布 $p(\theta) = U(0, 10)$ 。现有观测样本序列 $D = \{4, 7, 2, 8\}$ ，试利用贝叶斯学习迭代估计 θ 。

迭代过程：

1. 初始状态 (D^0):

$$p(\theta|D^0) = p(\theta) = \frac{1}{10}, \quad 0 \leq \theta \leq 10$$

2. 样本 $x_1 = 4$ 到来:

$$p(\theta|D^1) \propto p(x_1|\theta)p(\theta|D^0) = \frac{1}{\theta} \cdot \frac{1}{10}$$

由于必须满足 $\theta \geq x_1 = 4$, 故有效区间为 $4 \leq \theta \leq 10$ 。

$$p(\theta|D^1) \propto \frac{1}{\theta}, \quad 4 \leq \theta \leq 10$$

3. 样本 $x_2 = 7$ 到来:

$$p(\theta|D^2) \propto p(x_2|\theta)p(\theta|D^1) \propto \frac{1}{\theta} \cdot \frac{1}{\theta} = \frac{1}{\theta^2}$$

约束条件更新为 $\theta \geq \max(4, 7) = 7$ 。

$$p(\theta|D^2) \propto \frac{1}{\theta^2}, \quad 7 \leq \theta \leq 10$$

4. 样本 $x_3 = 2$ 到来:

$$p(\theta|D^3) \propto p(x_3|\theta)p(\theta|D^2) \propto \frac{1}{\theta} \cdot \frac{1}{\theta^2} = \frac{1}{\theta^3}$$

约束条件 $\theta \geq \max(7, 2) = 7$ 不变。

$$p(\theta|D^3) \propto \frac{1}{\theta^3}, \quad 7 \leq \theta \leq 10$$

5. 样本 $x_4 = 8$ 到来:

$$p(\theta|D^4) \propto p(x_4|\theta)p(\theta|D^3) \propto \frac{1}{\theta} \cdot \frac{1}{\theta^3} = \frac{1}{\theta^4}$$

约束条件更新为 $\theta \geq \max(7, 8) = 8$ 。

$$p(\theta|D^4) = \alpha \cdot \frac{1}{\theta^4}, \quad 8 \leq \theta \leq 10$$

归一化与最终结果: 计算归一化常数 α :

$$\frac{1}{\alpha} = \int_8^{10} \frac{1}{\theta^4} d\theta = \left[-\frac{1}{3\theta^3} \right]_8^{10} = \frac{1}{3} \left(\frac{1}{512} - \frac{1}{1000} \right) \approx \frac{1}{3147.5}$$

因此, 参数 θ 的最终后验分布为:

$$p(\theta|D^4) = \begin{cases} \frac{3147.5}{\theta^4}, & 8 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases} \quad (37)$$

数据的后验分布 (Posterior Predictive Distribution):

$$p(x|D) = \int p(x|\theta)p(\theta|D)d\theta = \int_{\max(x,8)}^{10} \frac{1}{\theta} \cdot \frac{3147.5}{\theta^4} d\theta$$

最终计算结果为:

$$p(x|D) = \begin{cases} 0.1134, & 0 \leq x \leq 8 \\ 786.9(\frac{1}{x^4} - \frac{1}{10^4}), & 8 < x \leq 10 \end{cases} \quad (38)$$

3.6 特征维数问题

- **过拟合 (Overfitting)**: 模型在训练集上表现极好, 但在测试集上性能不佳。通常由于模型过于复杂 (如高阶多项式拟合) 或训练数据相对于特征维数过少导致。
- **维数灾难**: 随着特征维数增加, 为了维持同样的估计精度, 所需样本量呈指数级增长。
- **解决方法**:
 - **特征降维**: 特征选择或提取 (如 PCA)。
 - **正则化 (Regularization/Shrinkage)**: 例如在估计协方差矩阵时, 使用 $\Sigma(\alpha) = (1 - \alpha)\hat{\Sigma} + \alpha I$ 进行平滑。

3.7 期望最大化 (EM) 算法

EM 算法是一种迭代算法, 用于含有隐变量 (Latent Variables) 的概率模型参数的极大似然估计。

3.7.1 1. 经典案例: 三硬币模型 (The Three Coins Example)

问题描述: 假设有 3 枚硬币 A、B、C, 正面朝上的概率分别为 π, p, q 。进行如下实验:

1. 先掷硬币 C。若正面朝上选 A, 若反面朝上选 B。
2. 掷选出的硬币 (A 或 B), 记录结果 (正面记为 1, 反面记为 0)。

重复 n 次实验, 观测数据为 $Y = (y_1, y_2, \dots, y_n)$, 但我们不知道每次具体选的是 A 还是 B (即隐变量 Z 未知)。目标是估计参数 $\theta = (\pi, p, q)$ 。

EM 算法求解过程:

- **E 步 (计算隐变量的期望)**: 在当前参数 $\theta^{(i)}$ 下, 计算第 j 次实验是硬币 A 抛出的概率 (即隐变量的后验概率):

$$\mu_j^{(i+1)} = P(z_j = A | y_j, \theta^{(i)}) = \frac{\pi^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j}}{\pi^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j} + (1-\pi^{(i)})(q^{(i)})^{y_j}(1-q^{(i)})^{1-y_j}} \quad (39)$$

- **M 步 (最大化似然更新参数)**: 基于 E 步计算出的概率权重 μ_j , 重新估计参数:

$$\begin{aligned} \pi^{(i+1)} &= \frac{1}{n} \sum_{j=1}^n \mu_j^{(i+1)} \\ p^{(i+1)} &= \frac{\sum_{j=1}^n \mu_j^{(i+1)} y_j}{\sum_{j=1}^n \mu_j^{(i+1)}} \\ q^{(i+1)} &= \frac{\sum_{j=1}^n (1 - \mu_j^{(i+1)}) y_j}{\sum_{j=1}^n (1 - \mu_j^{(i+1)})} \end{aligned} \quad (40)$$

3.7.2 2. EM 算法在高斯混合模型 (GMM) 中的应用

A. 什么是 GMM 与隐变量？ 高斯混合模型 (GMM) 是指由 K 个高斯分布 (Gaussian Distributions) 线性叠加而成的概率模型。其概率密度函数定义为：

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x|\mu_k, \Sigma_k) \quad (41)$$

其中：

- π_k 是混合系数 (Mixing Coefficient)，且满足 $\sum \pi_k = 1, \pi_k \geq 0$ 。
- $\mathcal{N}(x|\mu_k, \Sigma_k)$ 是第 k 个高斯分量 (Component)。

隐变量 (Latent Variable) 是什么？

在 GMM 的生成过程中，我们可以想象存在一个“上帝掷骰子”的过程：

1. 这是一个 K 面骰子。上帝首先根据概率 π 掷出骰子，决定选择第 k 个高斯分布。这个选择的结果就是**隐变量**，记为 z (通常用 one-hot 向量表示)。
2. 既然选定了第 k 个分布，就从 $\mathcal{N}(\mu_k, \Sigma_k)$ 中采样生成观测数据 x 。

为什么它是“隐”的？

因为我们只能观测到最终的数据 x (比如班里学生的身高)，但我们不知道这个 x 具体是由哪个分布生成的 (不知道该学生具体属于哪个班级)。EM 算法的目标就是：推断每个数据 x 来自哪个分布 (E 步)，并据此反推这些分布的参数 (M 步)。

B. EM 算法求解步骤 假设观测数据 $X = \{x_1, \dots, x_N\}$ ，模型参数为 $\theta = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^K$ 。

1. E 步：计算响应度 (Responsibility)

这一步相当于我们在做“软分类”。我们需要计算在当前参数下，第 n 个观测数据 x_n 属于第 k 个高斯分量的后验概率，记为 $\gamma(z_{nk})$ ：

$$\gamma(z_{nk}) = P(z_k = 1|x_n) = \frac{\overbrace{\pi_k \mathcal{N}(x_n|\mu_k, \Sigma_k)}^{\text{分量 } k \text{ 产生该数据的可能性}}}{\sum_{j=1}^K \pi_j \mathcal{N}(x_n|\mu_j, \Sigma_j)} \quad (42)$$

直观理解：如果 x_n 离第 k 个高斯中心的距离 μ_k 很近，那么该分量对这个点的“响应度” $\gamma(z_{nk})$ 就会很高 (接近 1)；反之则接近 0。

2. M 步：参数更新

既然我们不知道每个点确切属于哪个组，我们就用 E 步算出的“响应度”作为权重，来对参数进行加权更新。

首先定义第 k 个分量的有效样本总数 N_k ：

$$N_k = \sum_{n=1}^N \gamma(z_{nk}) \quad (43)$$

注：这相当于把所有数据点分给第 k 类的那部分“份额”加起来。

更新公式如下：

- 更新均值 μ_k (加权平均中心):

$$\mu_k^{new} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) x_n \quad (44)$$

解释: 谁对第 k 类响应度高, 谁就在计算中心时拥有更大的话语权。

- 更新协方差 Σ_k (加权离散程度):

$$\Sigma_k^{new} = \frac{1}{N_k} \sum_{n=1}^N \gamma(z_{nk}) (x_n - \mu_k^{new})(x_n - \mu_k^{new})^T \quad (45)$$

- 更新混合系数 π_k (该类的比重):

$$\pi_k^{new} = \frac{N_k}{N} \quad (46)$$

解释: 第 k 类的有效样本数占总样本数的比例。

重复 E 步和 M 步直到似然函数收敛。

3.7.3 3. EM 算法总结

- **核心思想:** 将复杂的不完全数据似然最大化问题, 转化为简单的完全数据似然期望最大化问题。
- **收敛性:** EM 算法保证每次迭代后似然函数值非递减 ($L(\theta^{(t+1)}) \geq L(\theta^{(t)})$), 但不能保证收敛到全局最优 (容易陷入局部最优, 且对初值敏感)。
- **与 K-Means 的关系:** K-Means 可以看作是 GMM 的一种特例 (硬分配, 协方差矩阵为单位阵且趋于 0 时)。

3.8 隐马尔可夫模型 (HMM) 详解与实例

HMM 是处理序列数据的统计模型。为了理解它, 我们使用一个经典的“盒子摸球”模型作为贯穿始终的例子。

3.8.1 1. 具体的模型定义与矩阵实例

假设我们要模拟一个摸球实验:

- **隐状态 (Hidden States) $Q = \{1, 2, 3\}$:** 我们有 3 个盒子, 分别编号 1, 2, 3。我们看不见手里拿的是哪个盒子。
- **观测值 (Observations) $V = \{, \}$:** 我们每次只能看到从盒子里摸出来的球的颜色。

一个完整的 HMM 模型 $\lambda = (\pi, A, B)$ 由以下具体参数定义:

- (1) **初始状态分布 π (Initial Distribution)** 刚开始实验时, 选中各个盒子的概率:

$$\pi = \begin{bmatrix} 0.2 \\ 0.4 \\ 0.4 \end{bmatrix} \quad (\text{即: 选中盒子 1 的概率是 0.2, 盒子 2 是 0.4...}) \quad (47)$$

(2) 状态转移矩阵 A (Transition Matrix) 如果我们当前在由盒子 i 摸球，下一次换到盒子 j 的概率。这是 HMM 的核心 (马尔可夫链):

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix} \quad (48)$$

解读: $A_{12} = 0.2$ 表示如果当前在盒子 1, 下一次有 0.2 的概率转移到盒子 2。


(3) 观测概率矩阵 B (Emission Matrix) 在盒子 j 中摸出某种颜色球的概率 (观测独立性):

$$B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix} \quad \begin{array}{l} \text{列 1: 红色} \\ \text{列 2: 白色} \end{array} \quad (49)$$

解读: $B_{21} = 0.4$ 表示在盒子 2 中, 摸到红球的概率是 0.4。

3.8.2 2. 状态转移图 (State Transition Diagram)

上述模型可以用有向图直观表示。节点代表隐状态 (盒子), 边代表转移概率 A_{ij} 。



3.8.3 3. HMM 的三个核心问题推导

假设我们观测到一个序列: $O = (\text{红}, \text{白})$ 。

问题一: 评估 (Evaluation) - 前向算法 问: 这个序列 $O = (\text{红}, \text{白})$ 发生的总概率 $P(O|\lambda)$ 是多少?

解: 我们需要累加所有可能的路径。使用前向变量 $\alpha_t(i)$ 。

第一步 ($t = 1$): 算出第一次摸到“红”且分别在盒子 1,2,3 的概率。

$$\begin{aligned}\alpha_1(1) &= \pi_1 \times B_1(\text{红}) = 0.2 \times 0.5 = 0.10 \\ \alpha_1(2) &= \pi_2 \times B_2(\text{红}) = 0.4 \times 0.4 = 0.16 \\ \alpha_1(3) &= \pi_3 \times B_3(\text{红}) = 0.4 \times 0.7 = 0.28\end{aligned}\tag{50}$$

第二步 ($t = 2$): 从 $t = 1$ 的所有状态转移过来，并摸到“白”。以计算 $\alpha_2(1)$ 为例（即第 2 次在盒子 1 且摸到白球的概率）：

$$\begin{aligned}\alpha_2(1) &= \left[\sum_{i=1}^3 \alpha_1(i) A_{i1} \right] \times B_1(\text{白}) \\ &= (0.10 \times 0.5 + 0.16 \times 0.3 + 0.28 \times 0.2) \times 0.5 \\ &= (0.05 + 0.048 + 0.056) \times 0.5 = 0.154 \times 0.5 = 0.077\end{aligned}\tag{51}$$

同理计算 $\alpha_2(2), \alpha_2(3)$ ，最后求和即为总概率。

问题二：解码 (Decoding) - 维特比算法 问：观测到 (红, 白)，最可能背后的盒子序列是什么？是 $(1 \rightarrow 1)$ 还是 $(3 \rightarrow 2)$ ？

解：我们要找一条“最强路径”。

- 前向算法里我们做的是 **求和 (Sum)**: $\sum \alpha_1(i) A_{ij}$ 。
- 维特比算法里我们做的是 **取最大值 (Max)**: $\max(\delta_1(i) A_{ij})$ 。

在 $t = 2$ 时，我们不看所有路径的总和，只看哪一个上一步状态 i 最容易跳到当前的 j 。我们记录下这个“最强上家”，最后倒着找回去。

问题三：学习 (Learning) - Baum-Welch 算法 问：如果我也不知道矩阵 A, B, π 里的数，只给你一堆红红白白的球的序列，怎么反推这些矩阵？

解：这就是 EM 算法。

- **E 步**：先猜一组 A, B ，算出每一步大概率是在哪个盒子里（计算 $\gamma_t(i)$ 和 $\xi_t(i, j)$ ）。
- **M 步**：根据算出来的概率，“数数”。

– 比如， A_{12} 的新估计值 = (也就是从 1 跳到 2 的期望次数) / (在 1 的期望总次数)。

4 非参数法 (Non-parametric Methods) (3 学时张燕明)

4.1 1. 引言：为什么要用非参数法？

- 参数法的局限性：
 - 假设样本服从特定的概率分布（如高斯分布），但在实际应用中，数据的分布往往是多峰的、非对称的或未知的。
 - 如果假设的分布模型与真实分布不符，会导致严重的系统误差（偏差大）。
- 非参数法的定义：
 - 不预先假设概率密度函数的数学形式。
 - 完全由数据驱动：概率密度的形式完全由训练样本决定。
- 核心思想：利用样本在特征空间中的局部密度来估计整体概率密度。

4.2 2. 概率密度估计的基本原理

- 概率与密度的关系：设概率密度为 $p(x)$ ，样本落在点 x 附近区域 R 中的概率 P 为：

$$P = \int_R p(x') dx' \quad (52)$$

若区域 R 足够小（体积为 V ），且 $p(x)$ 平滑，则 $P \approx p(x)V$ 。

- 极大似然估计：假设 n 个样本中有 k 个落入区域 R 。根据二项分布，概率 P 的最大似然估计为 $\hat{P} = k/n$ 。
- 通用估计公式：

$$p_n(x) = \frac{k_n/n}{V_n} \quad (\text{样本比例} / \text{体积}) \quad (53)$$

- 收敛性定理 (理论基础)：为了使估计 $p_n(x)$ 收敛于真实密度 $p(x)$ ，当 $n \rightarrow \infty$ 时，必须满足三个条件：

1. $\lim_{n \rightarrow \infty} V_n = 0$ （保证空间分辨率，偏差趋于 0）
2. $\lim_{n \rightarrow \infty} k_n = \infty$ （保证统计稳定性，方差趋于 0）
3. $\lim_{n \rightarrow \infty} k_n/n = 0$ （保证估计收敛，虽然 k 变大，但相对比例要变小）

4.3 3. Parzen 窗估计 (核密度估计)

策略：固定体积 V_n （通常令 $V_n = h_n^d/\sqrt{n}$ 等形式收缩），求落入该体积内的样本数 k_n 。

- 核函数 (Kernel Function) $\varphi(u)$ ：相当于定义了一个“窗口”形状。必须满足：

$$\varphi(u) \geq 0, \quad \int \varphi(u) du = 1$$

- 估计公式:

$$p_n(x) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h_n^d} \varphi\left(\frac{x - x_i}{h_n}\right) \quad (54)$$

直观理解: 在每个样本点 x_i 处堆放一个“小土包”(核函数), 最后把所有土包叠加起来取平均, 就得到了整体的地形(密度函数)。

- 典型窗函数:

- 方窗 (Hypercube Kernel):

$$\varphi(u) = \begin{cases} 1, & |u_j| \leq 1/2 \\ 0, & \text{otherwise} \end{cases}$$

特点: 计算简单, 但估计出的密度函数不连续(阶梯状)。

- 高斯窗 (Gaussian Kernel):

$$\varphi(u) = \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{1}{2}\|u\|^2\right)$$

特点: 光滑连续, 是应用最广泛的核函数。

- 窗宽 h_n (Bandwidth) 的关键影响:

- h_n 过大: 分辨率低, 细节丢失, 偏差大 (High Bias), 平滑过度。
- h_n 过小: 对噪声敏感, 出现很多尖峰, 方差大 (High Variance), 欠平滑。
- 最佳 h_n : 通常取 $h_n \propto n^{-1/5}$ (在 MSE 准则下)。

- 收敛性分析:

- 均值: $E[p_n(x)]$ 是真实密度 $p(x)$ 与窗函数的卷积(平滑后的版本)。
- 方差: $\text{Var}[p_n(x)] \approx \frac{p(x)}{nV_n}$ 。可见 V_n 不能太小, 否则方差爆炸。

4.4 4. k_n -近邻估计 (k-NN Estimation)

策略: 固定样本数 k_n (通常取 $k_n = \sqrt{n}$), 让体积 V_n 自动适应数据的疏密。

- 方法: 以 x 为中心扩大区域, 直到包含第 k_n 个最近邻, 此时区域半径为 r , 体积为 $V_n = c_d r^d$ 。
- 公式:

$$p_n(x) = \frac{k_n/n}{V_n(x)} \quad (55)$$

- 与 Parzen 窗的对比:

- Parzen 窗在数据稀疏区域效果差(很多窗是空的)。
- k-NN 估计在数据密集处 V_n 小(分辨率高), 稀疏处 V_n 大(平滑好)。

- 缺陷: 估计出的 $p_n(x)$ 拖尾严重, 积分为 ∞ , 不是严格的概率密度函数。

4.5 5. 最近邻分类器 (Nearest Neighbor Rule)

- 几何解释: Voronoi 泰森多边形:

- 将特征空间划分为许多多边形区域, 每个区域包含一个训练样本。
- 区域内任意一点到该样本的距离都小于到其他样本的距离。
- 1-NN 的决策边界就是这些 Voronoi 多胞体的边界。

- 渐进错误率分析: 设 P^* 为贝叶斯最优错误率 (Bayes Error), P 为 1-NN 的错误率。当 $n \rightarrow \infty$ 时:

- 直观逻辑: 当样本无限密时, 测试样本 x 与其最近邻 x' 无限接近, 它们属于某一类的后验概率几乎相同。
- 界限公式:

$$P^* \leq P \leq P^* \left(2 - \frac{c}{c-1} P^* \right) \leq 2P^* \quad (56)$$

其中 c 是类别数。

- 结论: 虽然 1-NN 很简单 (甚至没有训练过程), 但其性能下限非常有保证——错误率绝不会超过贝叶斯错误率的 2 倍。

4.6 6. 计算复杂度的优化

k-NN 的主要缺点是测试阶段计算量大 (Lazy Learning), 需计算与所有 n 个样本的距离。

- 1. 快速搜索 (Fast Search):

- 部分距离法 (Partial Distance): 计算欧氏距离时, 如果前 m 维的累积平方和已经超过了当前的最小距离, 直接在此中断, 不计算剩下的维度。
- 分层搜索树 (KD-Tree):
 - * 将样本空间按坐标轴递归分割, 构成二叉树。
 - * 查询时通过回溯搜索, 平均复杂度从 $O(n)$ 降至 $O(\log n)$ 。
 - * 在高维空间 ($d > 20$) 效果退化为线性扫描。

- 2. 样本集剪辑与压缩:

- 剪辑 (Editing) ——去噪: 利用 Wilson 算法等, 剔除那些被“异类”包围的样本 (通常是噪声或重叠区), 使得决策边界更平滑 (Smooth), 提高泛化能力。
- 压缩 (Condensing) ——减量: 保留定义决策边界的“边界样本”, 剔除那些在 Voronoi 区域内部、对分类不起作用的样本。目的是在保持分类性能不变的前提下, 大幅减少存储和计算量。

4.7 7. 距离度量与切距离

- 闵可夫斯基距离 (Minkowski Metric):

$$L_p(x, y) = (\sum |x_i - y_i|^p)^{1/p}$$

- $p = 1$: 曼哈顿距离。
- $p = 2$: 欧氏距离。
- $p = \infty$: 切比雪夫距离 ($\max |x_i - y_i|$).

- 切距离 (Tangent Distance) - Simard:

- **背景**: 用于手写数字识别。解决图像旋转、缩放、笔画粗细变化导致的欧氏距离失效问题。
- **原理**: 对于一个图像 x , 其经过各种变换 (旋转 α 等) 构成的轨迹是一个流形 (Manifold)。
- 在 x 处做切平面 (Tangent Plane), 用点到切平面的距离代替点到点的距离。
- **效果**: 具有对仿射变换的不变性 (Invariance)。

附录：模式识别常用 LaTeX 模板

1. 学术三线表模板

表 1: 不同分类器在 Iris 数据集上的错误率对比

算法	训练集错误率	测试集错误率	计算耗时 (ms)
KNN ($K = 3$)	0.02	0.04	12
Fisher LDA	0.05	0.06	2
SVM (RBF Kernel)	0.01	0.03	45

2. 图片插入模板 (已注释)

3. 模式识别核心公式模板

贝叶斯决策规则： 后验概率计算：

$$P(\omega_i|\mathbf{x}) = \frac{p(\mathbf{x}|\omega_i)P(\omega_i)}{p(\mathbf{x})}$$

最小错误率决策：若 $P(\omega_i|\mathbf{x}) > P(\omega_j|\mathbf{x})$ ，则判定 $\mathbf{x} \in \omega_i$ 。

多元正态分布 (Gaussian Density)：

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right]$$

线性判别函数 (Linear Discriminant)：

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

最大似然估计 (MLE)：

$$\hat{\boldsymbol{\theta}} = \arg \max_{\boldsymbol{\theta}} \prod_{k=1}^N p(\mathbf{x}_k|\boldsymbol{\theta}) \quad \Rightarrow \quad \hat{\boldsymbol{\theta}} = \arg \max_{\boldsymbol{\theta}} \sum_{k=1}^N \ln p(\mathbf{x}_k|\boldsymbol{\theta})$$

SVM 优化目标 (硬间隔)：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, N$$

特征值分解 (PCA)： 协方差矩阵 $\mathbf{S}$ 的特征方程：

$$\mathbf{S} \mathbf{u}_i = \lambda_i \mathbf{u}_i$$

K-Means 目标函数：

$$J = \sum_{j=1}^K \sum_{\mathbf{x} \in C_j} \|\mathbf{x} - \mathbf{m}_j\|^2$$