

(请大家预习)

第5章

线性判别函数

Linear Discriminant Functions

张 燕 明

ymzhang@nlpr.ia.ac.cn

peopleucas.ac.cn/~ymzhang

模式分析与学习课题组 (PAL)

多模态人工智能系统实验室 中科院自动化所

助教: 杨 奇 (yangqi2021@ia.ac.cn)

张 涛 (zhangtao2021@ia.ac.cn)

第5讲内容回顾

第二次作业已布置，请按时完成

- 任务：估计任意点 $\mathbf{x}$ 处的概率密度 $p(\mathbf{x})$

- 非参数估计的基本原理

- 以 $\mathbf{x}$ 点为中心找一个体积为 V 小区域 R
- 假设 n 个样本中，有 k 个落入 R ，则：

$$p(\mathbf{x}) \approx \frac{\hat{P}}{V} \approx \frac{k}{nV}$$

概率/体积

- 难点： R 的选取

- R 太大：估计值是一个很大区域上的平均，不能近似 $p(\mathbf{x})$
- R 太小：很可能没有样本落入 R 中，估计值不稳定

Parzen窗估计

- 当 n 给定时，选择一个固定大小的窗口，在任意位置 $\mathbf{x}$ ，统计落入小窗的样本数 k


$$p(\mathbf{x}) \approx \frac{k}{nV}$$

- 计数由窗函数完成，并由此得到Parzen窗估计的解析表达式


$$p_n(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \frac{1}{V_n} \varphi\left(\frac{\mathbf{x} - \mathbf{x}_i}{h_n}\right) = \frac{1}{n} \sum_{i=1}^n \delta(\mathbf{x} - \mathbf{x}_i)$$

- 当 n 增加时，使窗口大小随之减小，如：令 $V_n = V_0/\sqrt{n}$ ，从而使 $n \rightarrow \infty$ 时， $V_n \rightarrow 0$ ， $p_n(\mathbf{x}) \rightarrow p(\mathbf{x})$


Parzen窗
 $V_n = 1/\sqrt{n}$




$n=1$




$n=4$



$n=9$



$n=16$



$n=100$

第3页


K近邻估计

- 当 n 给定时，选择一个固定的近邻数 k ，在任意位置 $\mathbf{x}$ ，计算包含 k 个样本的最小窗的体积 V


$$p(\mathbf{x}) \approx \frac{k}{nV}$$

- 当 n 增加时，使近邻数 k 随之增加，如：令 $k_n = k_0\sqrt{n}$ ，从而使 $n \rightarrow \infty$ 时， $k_n \rightarrow \infty$ ， $p_n(\mathbf{x}) \rightarrow p(\mathbf{x})$


k 近邻
 $k_n = \sqrt{n}$




$n=1$




$n=4$



$n=9$



$n=16$



$n=100$

K近邻分类器

- 理论分析

- 样本数 $n \rightarrow \infty$ 时，最近邻分类器($K=1$)的错误率不超过2倍的贝叶斯错误率； $n \rightarrow \infty, K \rightarrow \infty$ 时， K 近邻分类器的错误率收敛至贝叶斯错误率
- 本质上， K 近邻分类器是使用 K 近邻方法估计类条件概率密度，然后用贝叶斯公式计算类后验概率的一种分类方法

- 距离度量

- K 近邻分类高度依赖距离度量的选择
- 常见距离度量
 - 无监督的距离度量、基于先验知识的距离度量

非参数密度估计的总结

- 优点:

- 基于概率和密度的原始定义，无需对数据分布的形式做任何假设，适用性广
- 当样本数趋于无穷时，Parzen窗估计和 K 近邻估计都能收敛到真实分布
- 方法简单；在低维问题上，性能出色

- 缺点:

- 选择合适的窗宽、近邻数都不容易
- 对高维数据，需要的样本量极大
- 存储开销和计算开销很大

本讲内容提要

- 5.1 引言：生成模型 vs 判别模型
- 5.2 线性判别函数与决策面
- 5.3 广义线性判别函数
- 5.4 感知准则函数
- 5.5 松弛方法
- 5.6 最小平方误差（MSE）准则函数
- 5.7 Ho-Kashyap 方法
- 5.8 多类线性判别函数

5.1 引言

- 统计模式分类的途径

- 估计类条件概率密度函数 $p(\mathbf{x}|\omega_i)$

- 利用贝叶斯公式求出类后验概率，然后决策
 - 核心步骤：概率密度估计（参数估计和非参数估计）

生成模型


- 直接估计类后验概率 $P(\omega_i|\mathbf{x})$ 或判别函数 $g_i(\mathbf{x})$

- 不估计类条件概率密度函数，直接找到可用于分类的判别函数

判别模型

5.1 引言

统计模式识别方法



5.1 引言

- Why 判别模型?
 - 生成 vs 判别
- 判别模型分类
 - 线性判别函数：感知器、支持向量机、Fisher线性判别函数
 - 广义线性判别函数：核学习机
 - 非线性模型：神经网络、决策树
 - 非参数模型： K 近邻分类、高斯过程

5.1 引言

- 本章学习判别函数的技术路线：
 - 假定有 n 个 d 维空间中的样本，每个样本的类别已知，且一共有 c 个不同的类别。
 - 对于给定的新样本 $\mathbf{x} \in \mathbb{R}^d$ ，用判别函数预测 $\mathbf{x}$ 属于 $\omega_1, \omega_2, \dots, \omega_c$ 中的哪个类别。(推理、预测问题)
 - 假定判别函数的形式已知，使用样本来估计 c 个判别函数的参数。(参数估计、学习问题)

5.2 线性判别函数与决策面


- 线性判别函数

$$g(\mathbf{x}) = \sum_{i=1}^d w_i x_i + w_0 = \mathbf{w}^T \mathbf{x} + w_0$$

↑ ↑
权重向量 偏移(阈值)

- 两类情形的决策准则:

$$\begin{cases} \mathbf{x} \in \omega_1, & \text{if } g(\mathbf{x}) > 0 \\ \mathbf{x} \in \omega_2, & \text{if } g(\mathbf{x}) < 0 \\ \text{uncertain}, & \text{if } g(\mathbf{x}) = 0 \end{cases}$$




线性分类器（神经网络描述）

5.2 线性判别函数与决策面

- 两类情形的决策面

- $g(\mathbf{x})=0$ 定义了一个决策面，它是类 ω_1 和 ω_2 的分界面。
- $g(\mathbf{x})=0$ 是一个超平面，记为 H ，将特征空间分为两个区域。
- 位于该平面的任意向量与法向量 $\mathbf{w}$ 垂直：
 - 如果 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 位于该超平面内，则有：

$$\mathbf{w}^T(\mathbf{x}_1 - \mathbf{x}_2) = g(\mathbf{x}_1) - g(\mathbf{x}_2) = 0$$




5.2 线性判别函数与决策面

- 两类情形的决策面
 - 对于任意样本 $\mathbf{x}$ ，将其向决策面内投影，并写成两个向量之和：

$$\mathbf{x} = \mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

其中， $\mathbf{x}_p$ 为 $\mathbf{x}$ 在超平面 H 上的投影， r 为点 $\mathbf{x}$ 到超平面 H 的代数距离。如果 $\mathbf{x}$ 在超平面正侧，则 $r > 0$ ；反之 $r < 0$ 。



5.2 线性判别函数与决策面

- 两类情形的决策面


- 因为 $g(\mathbf{x}_p) = 0$, 于是有:

$$\begin{aligned} g(\mathbf{x}) &= \mathbf{w}^T \left(\mathbf{x}_p + r \frac{\mathbf{w}}{\|\mathbf{w}\|} \right) + w_0 \\ &= r \|\mathbf{w}\| \end{aligned}$$

$$\Rightarrow r = \frac{g(\mathbf{x})}{\|\mathbf{w}\|}$$

r 为点 $\mathbf{x}$ 到超平面 H 的代数距离。

此外, 可得坐标原点到超平面的距离为: $w_0 / \|\mathbf{w}\|$



5.2 线性判别函数与决策面

- 多类情形($c > 2$) : 采用多个两类分类器
 - 一对多(One-vs-all) : 逐一将每个类与所有的其它类进行配对, 可以构造 c 个两类分类器。
 - 预测时, 得到 c 个分类结果, 若仅有一个分类器预测为正, 则对应类别即为预测结果; 否则, 需要进一步比较判别函数值。
 - 一对一(One-vs-one): 两两(类-类)配对, 可以构造 $c(c-1)/2$ 个两类分类器。
 - 预测时, 得到 $c(c-1)/2$ 个分类结果, 使用投票法得到预测结果。
 - 多对多: ECOC(error correcting output codes), 层次分类

5.2 线性判别函数与决策面

- 例子： $c = 4$

- 一对多(One-vs-all)：

- 4个两类分类器

$$\{1 : (2,3,4)\}, \{2 : (1,3,4)\}, \{3 : (1,2,4)\}, \{4 : (1,2,3)\}$$

- 一对一(One-vs-one)：

- 6个两类分类器

$$\{1 : 2\}, \{1 : 3\}, \{1 : 4\}, \{2 : 3\}, \{2 : 4\}, \{3 : 4\}$$


- 多对多(ECOC)：

- 2个两类分类器

$$\{(1,2) : (3,4)\}, \{(1,3) : (2,4)\}$$

5.2 线性判别函数与决策面

- 多类情形：One-vs-all (3类)



存在不确定区域

不使用判别函数的函数值，仅使用决策面进行分类

5.2 线性判别函数与决策面

- 多类情形：one-vs-all最大判别函数决策

- 考虑one-vs-all情形，构建 c 个两类线性分类器：

$$g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0}, \quad i = 1, 2, \dots, c$$


- 对样本 $\mathbf{x}$ ，采用最大判别函数决策：

$$g_i(\mathbf{x}) = \max_{j=1,2,\dots,c} g_j(\mathbf{x}) \Rightarrow \mathbf{x} \in \omega_i$$

线性机器将样本空间分为 c 个可以决策的区域 $R_1, \dots, R_c$

5.2 线性判别函数与决策面


- 多类情形：one-vs-all最大判别函数决策



线性机器将样本空间分为 c 个可以决策的区域 $R_1, \dots, R_c$


5.2 线性判别函数与决策面

- 线性机器决策面：例子
 - 可以多达 $c(c-1)/2$ 个决策边界（有些可能可以删除）！



5.2 线性判别函数与决策面


- 多类情形：One-vs-one (3类) 使用投票法对测试样本分类



5.2 线性判别函数与决策面

- 线性决策面优缺点：

- 所有的决策区域都是凸的 — 便于分析
- 所有的决策区域都是单通连的 — 便于分析
- **凸决策区域**：限制分类器的灵活性和精度
- **单通连区域**：不利于复杂分布数据的分类（比如：分离的多模式分布）



5.3 广义线性判别函数

- 线性判别函数形式简单，计算方便，且已被充分研究。
人们期望将其推广至非线性判别函数。

一种有效的途径是将原来的数据点 $\mathbf{x}$ 通过一种适当的非线性映射将其映射为新的数据点 $\mathbf{y}$ ，从而在新的特征空间内应用线性判别函数方法。

5.3 广义线性判别函数

- 以二次判别函数为例

$$g(\mathbf{x}) = w_0 + \sum_{i=1}^d w_i x_i + \sum_{i=1}^d \sum_{j=1}^d w_{ij} x_i x_j \quad \text{其中, } \mathbf{x} = [x_1, x_2, \dots, x_d]^T$$

$g(\mathbf{x})$ 是一个二次超曲面；共有 $\hat{d} = (d+1)(d+2)/2$ 个待估计参数($w_{ij} = w_{ji}$)

- 定义如下非线性变换 $\mathbf{y}(\mathbf{x})$ ，把 $\mathbf{x}$ 从 d 维变换到 $\hat{d}$ 维

$$y_1(\mathbf{x}) = 1$$

$$y_2(\mathbf{x}) = x_1$$

$$y_3(\mathbf{x}) = x_2$$

...


$$y_{d+1}(\mathbf{x}) = x_d$$

$$y_{d+2}(\mathbf{x}) = x_1^2$$

$$y_{d+3}(\mathbf{x}) = x_1 x_2$$

...

$$y_{\frac{(d+1)(d+2)}{2}}(\mathbf{x}) = x_d^2$$



$$g(\mathbf{x}) = w_0 + \sum_{i=1}^d w_i x_i + \sum_{i=1}^d \sum_{j=1}^d w_{ij} x_i x_j = \sum_{i=1}^{\hat{d}} a_i y_i(\mathbf{x})$$

5.3 广义线性判别函数

- 一般情形

$$g(\mathbf{x}) = \sum_{i=1}^{\hat{d}} a_i \boxed{y_i(\mathbf{x})}$$

$y_i(\mathbf{x})$: 变换函数

令 $\mathbf{a} = [a_1, a_2, \dots, a_{\hat{d}}]^T$, $\mathbf{y} = [y_1, y_2, \dots, y_{\hat{d}}]^T$ 可以简写为:


$$g(\mathbf{x}) = \mathbf{a}^T \mathbf{y}(\mathbf{x})$$

1. $\mathbf{a}$ 为广义权重向量, $\mathbf{y}$ 是经由 $\mathbf{x}$ 所变成的新数据点。
2. 广义判别函数 $g(\mathbf{x})$ 对 $\mathbf{x}$ 而言是非线性的, 对 $\mathbf{y}$ 是线性的。
3. $g(\mathbf{x})$ 对 $\mathbf{y}$ 是齐次的, 意味着决策面通过新空间的坐标原点。且任意点 $\mathbf{y}$ 到决策面的代数距离为 $\mathbf{a}^T \mathbf{y} / \|\mathbf{a}\|$ 。
4. 当新空间的维数足够高时, $g(\mathbf{x})$ 可以逼近任意判别函数。
5. 但是, 新空间的维数远远高于原始空间的维数 d 时, 会造成维数灾难问题。

5.3 广义线性判别函数

- 例子1

- 设有一维样本空间 X ，我们期望如果 $x < -1$ 或者 $x > 0.5$ ，则 x 属于 ω_1 类；如果 $-1 < x < 0.5$ ，则属于 ω_2 类，请设计一个判别函数 $g(x)$ 。



5.3 广义线性判别函数

- 例子1

- 设有一维样本空间 X ，我们期望如果 $x < -1$ 或者 $x > 0.5$ ，则 x 属于第一类 ω_1 ；如果 $-1 < x < 0.5$ ，则属于第二类 ω_2 ，请设计一个判别函数 $g(x)$ 。
- 判别函数： $g(x) = (x-0.5)(x+1)$
- 决策规则： $g(x) > 0$, x 属于 ω_1 ； $g(x) < 0$, x 属于 ω_2


$$\begin{aligned} g(x) &= (x-0.5)(x+1) \\ &= -0.5 + 0.5x + x^2 \\ &= a_1 + a_2x + a_3x^2 \end{aligned}$$

映射关系 $\Rightarrow \mathbf{y} = \begin{pmatrix} 1 \\ x \\ x^2 \end{pmatrix} \doteq \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix}$

5.3 广义线性判别函数

- 例子1

$$\mathbf{y} = \begin{pmatrix} 1 \\ x \\ x^2 \end{pmatrix} := \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix}$$



在低维空间中线性不可分，在高维空间中线性可分

- 例子2

- 对线性判别函数采用齐次增广表示

- 此时，增广样本向量 $\mathbf{y}$ 与增广权重向量 $\mathbf{a}$ 如下：

$$\mathbf{y} = \begin{pmatrix} 1 \\ \mathbf{x} \end{pmatrix} = [1 \quad x_1 \quad \cdots \quad x_d]^T, \quad \mathbf{a} = \begin{pmatrix} w_0 \\ \mathbf{w} \end{pmatrix} = [w_0 \quad w_1 \quad \cdots \quad w_d]^T$$

- 线性判别函数的齐次简化： $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 = \mathbf{a}^T \mathbf{y}$

- Y空间中任意一点 $\mathbf{y}$ 到 H 的距离为： $r = \frac{g(\mathbf{x})}{\|\mathbf{a}\|} = \frac{\mathbf{a}^T \mathbf{y}}{\|\mathbf{a}\|}$


线性齐次空间增加了一个维度，分类效果与原来的决策面相同。但分类面通过坐标原点，对于某些分析，将具有优势。

上述增广样本向量将在后面的讨论中经常使用。


5.4 感知准则函数

- 线性可分性

- 来自两个类别的 n 个样本： $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n$ （齐次增广表示）。
- 如果存在一个权向量 $\mathbf{a}$ ，对所有 $\mathbf{y} \in \omega_1$ ，均有 $\mathbf{a}^T \mathbf{y} > 0$ ，对所有 $\mathbf{y} \in \omega_2$ ，均有 $\mathbf{a}^T \mathbf{y} < 0$ ，则这组样本集为线性可分的；否则为线性不可分的。



线性可分



线性不可分

- 本节考虑“两类线性可分”情形

5.4 感知准则函数


- 样本规范化
 - 如果样本集是线性可分的，将属于 ω_2 的所有样本由 $\mathbf{y}$ 变成 $-\mathbf{y}$ ，对所有 n 样本，将得到 $\mathbf{a}^T \mathbf{y} > 0$ 。
 - 经过上述处理之后，在训练的过程中就不必考虑原来的样本类别。该操作称为对样本的规范化(normalization) 处理。
 - 规范化增广样本：
 - 首先，将所有样本写成齐次增广形式： $\mathbf{y} = (\mathbf{x}^T, 1)^T \in R^{d+1}$
 - 然后，将属于 ω_2 的所有样本由 $\mathbf{y}$ 变成 $-\mathbf{y}$ 。
 - 后续讲解主要将集中于“规范化增广样本”。

5.4 感知准则函数—两类可分情形

- 解向量与解区
 - 在线性可分的情形下，满足 $\mathbf{a}^T \mathbf{y}_i > 0, i = 1, 2, \dots, n$ 的权向量 $\mathbf{a}$ 称为解向量。
 - 权向量 $\mathbf{a}$ 可以理解为权空间中的一点，每个样本 $\mathbf{y}_i$ 对 $\mathbf{a}$ 的位置均起到限制作用，即要求 $\mathbf{a}^T \mathbf{y}_i > 0$
 - 任何一个样本点 $\mathbf{y}_i$ 均可以确定一个超平面 $H_i : \mathbf{a}^T \mathbf{y}_i = 0$ ，其法向量为 $\mathbf{y}_i$ 。如果解向量 $\mathbf{a}^*$ 存在，它必定在 H_i 的正侧，因为在正侧才能满足 $(\mathbf{a}^*)^T \mathbf{y}_i > 0$ 。
 - 按上述方法， n 个样本将产生 n 个超平面。每个超平面将空间分成两个半空间。如果解向量存在，它必定在所有这些正半空间的交集区域内。这个区域内的任意向量均是一个可行的解向量 $\mathbf{a}^*$ 。

5.4 感知准则函数—两类可分情形

- 解区与解向量




给定一个可行的 $\mathbf{a}$, 即可得到一个分界面

5.4 感知准则函数


- 限制解区
 - 可行的解向量不是唯一的，有无穷多个。
 - 经验：越靠近区域中间的解向量，越能对新的样本正确分类
 - 可以引入一些条件来限制解空间
 - 比如：寻找一个单位长度的解向量 $\mathbf{a}$ ，能最大化样本到分界面的最小距离
 - 比如：寻找一个最小长度的解向量 $\mathbf{a}$ ，使 $\mathbf{a}^T \mathbf{y}_i \geq b > 0$ 。此时可以将 b 称为间隔 (margin)。
 - 解更加可靠，推广性更强
 - 防止算法收敛到解区的边界

5.4 感知准则函数

- 限制解区：移动一个间隔



$\mathbf{a}^T \mathbf{y}_i > 0$, 不考虑margin



将正半空间向外
推一定的距离后
构成的交集

$\mathbf{a}^T \mathbf{y}_i > b, b > 0$, 考虑margin

$$\therefore r = \frac{g(\mathbf{x})}{\|\mathbf{w}\|}$$

5.4 感知准则函数

- 感知准则函数
 - 任务：设有一组样本 $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n$ ，各样本均规范化增广表示。我们的目的是要寻找一个解向量 $\mathbf{a}$ ，使

$$\mathbf{a}^T \mathbf{y}_i > 0, \quad i=1, 2, \dots, n$$

5.4 感知准则函数

- 感知准则函数

- 考虑如下准则函数：

$$J_p(\mathbf{a}) = \sum_{\mathbf{y} \in Y} (-\mathbf{a}^T \mathbf{y}), \quad \text{其中, } Y \text{ 为错分样本集合}$$

- 当 $\mathbf{y}$ 被错分时, $\mathbf{a}^T \mathbf{y} \leq 0$, 则 $-\mathbf{a}^T \mathbf{y} \geq 0$ 。因此 $J_p(\mathbf{a})$ 总是大于等于0。在可分情形下, 当且仅当 Y 为空集时 $J_p(\mathbf{a})$ 将等于零, 这时将不存在错分样本。
 - 因此, 目标是最小化 $J_p(\mathbf{a})$: $\min_{\mathbf{a}} J_p(\mathbf{a})$
 - 这即是Frank Rosenblatt 于50年代提出的感知器 (Perceptron) 思想。

5.4 感知准则函数

- 感知准则函数

- 考察 $J_p(\mathbf{a})$ 对 $\mathbf{a}$ 的导数：
$$\frac{\partial J_p(\mathbf{a})}{\partial \mathbf{a}} = - \sum_{\mathbf{y} \in Y} \mathbf{y}$$

- 根据梯度下降法，有如下更新准则：

$$\mathbf{a}_{k+1} = \mathbf{a}_k - \eta_k \left. \frac{\partial J_p(\mathbf{a})}{\partial \mathbf{a}} \right|_{\mathbf{a}=\mathbf{a}_k} = \mathbf{a}_k + \eta_k \sum_{\mathbf{y} \in Y_k} \mathbf{y}$$

这里， $\mathbf{a}_{k+1}$ 是当前迭代的结果， $\mathbf{a}_k$ 是前一次迭代的结果， Y_k 是被 $\mathbf{a}_k$ 错分的样本集合， η_k 为步长因子（更新动力因子，学习率）。

• 可变增量批处理感知器算法

Batch Variable-Increment Perceptron

```
1  begin initialize:  $\mathbf{a}_0, \eta_0, k=0$ 
2      do  $k \leftarrow k+1$ 
3           $Y_k = \{\}$ ,  $j = 0$ 
4          do  $j \leftarrow j + 1$ 
5              if  $\mathbf{y}^j$  is misclassified, then append  $\mathbf{y}^j$  to  $Y_k$ 
6          until  $j = n$ 
7               $\mathbf{a}_{k+1} = \mathbf{a}_k + \eta_k \sum_{\mathbf{y} \in Y(k)} \mathbf{y}$  //发现所有错分样本，然后再修正
8          until  $Y_k = \{\}$  //直到所有样本均正确分类
9      return  $\mathbf{a}_k$ 
10 end
```

1. 称为“batch”是因为在迭代过程中同时考虑多个样本
2. 称为“variable increment”是因为步长 η_k 可变
3. 对于线性可分的样本集，算法可以在有限步内找到最优解。收敛速度取决于初始权向量和步长


5.4 感知准则函数

- 几何解释

- 由于所有被 $\mathbf{a}_k$ 错分的样本必然位于以 $\mathbf{a}_k$ 为法向量的超平面的负侧，**所以这些样本的和也必然在该侧。**

$$\mathbf{a}_k^T (\sum_{\mathbf{y} \in Y_k} \mathbf{y}) = \sum_{\mathbf{y} \in Y_k} \mathbf{a}_k^T \mathbf{y} < 0$$

- 在更新中， $\mathbf{a}_{k+1}$ **会向错分类样本之和靠近，因而朝着有利的方向移动。**一旦这些错分样本点穿过超平面，就正确分类了。



$$\begin{aligned} & \mathbf{a}_{k+1}^T (\sum_{\mathbf{y} \in Y_k} \mathbf{y}) \\ &= (\mathbf{a}_k + \eta_k \sum_{\mathbf{y} \in Y_k} \mathbf{y})^T (\sum_{\mathbf{y} \in Y_k} \mathbf{y}) = \mathbf{a}_k^T (\sum_{\mathbf{y} \in Y_k} \mathbf{y}) + \eta_k \left\| \sum_{\mathbf{y} \in Y_k} \mathbf{y} \right\|^2 \\ &> \mathbf{a}_k^T (\sum_{\mathbf{y} \in Y_k} \mathbf{y}) \end{aligned}$$

5.4 感知准则函数

- 固定增量单样本修正方法

- 每次迭代只考虑一个错分样本 $\mathbf{y}^k$ ，梯度下降法可以写成：

- $\mathbf{a}_{k+1} = \mathbf{a}_k + \eta_k \mathbf{y}^k$ 。考虑固定增量，即令 $\eta_k = 1$ ：

Fixed-Increment Single-Sample Perceptron

```
1  begin initialize:  $\mathbf{a}$ ,  $k=0$ 
2      do  $k \leftarrow k+1 \pmod n$ 
3          if  $\mathbf{y}^k$  is misclassified by  $\mathbf{a}$ , then  $\mathbf{a} = \mathbf{a} + \mathbf{y}^k$ 
4      until all patterns properly classified
5      return  $\mathbf{a}$ 
6  end
```

“固定增量”并不改变分类决策，相当于将样本作了一个 $1/\eta_k$ 的缩放。

5.4 感知准则函数

- 可变增量单样本修正方法

- 梯度下降法可以写成: $\mathbf{a}_{k+1} = \mathbf{a}_k + \eta_k \mathbf{y}^k$

Variable-Increment Perceptron with Margin

```
1  begin initialize:  $\mathbf{a}$ , margin  $b$ ,  $\eta_0$ ,  $k=0$ 
2      do  $k \leftarrow k+1 \pmod n$ 
3          if  $\mathbf{a}^T \mathbf{y}^k \leq b$ , then  $\mathbf{a} = \mathbf{a} + \eta_k \mathbf{y}^k$  //小于margin, 马上修正
4      until  $\mathbf{a}^T \mathbf{y}^k > b$  for all  $k$ 
5      return  $\mathbf{a}$ 
6  end
```


5.4 感知准则函数

- 几何解释

- 梯度下降: $\mathbf{a}_{k+1} = \mathbf{a}_k + \mathbf{y}^k$
- 由于 $\mathbf{a}_k$ 将 $\mathbf{y}^k$ 分错, 所以 $(\mathbf{a}_k)^T \mathbf{y}^k \leq 0$ 。此时, $\mathbf{y}^k$ 不在 $\mathbf{a}_k$ 确定的超平面 $(\mathbf{a}_k)^T \mathbf{y}^k = 0$ 的正侧。
- 若将 $\mathbf{y}^k$ 加到 $\mathbf{a}_k$ 上, 则 $\mathbf{a}_{k+1}$ 将向 $\mathbf{y}^k$ 靠近, 可能会穿过这个超平面 (即正确分类)。

$$(\mathbf{a}_{k+1})^T \mathbf{y}^k = (\mathbf{a}_k)^T \mathbf{y}^k + \|\mathbf{y}^k\|^2$$

$(\mathbf{a}_{k+1})^T \mathbf{y}^k$ 在原来的基础上增加了一个正数: $\|\mathbf{y}^k\|^2$



5.4 感知准则函数

- 算法收敛性

- 以固定增量单样本修正方法为例来说明算法的收敛性

- 对于权向量 $\mathbf{a}_k$ ，如果错分某样本，则将得到一次修正。由于在分错样本时 $\mathbf{a}_k$ 才得到修正，不妨假定只考虑由错分样本组成的序列。即是说，每次都只需利用一个分错样本来更正权向量。
 - 记错分样本序列为 $\mathbf{y}^1, \mathbf{y}^2, \dots, \mathbf{y}^k \dots$ 。考虑此情形的算法收敛性问题。

5.4 感知准则函数

- 感知准则函数—收敛性定理
 - 在样本线性可分的情形下，固定增量单样本权向量修正方法收敛，并可得到一个可行解。
- 证明思路
 - 设 $\mathbf{a}$ 是一个解向量，只要证明 $\|\mathbf{a}_{k+1} - \mathbf{a}\| < \|\mathbf{a}_k - \mathbf{a}\| - C$ 即可。
 - 即算法每次迭代都使权向量到解向量的距离减少一个常数 C
 - 假设 $\text{Dist} = \|\mathbf{a}_1 - \mathbf{a}\|$ ，则 Dist/C 次迭代后，算法收敛

5.4 感知准则函数

- 证明[略]

- 设 $\mathbf{a}$ 是一个解向量，对于任意一个正的标量 α ， $\alpha\mathbf{a}$ 也为一个可行解，于是有：

$$\mathbf{a}_{k+1} - \alpha\mathbf{a} = (\mathbf{a}_k - \alpha\mathbf{a}) + \mathbf{y}^k$$

$$\|\mathbf{a}_{k+1} - \alpha\mathbf{a}\|^2 = \|\mathbf{a}_k - \alpha\mathbf{a}\|^2 + 2(\mathbf{a}_k - \alpha\mathbf{a})^T \mathbf{y}^k + \|\mathbf{y}^k\|^2$$

由于 $\mathbf{y}^k$ 被错分，有 $(\mathbf{a}_k)^T \mathbf{y}^k \leq 0$ 。但 $\mathbf{a}^T \mathbf{y}^k > 0$ ，于是：

$$\|\mathbf{a}_{k+1} - \alpha\mathbf{a}\|^2 \leq \|\mathbf{a}_k - \alpha\mathbf{a}\|^2 - 2\alpha\mathbf{a}^T \mathbf{y}^k + \|\mathbf{y}^k\|^2$$

因此，寻找一个合适的 α ，满足 $\|\mathbf{a}_{k+1} - \alpha\mathbf{a}\|^2 \leq \|\mathbf{a}_k - \alpha\mathbf{a}\|^2$ 即可。

- 证明 (续) [略]

$$\beta^2 = \max_{i=1,\dots,n} \|\mathbf{y}_i\|^2, \quad \gamma = \min_i \mathbf{a}^T \mathbf{y}_i$$

– 令 $\|\mathbf{a}_{k+1} - \alpha \mathbf{a}\|^2 \leq \|\mathbf{a}_k - \alpha \mathbf{a}\|^2 - 2\alpha\gamma + \beta^2$

令 $\alpha = \beta^2 / \gamma$

$$\|\mathbf{a}_{k+1} - \alpha \mathbf{a}\|^2 \leq \|\mathbf{a}_k - \alpha \mathbf{a}\|^2 - \beta^2$$

因此，每次迭代，当前解距离可行解越来越近。
经过 $k+1$ 次迭代后：

$$\|\mathbf{a}_{k+1} - \alpha \mathbf{a}\|^2 \leq \|\mathbf{a}_1 - \alpha \mathbf{a}\|^2 - k\beta^2$$

由于 $\|\mathbf{a}_{k+1} - \alpha \mathbf{a}\|$ 总是非负的，所以至多经过如下次更正即可：

$$k_0 = \|\mathbf{a}_1 - \alpha \mathbf{a}\|^2 / \beta^2$$

5.5 松弛方法

- 学习准则

- 在感知函数准则中，目标函数中采用了 $-\mathbf{a}^T \mathbf{y}$ 的形式。实际上有很多其它准则也可以用于感知函数的学习。

- 线性准则: $J_p(\mathbf{a}) = \sum_{\mathbf{y} \in Y} (-\mathbf{a}^T \mathbf{y})$,
- 平方准则: $J_q(\mathbf{a}) = \sum_{\mathbf{y} \in Y} (\mathbf{a}^T \mathbf{y})^2$,


} Y 为错分样本集合

- 松弛准则: $J_r(\mathbf{a}) = \frac{1}{2} \sum_{\mathbf{y} \in Y} \frac{(\mathbf{a}^T \mathbf{y} - b)^2}{\|\mathbf{y}\|^2}$, Y 为 $\mathbf{a}^T \mathbf{y} \leq b$ 的样本集合

5.5 松弛方法

- 学习准则

- $J_p(\mathbf{a})$ 是分段线性的，因此其梯度是不连续的。
- $J_q(\mathbf{a})$ 的梯度是连续的，但目标函数过于平滑，收敛速度很慢（达到目标函数为零的区域的路径很平缓）。同时，目标函数过于受到最长样本的影响。
- $J_r(\mathbf{a})$ 则避免了这些缺点。 $J_r(\mathbf{a})=0$ 时，对所有 $\mathbf{y}$ ， $\mathbf{a}^T \mathbf{y} > b$ ，意味着集合 Y 是空集。



5.5 松弛方法

- 学习

- 梯度:
$$\frac{\partial J_r(\mathbf{a})}{\partial \mathbf{a}} = \sum_{\mathbf{y} \in Y} \frac{\mathbf{a}^T \mathbf{y} - b}{\|\mathbf{y}\|^2} \mathbf{y}$$

- 梯度下降:
$$\mathbf{a}_{k+1} = \mathbf{a}_k - \eta_k \sum_{\mathbf{y} \in Y} \frac{\mathbf{a}^T \mathbf{y} - b}{\|\mathbf{y}\|^2} \mathbf{y}$$

5.5 松弛方法

Batch Relaxation with Margin

```
1  begin initialize:  $\mathbf{a}, b, \eta_0, k=0$ 
2    do  $k \leftarrow k+1$ 
3       $Y_k = \{\}$ ,  $j = 0$ 
4      do  $j \leftarrow j + 1$ 
5        if  $\mathbf{a}_k^T \mathbf{y}^j \leq b$ , then append  $\mathbf{y}^j$  to  $Y_k$  //如果小于margin
6      until  $j = n$ 
7       $\mathbf{a}_{k+1} = \mathbf{a}_k - \eta_k \sum_{\mathbf{y} \in Y_k} ((\mathbf{a}^T \mathbf{y} - b) / \|\mathbf{y}\|^2) \mathbf{y}$ 
8    until  $Y_k = \{\}$ 
9    return  $\mathbf{a}$ 
10 end
```

5.5 松弛方法

- 单样本松弛算法

Single Sample Relaxation with Margin

```
1  begin initialize:  $\mathbf{a}$ , margin  $b$ ,  $\eta$ ,  $k=0$ 
2      do  $k \leftarrow k+1 \pmod n$ 
3          if  $\mathbf{a}^T \mathbf{y}^k \leq b$ , then  $\mathbf{a} = \mathbf{a} - \left( \eta (\mathbf{a}^T \mathbf{y}^k - b) / \|\mathbf{y}^k\|^2 \right) \cdot \mathbf{y}^k$ 
4      until  $\mathbf{a}^T \mathbf{y}^k > b$  for all  $\mathbf{y}^k$ 
5      return  $\mathbf{a}$ 
6  end
```

5.5 松弛方法

- 几何解释

点 $\mathbf{a}_k$ 到超平面 $\mathbf{a}^T \mathbf{y}^k = b$ 的距离:

$$r_k = \frac{b - \mathbf{a}_k^T \mathbf{y}^k}{\|\mathbf{y}^k\|}$$


点 $\mathbf{a}_k$ 沿着单位向量方向 $\mathbf{y}^k / \|\mathbf{y}^k\|$ 移动其 ηr_k 倍的距离, 得到新的 $\mathbf{a}_{k+1}$ 。

根据更新准则, 有:

$$(\mathbf{a}_{k+1})^T \mathbf{y}^k - b = (1 - \eta) ((\mathbf{a}_k)^T \mathbf{y}^k - b)$$

(离超平面更近了)

$$\begin{aligned} \mathbf{a}_{k+1} &= \mathbf{a}_k - \eta \frac{\mathbf{a}_k^T \mathbf{y}^k - b}{\|\mathbf{y}^k\|^2} \mathbf{y}^k = \mathbf{a}_k - \eta \frac{\mathbf{a}_k^T \mathbf{y}^k - b}{\|\mathbf{y}^k\|} \frac{\mathbf{y}^k}{\|\mathbf{y}^k\|} \\ &= \mathbf{a}_k + \eta r_k \frac{\mathbf{y}^k}{\|\mathbf{y}^k\|} \end{aligned}$$



5.5 松弛方法

$$\begin{aligned}\mathbf{a}_{k+1} &= \mathbf{a}_k - \eta \frac{\mathbf{a}_k^T \mathbf{y}^k - b}{\|\mathbf{y}^k\|^2} \mathbf{y}^k = \mathbf{a}_k - \eta \frac{\mathbf{a}_k^T \mathbf{y}^k - b}{\|\mathbf{y}^k\|} \frac{\mathbf{y}^k}{\|\mathbf{y}^k\|} \\ &= \mathbf{a}_k + \eta r_k \frac{\mathbf{y}^k}{\|\mathbf{y}^k\|}\end{aligned}$$


• 几何解释

如果 $\eta = 1$, $\mathbf{a}_k$ 将直接移动到该超平面。由于 $\mathbf{y}^k$ 引起的压力 “ $\mathbf{a}^T \mathbf{y}^k < b$ ” 被释放, 所以称为松弛方法。

如果 $\eta < 1$, 仍有 $(\mathbf{a}_{k+1})^T \mathbf{y}^k < b$, 但 $\mathbf{a}_{k+1}$ 比 $\mathbf{a}_k$ 更好。因为 $\mathbf{a}_{k+1}$ 离超平面更近。此时, 称为软松弛。

如果 $\eta > 1$, $\mathbf{a}_{k+1}$ 将跨过超平面, 即 $(\mathbf{a}_{k+1})^T \mathbf{y}^k > b$ 。称为超松弛。

实际中取 $0 < \eta < 2$ 。



5.5 松弛方法

$$\mathbf{a}_{k+1} = \mathbf{a}_k - \eta_k \frac{\mathbf{a}_k^T \mathbf{y}^k - b}{\|\mathbf{y}^k\|^2} \mathbf{y}^k$$

- 收敛性—考虑单样本松弛法[略]

— 设 $\mathbf{a}$ 是一个解向量，因此对任意 $\mathbf{y}_i$ ，有 $\mathbf{a}^T \mathbf{y}_i > b$ ，于是：

$$\begin{aligned}\|\mathbf{a}_{k+1} - \mathbf{a}\|^2 &= \left\| \mathbf{a}_k - \eta_k \frac{\mathbf{a}_k^T \mathbf{y}^k - b}{\|\mathbf{y}^k\|^2} \mathbf{y}^k - \mathbf{a} \right\|^2 \\ &= \|\mathbf{a}_k - \mathbf{a}\|^2 - 2\eta \frac{b - \mathbf{a}_k^T \mathbf{y}^k}{\|\mathbf{y}^k\|^2} (\mathbf{a} - \mathbf{a}_k)^T \mathbf{y}^k + \eta^2 \frac{(b - \mathbf{a}_k^T \mathbf{y}^k)^2}{\|\mathbf{y}^k\|^2}\end{aligned}$$

$$(\mathbf{a} - \mathbf{a}_k)^T \mathbf{y}^k = \mathbf{a}^T \mathbf{y}^k - \mathbf{a}_k^T \mathbf{y}^k > b - \mathbf{a}_k^T \mathbf{y}^k$$

$$\Rightarrow \|\mathbf{a}_{k+1} - \mathbf{a}\|^2 < \|\mathbf{a}_k - \mathbf{a}\|^2 - \eta(2 - \eta) \frac{(b - \mathbf{a}_k^T \mathbf{y}^k)^2}{\|\mathbf{y}^k\|^2}$$

$$\Rightarrow \|\mathbf{a}_{k+1} - \mathbf{a}\|^2 < \|\mathbf{a}_k - \mathbf{a}\|^2 \quad (\text{由于 } 0 < \eta < 2)$$

证明不完整，详见教材

5.6 最小平方误差(MSE)准则函数

- 动机

- 对两类分问题，感知准则函数是寻找一个解向量 $\mathbf{a}$ ，对所有样本 $\mathbf{y}_i$ ，满足 $\mathbf{a}^T \mathbf{y}_i > 0, i=1,2,\dots,n$ 。或者说，求解一个不等式组，使满足 $\mathbf{a}^T \mathbf{y}_i > 0$ 的数目最大，从而错分样本最少。
- 现在将不等式改写为等式形式：

$$\mathbf{a}^T \mathbf{y}_i = b_i > 0$$

其中， b_i 是任意给定的正常数，通常取 $b_i = 1$ ，或者 $b_i = n_i / n$ 。其中， $n_i, i = 1 \text{ or } 2$ ，为属于第 i 类样本的总数，且 $n_1 + n_2 = n$ 。

5.6 MSE 准则函数

- 方法

- 可得一个线性方程组：

$$\begin{pmatrix} y_{10} & y_{11} & \cdots & y_{1d} \\ y_{20} & y_{21} & \cdots & y_{2d} \\ \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots \\ y_{n0} & y_{n1} & \cdots & y_{nd} \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ \vdots \\ a_d \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ \vdots \\ b_n \end{pmatrix} \quad \text{or} \quad \mathbf{Y}\mathbf{a} = \mathbf{b}$$

- 如果 $\mathbf{Y}$ 可逆，则 $\mathbf{a} = \mathbf{Y}^{-1}\mathbf{b}$
 - 但通常情形下， $n \gg d+1$ ，因此，考虑定义一个误差向量：
 $\mathbf{e} = \mathbf{Y}\mathbf{a} - \mathbf{b}$ ，并使误差向量最小

5.6 MSE 准则函数

- 平方误差准则函数： $J_s(\mathbf{a}) = \|\mathbf{e}\|^2 = \|\mathbf{Y}\mathbf{a} - \mathbf{b}\|^2 = \sum_{i=1}^n (\mathbf{a}^T \mathbf{y}_i - b_i)^2$

- 偏导数：
$$\frac{\partial J_s(\mathbf{a})}{\partial \mathbf{a}} = \sum_{i=1}^n 2(\mathbf{a}^T \mathbf{y}_i - b_i) \mathbf{y}_i = 2\mathbf{Y}^T (\mathbf{Y}\mathbf{a} - \mathbf{b})$$

- 令偏导数为零，得：

$$\mathbf{Y}^T \mathbf{Y} \mathbf{a} = \mathbf{Y}^T \mathbf{b}, \quad \Rightarrow \mathbf{a} = (\mathbf{Y}^T \mathbf{Y})^{-1} \mathbf{Y}^T \mathbf{b} = \mathbf{Y}^+ \mathbf{b}$$

其中， $\mathbf{Y}^+$ 为 $\mathbf{Y}$ 的伪逆

- 实际计算（正则化技术）：
$$\mathbf{Y}^+ \approx (\mathbf{Y}^T \mathbf{Y} + \varepsilon \mathbf{I})^{-1} \mathbf{Y}^T \Big|_{\varepsilon \rightarrow 0}$$

（即回归分析方法）

5.6 MSE 准则函数

- 梯度下降法

- 计算伪逆需要求矩阵的逆，计算复杂度高。如果原始样本的维数很高，比如 $d > 5000$ ，将十分耗时。
- 批处理梯度下降：

$$\mathbf{a}_{k+1} = \mathbf{a}_k + \eta_k \mathbf{Y}^T (\mathbf{b} - \mathbf{Y} \mathbf{a}_k)$$

- 梯度下降法得到的 $\mathbf{a}_{k+1}$ 将收敛于一个解，该解满足方程：

$$\mathbf{Y}^T (\mathbf{b} - \mathbf{Y} \mathbf{a}) = 0$$

- 单样本梯度下降：此方法需要的计算存储量会更小

$$\mathbf{a}_{k+1} = \mathbf{a}_k + \eta_k (b_k - (\mathbf{a}_k)^T \mathbf{y}^k) \mathbf{y}^k$$

（此时考虑单个样本对误差的贡献）

5.6 MSE 准则函数

- Widrow-Hoff方法（单样本最小平方更新方法）

Widrow-Hoff (Least mean squared) Approach

```
1  begin initialize:  $\mathbf{a}$ ,  $\mathbf{b}$ ,  $\eta$ , threshold  $\theta$ ,  $k=0$ 
2    do  $k \leftarrow k+1 \pmod{n}$ 
3       $\mathbf{a} = \mathbf{a} + \eta_k (b_k - (\mathbf{a}_k)^T \mathbf{y}^k) \mathbf{y}^k$ 
4    until  $\| (b_k - (\mathbf{a}_k)^T \mathbf{y}^k) \mathbf{y}^k \| < \theta$ 
5    return  $\mathbf{a}$ 
6  end
```

注： $\mathbf{y}^k$ 为使 $(\mathbf{a}_k)^T \mathbf{y}^k \neq b_k$ 的样本，因为相等时对更新无贡献


5.6 MSE 准则函数

- Widrow-Hoff方法 vs 松弛算法

- 松弛准则要求 $\mathbf{a}^T \mathbf{y}^k > b$ for all $\mathbf{y}^k$ 。
- Widrow-Hoff 要求更正不相等情形: $(\mathbf{a}_k)^T \mathbf{y}^k \neq b_k$ 。但是，**实际上，满足 $(\mathbf{a}_k)^T \mathbf{y}^k = b_k$ 几乎是不可能的**。因此，迭代将会无穷次进行下去。所以要求 η_k 需要随着 k 的增加而逐渐减小，以保证算法的收敛性。一般来讲，实际计算中取: $\eta_k = \eta_1 / k$ 。

5.6 MSE 准则函数

- **Widrow-Hoff方法 vs 感知器准则**
 - 相对于感知器准则，**最小平方准则方法可能并不收敛于可分超平面**，即使该平面是存在的。
 - MSE方法的本质是最小化样本至超平面的距离的平方和。



5.7 Ho-Kashyap 方法

- Ho-Kashyap 方法

- MSE算法上最小化 $\|\mathbf{Y}\mathbf{a}-\mathbf{b}\|^2$ ，所得到的最优解并不需要位于可分超平面上。
- 如果训练样本是线性可分的，则可找到一个权向量 $\mathbf{a}$ ，对所有样本，均有 $\mathbf{a}^T \mathbf{y}_i > 0$ 。换句话说，一定存在 $\mathbf{a}$ 和 $\mathbf{b}$ ，使

$$\mathbf{Y}\mathbf{a} = \mathbf{b} > 0$$

- 但是，事先并不知道 $\mathbf{b}$ 。因此，MSE准则函数可以更新为：

$$J_s(\mathbf{a}, \mathbf{b}) = \|\mathbf{Y}\mathbf{a}-\mathbf{b}\|^2$$

注：直接优化 $J_s(\mathbf{a}, \mathbf{b})$ 将导致平凡解，所以需要给 $\mathbf{b}$ 加一个 $\mathbf{b}>0$ 的约束条件。此时， $\mathbf{b}$ 可以解释为margin。

5.7 Ho-Kashyap 方法

- 梯度下降法

- 梯度

$$\frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{a}} = 2\mathbf{Y}^T(\mathbf{Y}\mathbf{a} - \mathbf{b}), \quad \frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{b}} = -2(\mathbf{Y}\mathbf{a} - \mathbf{b})$$

对 $\mathbf{a}$ ，总有 $\mathbf{a} = \mathbf{Y}^+\mathbf{b}$ ，其中 $\mathbf{Y}^+$ 为 $\mathbf{Y}$ 的伪逆。

对 $\mathbf{b}$ ，需要同时满足约束条件 $\mathbf{b} > \mathbf{0}$ 。梯度更新：

$$\mathbf{b}_{k+1} = \mathbf{b}_k - \eta_k \frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{b}}$$

由于 $\mathbf{b}_k$ 总是大于零，要使 $\mathbf{b}_{k+1}$ 也大于零，可以要求 $\partial J_s(\mathbf{a}, \mathbf{b}) / \partial \mathbf{b} \leq \mathbf{0}$ 。

• 梯度下降法

– $\mathbf{b}$ 的梯度下降:

$$\mathbf{b}_1 > \mathbf{0}, \quad \mathbf{b}_{k+1} = \mathbf{b}_k - \eta_k \left(\frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{b}} - \left| \frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{b}} \right| \right) \quad (\leq 0)$$

元素取绝对值

– 更新 $\mathbf{a}$ 和 $\mathbf{b}$:

$$\mathbf{a}_{k+1} = \mathbf{Y}^+ \mathbf{b}_k$$

$$\mathbf{b}_1 > \mathbf{0}, \quad \mathbf{b}_{k+1} = \mathbf{b}_k + 2\eta_k \mathbf{e}_k^+$$

$$\text{其中, } \mathbf{e}_k^+ = \frac{1}{2} \left((\mathbf{Y} \mathbf{a}_k - \mathbf{b}_k) + |\mathbf{Y} \mathbf{a}_k - \mathbf{b}_k| \right), \quad \because \frac{\partial J_s(\mathbf{a}, \mathbf{b})}{\partial \mathbf{b}} = -2(\mathbf{Y} \mathbf{a} - \mathbf{b})$$

为了防止 $\mathbf{b}$ 收敛于 $\mathbf{0}$, 可以让 $\mathbf{b}$ 从一个非负向量 ($\mathbf{b}_1 > \mathbf{0}$) 开始进行更新。

由于要求 $\partial J_s(\mathbf{a}, \mathbf{b}) / \partial \mathbf{b}$ 等于 $\mathbf{0}$, 在开始迭代时可令 $\partial J_s(\mathbf{a}, \mathbf{b}) / \partial \mathbf{b}$ 的元素为正的分量等于零, 从而加快收敛速度。

5.7 Ho-Kashyap 方法

Ho-Kashyap Algorithm

```
1  begin initialize:  $\mathbf{a}$ ,  $\mathbf{b} > \mathbf{0}$ ,  $\eta_0 < 1$ ,  $k=0$ , threshold  $b_{\min}$ ,  $k_{\max}$ 
2    do  $k \leftarrow k+1 \pmod n$ 
3       $\mathbf{e} \leftarrow \mathbf{Y}\mathbf{a} - \mathbf{b}$ 
4       $\mathbf{e}^+ \leftarrow 1/2(\mathbf{e} + \text{abs}(\mathbf{e}))$ 
5       $\mathbf{b} \leftarrow \mathbf{b} + 2\eta_k \mathbf{e}^+$ 
6       $\mathbf{a} = \mathbf{Y}^+\mathbf{b}$ 
7      if  $\text{abs}(\mathbf{e}) \leq b_{\min}$ , then return  $\mathbf{a}$ ,  $\mathbf{b}$  and exit
8    until  $k = k_{\max}$ 
9    print “No solution found!”
10 end
```

5.7 Ho-Kashyap 方法

- Ho-Kashyap算法
 - 由于权向量序列 $\{\mathbf{a}_k\}$ 完全取决于 $\{\mathbf{b}_k\}$ ，因此本质上讲 Ho-Kashyap 算法是一个生成margin 序列 $\{\mathbf{b}_k\}$ 的方法。
 - 由于初始 $\mathbf{b}_1 > 0$ ，且更新因子 $\eta > 0$ ，因此 $\mathbf{b}_k$ 总是大于0。
 - 对于更新因子 $0 < \eta \leq 1$ ，如果问题线性可分，则总能找到元素全为正的 $\mathbf{b}$ 。
 - 如果 $\mathbf{e}_k = \mathbf{Y}\mathbf{a}_k - \mathbf{b}_k$ 全为 0，此时， $\mathbf{b}_k$ 将不再更新，因此获得一个解。如果 $\mathbf{e}_k$ 有一部分元素小于0，则可以证明该问题不是线性可分的*。


*证明见：Richard O. Duda, Peter E. Hart, David G. Stork, Pattern Classification, 2nd Edition, John Wiley, 2001. page: 251-253

5.8 逻辑回归(Logistic Regression)

- Logistic Regression

- Sigmoid函数

$$\sigma(z) = \frac{\exp(z)}{1 + \exp(z)} = \frac{1}{1 + \exp(-z)}$$



- LR模型：通过Sigmoid函数将线性判别函数的输出转化为类后验概率

$$P(\omega_1 | \mathbf{y}) = \sigma(\mathbf{a}^T \mathbf{y}) = \frac{\exp(\mathbf{a}^T \mathbf{y})}{1 + \exp(\mathbf{a}^T \mathbf{y})}$$

$$P(\omega_2 | \mathbf{y}) = 1 - P(\omega_1 | \mathbf{y}) = \frac{1}{1 + \exp(\mathbf{a}^T \mathbf{y})}$$

(只做增广，不做规范化)

5.8 逻辑回归(Logistic Regression)

- Logistic Regression
 - LR模型：将判别函数的输出转化成类后验概率

$$P(\omega_1 | \mathbf{y}) = \sigma(\mathbf{a}^T \mathbf{y}) = \frac{\exp(\mathbf{a}^T \mathbf{y})}{1 + \exp(\mathbf{a}^T \mathbf{y})}$$

$$P(\omega_2 | \mathbf{y}) = 1 - P(\omega_1 | \mathbf{y}) = \frac{1}{1 + \exp(\mathbf{a}^T \mathbf{y})}$$

-
- 几率(odds): $P/(1-P)$, 即成功的概率/失败的概率
 - 对数几率(log odds or logit): $\log P/(1-P)$
 - 对于Logistic regression:

$$\log \frac{P(\omega_1 | \mathbf{y})}{P(\omega_2 | \mathbf{y})} = \log \frac{\exp(\mathbf{a}^T \mathbf{y})}{1} = \mathbf{a}^T \mathbf{y}$$

判别函数的输出是 $\mathbf{y}$ 属于 ω_1 类的对数几率

5.8 逻辑回归(Logistic Regression)

- Logistic Regression的参数估计

- 对数似然函数 $L(\mathbf{a})$

$$\begin{aligned} L(\mathbf{a}) &= \sum_{\mathbf{y}_i \in \omega_1} \log P(\omega_1 | \mathbf{y}_i) + \sum_{\mathbf{y}_i \in \omega_2} \log P(\omega_2 | \mathbf{y}_i) \\ &= \sum_{\mathbf{y}_i \in \omega_1} \log \frac{\exp(\mathbf{a}^T \mathbf{y}_i)}{1 + \exp(\mathbf{a}^T \mathbf{y}_i)} + \sum_{\mathbf{y}_i \in \omega_2} \log \frac{1}{1 + \exp(\mathbf{a}^T \mathbf{y}_i)} \\ &= \sum_{\mathbf{y}_i \in \omega_1} \mathbf{a}^T \mathbf{y}_i - \sum_{i=1}^n \log(1 + \exp(\mathbf{a}^T \mathbf{y}_i)) \end{aligned}$$

- 使用梯度上升算法最大化 $L(\mathbf{a})$ ，得到 $\mathbf{a}$ 的估计

5.8 多类线性判别函数

- 对 c 类分类的学习问题

- One-vs-all方法

- 设 $g_i(\mathbf{x})$, $i=1,2,\dots,c$, 表示每个类别对应的判别函数

- 决策准则:

- 如果 $g_i(\mathbf{x}) \geq g_j(\mathbf{x})$, $\forall j \neq i$, 则 $\mathbf{x}$ 被分为 ω_i 类

- 对于线性判别函数

- 如果 $\mathbf{a}_i^T \mathbf{x} + \mathbf{b}_i \geq \mathbf{a}_j^T \mathbf{x} + \mathbf{b}_j$, $\forall j \neq i$, 则 $\mathbf{x}$ 被分为 ω_i 类

- 方法一：MSE多类扩展

- 可以直接采用 c 个两类分类器的组合，且这种组合具有与两类分类问题类似的代数描述形式
- 线性变换(注，此处不采用规范化增广表示):

$$\mathbf{z} = \mathbf{W}^T \mathbf{x} + \mathbf{b}, \quad \mathbf{W} \in R^{d \times c}, \mathbf{b} \in R^c$$

- 决策准则： if $i = \arg \max (\mathbf{W}^T \mathbf{x} + \mathbf{b})$, then $\mathbf{x} \in \omega_i$
- 回归值的构造： one-hot编码

$$\mathbf{x} \in \omega_j \Rightarrow \mathbf{z} \in R^c, \mathbf{z}_i = \begin{cases} 1, & \text{if } i = j \\ 0, & \text{otherwise} \end{cases}$$

若 $\mathbf{x}$ 属于 ω_j 类，则 $\mathbf{x}$ 的类别编码 $\mathbf{z}$ 为一个 c 维向量，其中第 j 个元素为1，其余为0

• 方法一：MSE多类扩展

— 目标函数：

$$\min_{\mathbf{W}, \mathbf{b}} \sum_{i=1}^n \left\| \mathbf{W}^T \mathbf{x}_i + \mathbf{b} - \mathbf{z}_i \right\|_2^2$$

令： $\hat{\mathbf{W}} = \begin{pmatrix} \mathbf{W} \\ \mathbf{b}^T \end{pmatrix} \in R^{(d+1) \times c}$, $\hat{\mathbf{x}} = \begin{pmatrix} \mathbf{x} \\ 1 \end{pmatrix} \in R^{d+1}$, $\hat{\mathbf{X}} = (\hat{\mathbf{x}}_1, \hat{\mathbf{x}}_2, \dots, \hat{\mathbf{x}}_n) \in R^{(d+1) \times n}$



$$\sum_{i=1}^n \left\| \mathbf{W}^T \mathbf{x}_i + \mathbf{b} - \mathbf{z}_i \right\|_2^2 = \left\| \hat{\mathbf{W}}^T \hat{\mathbf{X}} - \mathbf{Z} \right\|_F^2, \quad \mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_n] \in R^{c \times n}$$



$$\min_{\hat{\mathbf{W}}} \left\| \hat{\mathbf{W}}^T \hat{\mathbf{X}} - \mathbf{Z} \right\|_F^2 \quad (\|\cdot\|_F \text{ 为 Frobenius 范数})$$



$$\hat{\mathbf{W}} = (\hat{\mathbf{X}} \hat{\mathbf{X}}^T)^{-1} \hat{\mathbf{X}} \mathbf{Z}^T \in R^{(d+1) \times c} \quad \hat{\mathbf{W}} = (\hat{\mathbf{X}} \hat{\mathbf{X}}^T + \lambda \mathbf{I})^{-1} \hat{\mathbf{X}} \mathbf{Z}^T \in R^{(d+1) \times c}$$

λ : 一个小正数

- **方法二：感知器准则扩展方法—逐步修正(不讲-自学)**

- **目标：一次性学习出 c 个权重向量**（以下采用规范化增广样本表示）

- S_1 : 设置任意的初始权重向量 $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_c$

- S_2 : 考察某个属于第 i 类的样本 $\mathbf{y}^k$:

- 如果 $(\mathbf{a}_i)^T \mathbf{y}^k > (\mathbf{a}_j)^T \mathbf{y}^k$ ，对任意 $j \neq i$ 均成立，则所有权向量不变；
- 如果存在 j 使 $(\mathbf{a}_i)^T \mathbf{y}^k \leq (\mathbf{a}_j)^T \mathbf{y}^k$ ，则可以选择一个 j （比如使 $(\mathbf{a}_j)^T \mathbf{y}^k$ 最大者），对权值分量进行修正：

$$\left\{ \begin{array}{l} \mathbf{a}_i(k+1) = \mathbf{a}_i(k) + \eta_k \mathbf{y}^k \\ \mathbf{a}_j(k+1) = \mathbf{a}_j(k) - \eta_k \mathbf{y}^k \\ \mathbf{a}_m(k+1) = \mathbf{a}_m(k), \quad m \neq i, j \end{array} \right\} \text{ 相当于将样本 } [(\mathbf{y}^k)^T, (-\mathbf{y}^k)^T] \text{ 错分}$$

- S_3 : 如果对所有样本均正确分类，则停止；否则考察另一个样本。

- 方法三：Kelser 构造（注：此处采用齐次增广样本表示）（不讲-自学）

- 设计一个两类分类线性分类器

- (1) 将 $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_c$ 拼接成一个长向量

$$\mathbf{a} = \begin{pmatrix} \mathbf{a}_1 \\ \mathbf{a}_2 \\ \vdots \\ \mathbf{a}_c \end{pmatrix} \in R^{c(d+1)}$$

- (2) 对每个训练样本 $\mathbf{y}$ ，构造 $c-1$ 的新样本

- 比如：若样本 $\mathbf{y}$ 属于第一类，则构造如下 $c-1$ 个新样本：

$$\boldsymbol{\eta}_{12} = \begin{pmatrix} \mathbf{y} \\ -\mathbf{y} \\ \mathbf{0} \\ \vdots \\ \mathbf{0} \end{pmatrix}, \quad \boldsymbol{\eta}_{13} = \begin{pmatrix} \mathbf{y} \\ \mathbf{0} \\ -\mathbf{y} \\ \vdots \\ \mathbf{0} \end{pmatrix}, \quad \dots, \quad \boldsymbol{\eta}_{1c} = \begin{pmatrix} \mathbf{y} \\ \mathbf{0} \\ \mathbf{0} \\ \vdots \\ -\mathbf{y} \end{pmatrix} \quad \boldsymbol{\eta}_{1j} \in R^{c(d+1)}$$

- 方法三：Kelser 构造(不讲-自学)

- (接上页) 若样本 $\mathbf{y}$ 属于第一类，则构造如下 $c-1$ 个新样本：

$$\boldsymbol{\eta}_{12} = \begin{pmatrix} \mathbf{y} \\ -\mathbf{y} \\ \mathbf{0} \\ \vdots \\ \mathbf{0} \end{pmatrix}, \quad \boldsymbol{\eta}_{13} = \begin{pmatrix} \mathbf{y} \\ \mathbf{0} \\ -\mathbf{y} \\ \vdots \\ \mathbf{0} \end{pmatrix}, \quad \dots, \quad \boldsymbol{\eta}_{1c} = \begin{pmatrix} \mathbf{y} \\ \mathbf{0} \\ \mathbf{0} \\ \vdots \\ -\mathbf{y} \end{pmatrix}$$

- 若要正确分类，则应当有：

$$\begin{array}{ccc} \mathbf{a}_1^T \mathbf{y} > \mathbf{a}_2^T \mathbf{y} & \mathbf{a}_1^T \mathbf{y} > \mathbf{a}_3^T \mathbf{y} & \mathbf{a}_1^T \mathbf{y} > \mathbf{a}_c^T \mathbf{y} \\ \updownarrow & \updownarrow & \updownarrow \\ \mathbf{a}^T \boldsymbol{\eta}_{12} > 0 & \mathbf{a}^T \boldsymbol{\eta}_{12} > 0 & \mathbf{a}^T \boldsymbol{\eta}_{12} > 0 \end{array}$$

- 方法三：Kelser 构造(不讲-自学)

- 一般地，若样本 $\mathbf{y}$ 属于第 i 类，构造如下 $c-1$ 个新样本：

$$\boldsymbol{\eta}_{ij} = \begin{pmatrix} \vdots \\ \mathbf{y} \\ \vdots \\ -\mathbf{y} \\ \vdots \end{pmatrix} \quad \begin{matrix} \leftarrow i \\ \leftarrow j \end{matrix} \quad \boldsymbol{\eta}_{ij} \in R^{c(d+1)}$$

- 若要对样本 $\mathbf{y}$ 正确分类，则应当有：

$$\mathbf{a}_i^T \mathbf{y} > \mathbf{a}_j^T \mathbf{y} \Leftrightarrow \mathbf{a}^T \boldsymbol{\eta}_{ij} > 0, \quad j \neq i$$

- **方法三：Kelser 构造(不讲-自学)**

- 优点：

- 可以将一个多类问题转化为一个两类分类问题，便于采用现有的两类分类器构造方法
 - 由此获得的一个多类线性分类器可以保证不会出现歧义区域。


- 缺点：

- 增加了样本的规模，增大了样本空间的维数，对大数据处理极度不利。

方法四：多类Logistic Regression

- Softmax function

- The softmax function takes as input a vector $\mathbf{z}$ of c real numbers, and normalizes it into a probability distribution



$$\text{softmax}(\mathbf{z})_i = \frac{\exp(z_i)}{\sum_{j=1}^c \exp(z_j)}$$

$$\mathbf{z} = (z_1, z_2, \dots, z_c) \in R^c$$

- Multinomial logistic regression

$$P(\omega_i | \mathbf{y}) = \frac{\exp(\mathbf{a}_i^T \mathbf{y})}{\sum_{j=1}^c \exp(\mathbf{a}_j^T \mathbf{y})}$$

$$i = 1, 2, \dots, c$$

(只做增广，不做规范化)

- 通过极大似然法估计参数

5.9 本章小结

- 概念

- 判别函数、线性判别函数、广义线性判别函数、可分性、分界面、决策规则、点到超平面的距离、规范化增广样本表示、多类分类


- 线性判别函数

- 感知准则函数、松弛感知准则函数、平方误差准则函数

- 算法

- 感知准则函数的批量更新方法、感知准则函数的单样本更新方法、松弛感知准则函数单样本更新方法、MSE梯度下降法、Ho-Kashyap方法、多类扩展方法

5.9 本章小结



下次课内容

- 神经网络基础
 - 发展历史
 - 网络结构
- 基本模型
 - 单层感知器、多层感知器、反向传播算法等

致谢

- PPT由向世明老师提供

Thank All of You!
(Questions?)

张燕明

ymzhang@nlpr.ia.ac.cn

people.ucas.ac.cn/~ymzhang

模式分析与学习课题组(PAL)

中科院自动化研究所·多模态人工智能系统实验室