

第3章

概率密度估计—参数法(第1讲)

Estimation on PDF: Parameter Estimation

张 燕 明

ymzhang@nlpr.ia.ac.cn

peopleucas.ac.cn/~ymzhang

模式分析与学习课题组(PAL)

多模态人工智能系统实验室 中科院自动化所

助教: 杨 奇 (yangqi2021@ia.ac.cn)

张 涛 (zhangtao2021@ia.ac.cn)

课程简介

第一章 绪论 3学时 向世明

第二章 贝叶斯决策理论 3学时 向世明

第三章 概率密度函数估计 6学时 张燕明

第四章 非参数法 3学时 张燕明

第五章 线性分类器设计 3学时 张燕明

第六章 神经网络和深度学习 9学时 张燕明

第七章 特征提取与选择 6学时 张燕明

第八章 模型选择 3学时 张燕明

第九章 聚类分析 6学时 张燕明

第十章 支持向量机与核方法 6学时 向世明

第十一章 决策树方法 3学时 向世明

第十二章 模式识别前沿趋势 3学时 向世明

课程简介

- 教材

- 李航 《统计学习方法》
- 周志华 《机器学习》
- R. O. Duda, etc. 《Pattern Classification》
- C. M. Bishop 《Pattern Recognition and Machine Learning》
- C. M. Bishop and H. Bishop 《Deep Learning》

- 作业

- 6次作业，须在作业发布后两周内提交，占总成绩30%

- 考试

- 1次期末考试，闭卷，占总成绩70%

内容提要

- 上讲内容回顾
- 参数估计的基本概念
- 最大似然估计
- 贝叶斯估计
 - 正态分布下的贝叶斯估计
 - 贝叶斯学习
 - 贝叶斯估计：一个例子
- 特征维数问题

上次课主要内容回顾

- 贝叶斯决策

- 已知类条件概率密度 $p(\mathbf{x}|\omega_i)$ 和类先验分布 $P(\omega_i)$ ，计算样本 $\mathbf{x}$ 的类后验分布

$$P(\omega_i | \mathbf{x}) = \frac{p(\omega_i, \mathbf{x})}{p(\mathbf{x})} = \frac{p(\mathbf{x} | \omega_i)P(\omega_i)}{p(\mathbf{x})}$$

- 得到类后验概率，如何对 $\mathbf{x}$ 分类？

上次课主要内容回顾

- 贝叶斯决策

- 决策损失: $\lambda \in R^{c \times c}$, $\lambda_{ij} = \lambda(\alpha_i | \omega_j)$ 把 j 类样本决策为 i 类的损失
- 条件风险: $R(\alpha_i | \mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(\omega_j | \mathbf{x})$ 把样本 $\mathbf{x}$ 决策为 i 类的期望损失
- 最小风险决策:

$$\arg \min_i R(\alpha_i | \mathbf{x})$$

- 最小分类错误率决策:

$$\lambda(\alpha_i | \omega_j) = \begin{cases} 0, & \alpha_i = \omega_j \\ 1, & \alpha_i \neq \omega_j \end{cases}$$

$$\arg \min_i R(\alpha_i | \mathbf{x}) = \arg \min_i 1 - P(\omega_i | \mathbf{x}) = \arg \max_i P(\omega_i | \mathbf{x})$$

最大后验概率决策

最小分类错误率 $R^* = \int (1 - \max_i P(\omega_i | \mathbf{x})) p(\mathbf{x}) d\mathbf{x}$

对给定的特征空间，最小分类错误率是确定的；要减小分类错误率，只能改进特征空间。

上次课主要内容回顾

- 贝叶斯决策

- 决策损失: $\lambda \in R^{c \times c}$, $\lambda_{ij} = \lambda(\alpha_i | \omega_j)$ 把 j 类样本决策为 i 类的损失
- 条件风险: $R(\alpha_i | \mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(\omega_j | \mathbf{x})$ 把样本 $\mathbf{x}$ 决策为 i 类的期望损失
- 最小风险决策:

$$\arg \min_i R(\alpha_i | \mathbf{x})$$

- 最小分类错误率决策:

$$\lambda(\alpha_i | \omega_j) = \begin{cases} 0, & \alpha_i = \omega_j \\ 1, & \alpha_i \neq \omega_j \end{cases}$$

$$\arg \max_i R(\alpha_i | \mathbf{x}) = \arg \max_i P(\omega_i | \mathbf{x}) \quad \text{最大后验概率决策}$$

- Reject recognition

$$\lambda(\alpha_i | \omega_j) = \begin{cases} 0, & \alpha_i = \omega_j \\ \lambda_s, & \alpha_i \neq \omega_j \\ \lambda_r, & \text{reject} \end{cases} \quad (\lambda_r < \lambda_s)$$
$$\arg \min_i R_i(\mathbf{x}) = \begin{cases} \arg \max_i P(\omega_i | \mathbf{x}), & \max_i P(\omega_i | \mathbf{x}) > 1 - \lambda_r / \lambda_s \\ \text{reject}, & \text{otherwise} \end{cases}$$

上次课主要内容回顾

- 判别函数(Discriminant Function)

- 表征样本 $\mathbf{x}$ 属于某一类的广义似然度:

$$g_i(\mathbf{x}) \quad i = 1, \dots, c$$

- 多种形式:

$$g_i(\mathbf{x}) = -R(\alpha_i | \mathbf{x})$$


$$g_i(\mathbf{x}) = P(\omega_i | \mathbf{x})$$

$$g_i(\mathbf{x}) = p(\mathbf{x} | \omega_i)P(\omega_i)$$

$$g_i(\mathbf{x}) = \log p(\mathbf{x} | \omega_i) + \log P(\omega_i)$$

- 已知类判别函数后的分类准则:

$$\arg \max_i g_i(\mathbf{x})$$




上次课主要内容回顾

- 决策面(Decision Boundary)

- 特征空间中二类判别函数相等的点的集合

令 $g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x})$, 决策面由所有满足 $g(\mathbf{x}) = 0$ 的 $\mathbf{x}$ 组成



正态分布下的一个例子

$$g_i(\mathbf{x}) = p(\mathbf{x} | \omega_i)P(\omega_i)$$

2维特征空间

上次课主要内容回顾


- 高斯分布（正态分布）
 - 1D、多维（记住了？）
 - 协方差矩阵的性质
 - 等密度点轨迹、马氏距离
 - 线性变换的高斯密度
- 高斯分布下的判别函数
 - Linear discriminant function (LDF): $\Sigma_i = \Sigma_j$
 - Quadratic discriminant function (QDF): $\Sigma_i \neq \Sigma_j$

2.7 离散变量贝叶斯决策


- 离散特征变量

- 例如：性别、民族、选择题...

- 概率分布函数 $P(\mathbf{x} | \omega_i) = P(x_1, x_2, \dots, x_d | \omega_i)$



一维分布（血型）



二维离散分布

参数个数随维度 d
指数增长： $O(K^d)$

- 特征独立假设（朴素贝叶斯，Naïve Bayes）

$$P(\mathbf{x} | \omega_i) = P(x_1, x_2, \dots, x_d | \omega_i) = \prod_{j=1}^d P(x_j | \omega_i)$$

- 独立二值特征 (Binary features)
 - d 维特征空间中的两类数据
 - 假设每维特征服从伯努利分布 (0/1分布)，特征之间相互独立
 - 类条件概率分布：

$$p_i = P(x_i=1|\omega_1) \quad i=1,\dots,d$$

$$P(\mathbf{x}|\omega_1) = \prod_{i=1}^d p_i^{x_i} (1 - p_i)^{1-x_i}$$

ω_1 类

$$q_i = P(x_i=1|\omega_2) \quad i=1,\dots,d$$

$$P(\mathbf{x}|\omega_2) = \prod_{i=1}^d q_i^{x_i} (1 - q_i)^{1-x_i}$$

ω_2 类

- 独立二值特征 (Binary features)

- Discriminant/decision function

$$\begin{aligned} g(\mathbf{x}) &\equiv g_1(\mathbf{x}) - g_2(\mathbf{x}) = \ln P(\mathbf{x} | \omega_1) P(\omega_1) - \ln P(\mathbf{x} | \omega_2) P(\omega_2) \\ &= \sum_{i=1}^d \left[x_i \ln \frac{p_i}{q_i} + (1 - x_i) \ln \frac{1 - p_i}{1 - q_i} \right] + \ln \frac{P(\omega_1)}{P(\omega_2)} \\ &= \sum_{i=1}^d \ln \frac{p_i}{q_i} \frac{1 - q_i}{1 - p_i} x_i + \sum_{i=1}^d \ln \frac{1 - p_i}{1 - q_i} + \ln \frac{P(\omega_1)}{P(\omega_2)} \end{aligned}$$

- $g(\mathbf{x})$ 为线性判别函数

$$g(\mathbf{x}) = \sum_{i=1}^d w_i x_i + w_0 \quad w_i \text{ 为每个特征的权重}$$

$$w_i = \ln \frac{p_i(1 - q_i)}{q_i(1 - p_i)} \quad i = 1, \dots, d \quad w_0 = \sum_{i=1}^d \ln \frac{1 - p_i}{1 - q_i} + \ln \frac{P(\omega_1)}{P(\omega_2)}$$

- 一个例子: 3D binary data

- $P(\omega_1)=0.5, P(\omega_2)=0.5$

- $p_i=0.8, q_i=0.5, \quad i=1,2,3$


$$P(\mathbf{x}|\omega_1) = \prod_{i=1}^d p_i^{x_i} (1 - p_i)^{1-x_i}$$

$$P(\mathbf{x}|\omega_2) = \prod_{i=1}^d q_i^{x_i} (1 - q_i)^{1-x_i}$$

$$g(\mathbf{x}) = \sum_{i=1}^d w_i x_i + w_0$$

$$w_i = \ln \frac{.8(1 - .5)}{.5(1 - .8)} = 1.3863$$

$$w_0 = \sum_{i=1}^3 \ln \frac{1 - .8}{1 - .5} + \ln \frac{.5}{.5} = -2.7489$$



2.8 复合模式分类

(Compound Bayesian Decision Theory and Context)

- 多个样本同时分类 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n]$ $\omega = \omega(1)\omega(2)\dots\omega(n)$

- 比如：字符串识别

tomorrow

- Bayesian decision

$$P(\omega|\mathbf{X}) = \frac{p(\mathbf{X}|\omega)P(\omega)}{p(\mathbf{X})} = \frac{p(\mathbf{X}|\omega)P(\omega)}{\sum_{\omega} p(\mathbf{X}|\omega)P(\omega)}$$

- 注意： ω 类别数巨大(c^n)， $p(\mathbf{X}|\omega)$ 与 $p(\omega)$ 存储和估计困难

- Conditionally independent

$$p(\mathbf{X}|\omega) = \prod_{i=1}^n p(\mathbf{x}_i|\omega(i))$$

已知类别的条件下，
样本之间相互独立

- Prior assumption

- Markov chain

$$P(\omega) = P[\omega(1), \omega(2), \dots, \omega(n)] = P[\omega(1)] \prod_{j=2}^n P[\omega(j)|\omega(j-1)]$$

- Hidden Markov model (Chapter 3)

与复合模式识别类似的问题：多分类器融合

- 有同一个分类问题的 K 个分类器，对于样本 $\mathbf{x}$ ，怎样使用 K 个分类结果得到最终分类结果？

- 一个分类器的输出：离散变量 $e_k \in \{\omega_1, \dots, \omega_c\}$
- 多个分类器的决策当作样本 $\mathbf{x}$ 的多维特征，用Bayes方法重新分类

$$P(\omega_i | e_1, \dots, e_K) = \frac{P(e_1, \dots, e_K | \omega_i) P(\omega_i)}{P(e_1, \dots, e_K)}, \quad i = 1, \dots, c$$

- 需要估计离散空间的类条件概率

$$P(e_1, \dots, e_K | \omega_i) \quad \text{指数级复杂度，需要大量样本}$$

- 特征独立假设（Naïve Bayes）

$$P(e_1, \dots, e_K | \omega_i) = \prod_{k=1}^K P(e_k | \omega_i)$$

2.9 模式分类与特征的关系

- 贝叶斯分类错误率

- 贝叶斯决策（0-1）损失：

$$\omega^* = \arg \max_i P(\omega_i | \mathbf{x}) \Rightarrow R^* = \int (1 - P(\omega^* | \mathbf{x})) p(\mathbf{x}) d\mathbf{x}$$

- 特征空间给定时，贝叶斯分类错误率就确定了，即分类精度的理论上限就确定了，这与分类器结构、学习算法无关

- 改进/增加特征的好处

- 只有改进特征或增加新特征才能改进贝叶斯分类错误率
 - 增加类别间的差异性有助于分类

- 可能带来的新问题

- 过拟合的风险
 - 计算、存储开销


2.9 模式分类与特征的关系

- 高斯分布（两类问题）：
 - $p(\mathbf{x}|\omega_j) \sim N(\boldsymbol{\mu}_j, \boldsymbol{\Sigma})$, $j=1,2$, 等协方差矩阵
 - Bayes error rate

$$\begin{aligned} P(\text{error}) &= P(\mathbf{x} \in R_2, \omega_1) + P(\mathbf{x} \in R_1, \omega_2) \\ &= \int_{R_2} p(\mathbf{x} | \omega_1) P(\omega_1) d\mathbf{x} + \int_{R_1} p(\mathbf{x} | \omega_2) P(\omega_2) d\mathbf{x} \\ &= P(\mathbf{x} \in R_2 | \omega_1) P(\omega_1) + P(\mathbf{x} \in R_1 | \omega_2) P(\omega_2) \end{aligned}$$



$$P(\text{error}) = \frac{1}{\sqrt{2\pi}} \int_{r/2}^{+\infty} e^{-\mu^2} d\mu, \quad r^2 = (\mathbf{u}_1 - \mathbf{u}_2)^T \boldsymbol{\Sigma}^{-1} (\mathbf{u}_1 - \mathbf{u}_2)$$



- 高斯分布（两类问题）：

- Conditionally independent case $\Sigma = \text{diag}(\sigma_1^2, \sigma_1^2, \dots, \sigma_d^2)$


- 每一维的二类均值之间距离反映区分度，从而决定错误率
 - 特征增加有助于减小错误率 (因为 r^2 增大)

$$r^2 = \sum_{i=1}^d \frac{(\mu_{i1} - \mu_{i2})^2}{\sigma_i^2}, \quad r^2 = (\mathbf{u}_1 - \mathbf{u}_2)^T \Sigma^{-1} (\mathbf{u}_1 - \mathbf{u}_2)$$

- 特征维数决定可分性的例子


- 3D空间完全可分
 - 2D和1D投影空间有重叠

然而，增加特征也可能导致分类性能更差，
因为有模型估计误差 (wrong model)



2.9 模式分类与特征的关系：过拟合

- 增加特征维数的风险：过拟合(overfitting)
 - 特征维数高、训练样本少导致模型参数估计不准确
 - 比如协方差矩阵需要样本数在 d 以上
- 过拟合的例子



$$f(x) = ax^2 + bx + c + \varepsilon, \quad \text{where } p(\varepsilon) = \mathcal{N}(0, \sigma^2)$$

完美拟合训练数据，但测试误差很大

2.9 特征维数问题：过拟合(Overfitting)

- 克服办法

- 特征降维：特征提取(变换)、特征选择

- 参数共享/平滑

- 方法一：共享协方差矩阵 Σ_0

- 方法二：Shrinkage (a.k.a. **Regularized Discriminant Analysis**):

第*i*类的协
方差矩阵：

$$\Sigma_i(\alpha) = \frac{(1-\alpha)n_i \Sigma_i + \alpha n \Sigma}{(1-\alpha)n_i + \alpha n},$$

(启发式方法)

$$\Sigma(\beta) = (1-\beta)\Sigma + \beta\mathbf{I}$$

用第*i*类数据

用所有数据

第2章小结

本章，我们探讨了在已知类条件概率密度 $p(\mathbf{x}|\omega_i)$ 和类先验分布 $P(\omega_i)$ 的情况下，如何基于贝叶斯决策理论对样本 $\mathbf{x}$ 分类的问题

- (1) 单模式分类：连续特征、离散特征
- (2) 复合模式分类
- (3) 多分类器融合
- (4) 模式分类与特征的关系

第3章

最大似然和贝叶斯参数估计

3.1 基本概念

- 贝叶斯分类器

- 已知类先验概率 $P(\omega_i)$ 和类条件概率密度 $p(\mathbf{x}|\omega_i)$ ，按**某决策规则**确定判别函数和决策面。
- 但类先验概率和类条件概率密度**在实际中往往是未知的**。因此，我们要换一种处理问题的方式：“**基于样本设计分类器**”。
- 根据设计方法，可以将分类器分为两类：
 - **产生式方法**：估计类先验概率和类条件概率密度函数
 - **判别式方法**：直接估计类后验概率或判别函数

3.1 基本概念

- 产生式方法的分类

- 参数估计：

- 样本所属的类条件概率密度函数的形式已知，而概率密度函数的参数是未知的；目标是由已知类别的样本集估计概率密度函数的参数
 - 例如，知道样本所属总体为正态分布，而正态分布的参数未知

$$p(x | \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2}\left(\frac{x - \mu}{\sigma}\right)^2\right)$$

- 非参数估计：

- 样本所属的类条件概率密度函数的形式和参数都是未知的，目标是由已知类别的样本集估计类条件概率密度函数本身。

3.1 基本概念

- 基本概念

- **统计量**：样本中包含总体的信息，我们希望通过样本集将有关信息估计出来。根据不同要求构造出有关样本的某种函数，在统计学中称为**统计量** $d(x_1, x_2, \dots, x_n)$ 。比如，

- 均值 $\mu = \frac{1}{n} \sum_{i=1}^n x_i$

- **参数空间**：将未知待估计参数记为 θ ，参数 θ 的**全部允许取值集合**构成参数空间，记为 Θ 。

3.1 基本概念

- 基本概念

- **点估计**：点估计问题就是构造一个统计量 $d(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$ 作为参数 θ 的估计 $\hat{\theta}$ 。比如，常用的均值估计：

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

- **区间估计**：与点估计不同，区间估计要求采用 (d_1, d_2) 作为参数 θ 可能取值范围的一种估计。这个区间称为**置信区间**。这类估计问题称为**区间估计**。

3.2 最大似然估计

- 基本假设

- 独立同分布(i.i.d.)假设：每类样本均是从类条件概率密度 $p(\mathbf{x}|\omega_i)$ 中独立采样出来的。
- $p(\mathbf{x}|\omega_i)$ 具有确定的函数形式，只是其中的参数 θ 未知：
 - 比如，当 $\mathbf{x}$ 服从一维正态分布 $N(\mu, \sigma^2)$ ，未知的参数为 $\theta = [\mu, \sigma]^T$ ，为一个二维向量。
- 各类样本只包含本类的分布信息：不同类别的条件概率密度函数的参数是独立的。可以分别处理 c 个独立问题。

3.2 最大似然估计

- 基本原理


- 已知随机抽取的 n 个样本(观测值)，最合理的参数估计是使得从该分布中能抽取这 n 个样本的概率最大。

- 直观想法

- 一个随机试验如有若干个可能的结果：A, B, C, ...。若仅作一次试验，结果A出现，则认为试验条件（分布的参数）对A出现有利，使A出现的概率很大。
 - 一般地，事件A发生的概率与参数 θ 相关，A发生的概率记为 $P(A|\theta)$ ，则 θ 的估计应该使上述概率达到最大，这样的 θ 顾名思义称为极大似然估计。

3.2 最大似然估计

- 例如：我们观察到10个一维空间中的样本。现假定其来自于4个高斯分布中的一个。哪一个最有可能？



- 基本原理

- 设样本集 D 包含 n 个样本 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ ，这些样本是从概率密度函数 $p(\mathbf{x}|\theta)$ 中独立抽取的，则获得 n 个样本的联合概率为：

$$l(\theta) = P(D | \theta) = P(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n | \theta) = \prod_{i=1}^n p(\mathbf{x}_i | \theta)$$

- $l(\theta)$ 是 θ 的函数，描述了在不同参数取值下取得当前样本集的可能性。
- $l(\theta)$ 被称为参数 θ 相对于样本集 D 的似然函数。
 - 似然函数给出了从总体中抽出 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 这 n 个样本的概率。

3.2 最大似然估计

- 方法描述

- 令 $l(\theta)$ 为样本集 D 的似然函数， $D=\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 。如果 $\hat{\theta}$ 是参数空间 Θ 中能使 $l(\theta)$ 极大化的 θ 值，那么 $\hat{\theta}$ 就是 θ 的最大似然估计量，即

$$\hat{\theta} = \arg \max_{\theta \in \Theta} l(\theta)$$

- 为计算方便，通常采用对数似然函数：

$$H(\theta) = \ln(l(\theta)) = \ln \prod_{i=1}^n p(\mathbf{x}_i | \theta) = \sum_{i=1}^n \ln(p(\mathbf{x}_i | \theta))$$

$$\arg \max_{\theta \in \Theta} l(\theta) = \arg \max_{\theta \in \Theta} H(\theta)$$

• 问题求解

$$H(\boldsymbol{\theta}) = \ln(l(\boldsymbol{\theta})) = \ln\left(\prod_{i=1}^n p(\mathbf{x}_i | \boldsymbol{\theta})\right) = \sum_{i=1}^n \ln(p(\mathbf{x}_i | \boldsymbol{\theta}))$$

$$\hat{\boldsymbol{\theta}} = \arg \max_{\boldsymbol{\theta} \in \Theta} l(\boldsymbol{\theta})$$

当 $l(\boldsymbol{\theta})$ 可微时:

$$\frac{\partial l(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = 0, \quad \text{or} \quad \frac{\partial H(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = 0$$

对于多维情形 $\boldsymbol{\theta} = [\theta_1, \theta_2, \dots, \theta_m]^T$, 梯度向量为零:

$$\nabla_{\boldsymbol{\theta}}(l(\boldsymbol{\theta})) = \frac{\partial l(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \left[\frac{\partial l(\boldsymbol{\theta})}{\partial \theta_1}, \frac{\partial l(\boldsymbol{\theta})}{\partial \theta_2}, \dots, \frac{\partial l(\boldsymbol{\theta})}{\partial \theta_m} \right]^T = \mathbf{0}$$

用梯度上升法迭代求解 $\boldsymbol{\theta}' = \boldsymbol{\theta} + \eta \frac{\partial l(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}}$

• 问题求解


$$H(\boldsymbol{\theta}) = \ln(l(\boldsymbol{\theta})) = \ln\left(\prod_{i=1}^n p(\mathbf{x}_i | \boldsymbol{\theta})\right) = \sum_{i=1}^n \ln(p(\mathbf{x}_i | \boldsymbol{\theta}))$$

$$\hat{\boldsymbol{\theta}} = \arg \max_{\boldsymbol{\theta} \in \Theta} l(\boldsymbol{\theta})$$

当 $l(\theta)$ 是可微凹函数时:

$$\arg \max l(\boldsymbol{\theta}) \Leftrightarrow \frac{\partial l(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = 0$$

梯度等于0是最优解的充要条件




当 $l(\theta)$ 是一般可微函数时:

$$\arg \max l(\boldsymbol{\theta}) \Rightarrow \frac{\partial l(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = 0$$

梯度等于0是最优解的必要条件

在高维空间中, 寻找全局最优解是极困难的, 通常满足于局部最优解。



3.2 最大似然估计

- 一个袋子里装有白球与黑球，但是不知道它们之间的比例。现有放回地抽取10次，结果获得8次黑球2次白球，估计袋子中的黑球的比例。
 - 最大似然估计法：设抽到黑球的概率为 p ，取到8次黑球2次白球的概率为： $l(p) = \binom{10}{8} p^8 (1-p)^2$
 - 计算 $l(p)$ 和 $H(p)$ 的最优解：

$$\frac{\partial l(p)}{\partial p} = \binom{10}{8} \frac{\partial p^8 (1-p)^2}{\partial p} = \binom{10}{8} (10p^9 - 18p^8 + 8p^7) = 0 \Rightarrow \hat{p} = 0.8$$

$$\frac{\partial \ln l(p)}{\partial p} = \frac{\partial \ln \binom{10}{8} + 8 \ln p + 2 \ln(1-p)}{\partial p} = \frac{8}{p} - \frac{2}{1-p} = 0 \Rightarrow \hat{p} = 0.8$$

• 例子2：高斯分布下的最大似然估计

- 将在下面的推导中用到如下几个公式（见清华大学张贤达老师著的《矩阵分析与应用》第五章：“梯度分析应用”）：

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^d A_{ii}, \quad \text{where } \mathbf{A} = (A_{ij}) \in R^{d \times d}$$

$$s = \text{tr}(s), \quad \text{if } s \text{ is a scalar} \quad \Rightarrow \quad \mathbf{x}^T \mathbf{A} \mathbf{x} = \text{tr}(\mathbf{x}^T \mathbf{A} \mathbf{x}), \quad \text{where } \mathbf{x} \in R^d, \mathbf{A} \in R^{d \times d}$$

$$\frac{\partial |\Sigma|}{\partial \Sigma} = |\Sigma|(\Sigma^{-1}), \quad \text{if } \Sigma \text{ is symmetrical}$$

$$\frac{\partial \text{tr}(\mathbf{A} \Sigma^{-1} \mathbf{B})}{\partial \Sigma} = (-\Sigma^{-1} \mathbf{B} \mathbf{A} \Sigma^{-1})^T \Rightarrow \frac{\partial (\mathbf{x}^T \Sigma^{-1} \mathbf{x})}{\partial \Sigma} = -\Sigma^{-1} \mathbf{x} \mathbf{x}^T \Sigma^{-1}, \quad \text{if } \Sigma \text{ is symmetrical}$$

- 例子2：高斯分布下的最大似然估计

$$\begin{aligned}\mathbf{x} &= [x_1, x_2, \dots, x_d]^T \in R^d, \\ \boldsymbol{\mu} &= [\mu_1, \mu_2, \dots, \mu_d]^T \in R^d, \\ \boldsymbol{\Sigma} &\in R^{d \times d}\end{aligned}$$

$$p(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$



$$\ln p(\mathbf{x}_i | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = -\frac{1}{2} \ln[(2\pi)^d |\boldsymbol{\Sigma}|] - \frac{1}{2}(\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}_i - \boldsymbol{\mu}), \quad i = 1, 2, \dots, n$$



$$\nabla_{\boldsymbol{\theta}}(H(\boldsymbol{\theta})) = \nabla_{\boldsymbol{\theta}}\left(\sum_{i=1}^n \ln p(\mathbf{x}_i | \boldsymbol{\theta})\right) = \sum_{i=1}^n \nabla_{\boldsymbol{\theta}} \ln p(\mathbf{x}_i | \boldsymbol{\theta}) = \mathbf{0}$$

(where $\boldsymbol{\theta} = \boldsymbol{\mu}$, and (or) $\boldsymbol{\Sigma}$)

- 估计 μ

$$\ln p(\mathbf{x}_i | \mu, \Sigma) = -\frac{1}{2} \ln[(2\pi)^d |\Sigma|] - \frac{1}{2} (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu), \quad i = 1, 2, \dots, n$$



$$\frac{\partial H(\mu)}{\partial \mu} = \sum_{i=1}^n \frac{\partial \ln p(\mathbf{x}_i | \mu, \Sigma)}{\partial \mu} = \sum_{i=1}^n \Sigma^{-1} (\mathbf{x}_i - \mu)$$



$$\sum_{i=1}^n \Sigma^{-1} (\mathbf{x}_i - \hat{\mu}) = \mathbf{0} \Rightarrow \sum_{i=1}^n \mathbf{x}_i - n\hat{\mu} = \mathbf{0} \Rightarrow \hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

$$\frac{\partial (\mathbf{x}^T \mathbf{A} \mathbf{x})}{\partial \mathbf{x}} = 2\mathbf{A} \mathbf{x}, \quad \text{where } \mathbf{x} \in R^d, \mathbf{A} \in R^{d \times d} \text{ is a real symmetrical matrix}$$

• 估计 Σ

$$\ln p(\mathbf{x}_i | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = -\frac{1}{2} \ln[(2\pi)^d |\boldsymbol{\Sigma}|] - \frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}), \quad i = 1, 2, \dots, n$$

$$\frac{\partial H(\boldsymbol{\mu}, \boldsymbol{\Sigma})}{\partial \boldsymbol{\Sigma}} = \sum_{i=1}^n \frac{\partial \ln p(\mathbf{x}_i | \boldsymbol{\mu}, \boldsymbol{\Sigma})}{\partial \boldsymbol{\Sigma}} \quad \Downarrow$$

$$= \sum_{i=1}^n \left(-\frac{1}{2} \frac{\partial \ln[(2\pi)^d |\boldsymbol{\Sigma}|]}{\partial \boldsymbol{\Sigma}} - \frac{1}{2} \frac{\partial \left((\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \right)}{\partial \boldsymbol{\Sigma}} \right)$$

$$= \sum_{i=1}^n \left(-\frac{1}{2} \frac{\partial \ln[|\boldsymbol{\Sigma}|]}{\partial \boldsymbol{\Sigma}} - \frac{1}{2} \frac{\partial \left((\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \right)}{\partial \boldsymbol{\Sigma}} \right)$$

(复合函数求偏导)

$$= \sum_{i=1}^n \left(-\frac{1}{2} \frac{1}{|\boldsymbol{\Sigma}|} \frac{\partial |\boldsymbol{\Sigma}|}{\partial \boldsymbol{\Sigma}} - \frac{1}{2} \frac{\partial \left((\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \right)}{\partial \boldsymbol{\Sigma}} \right)$$

$$\frac{\partial |\boldsymbol{\Sigma}|}{\partial \boldsymbol{\Sigma}} = |\boldsymbol{\Sigma}| (\boldsymbol{\Sigma}^{-1})$$

$$= \sum_{i=1}^n \left(-\frac{1}{2} \frac{1}{|\boldsymbol{\Sigma}|} |\boldsymbol{\Sigma}| \boldsymbol{\Sigma}^{-1} - \frac{1}{2} \frac{\partial \left((\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \right)}{\partial \boldsymbol{\Sigma}} \right)$$

$$\frac{\partial \left(\mathbf{x}^T \boldsymbol{\Sigma}^{-1} \mathbf{x} \right)}{\partial \boldsymbol{\Sigma}} = -\boldsymbol{\Sigma}^{-1} \mathbf{x} \mathbf{x}^T \boldsymbol{\Sigma}^{-1}$$

$$= \sum_{i=1}^n \left(-\frac{1}{2} \boldsymbol{\Sigma}^{-1} - \frac{1}{2} \left(-\boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) (\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} \right) \right)$$

$$= -\frac{1}{2} \boldsymbol{\Sigma}^{-1} \sum_{i=1}^n \left(\mathbf{I} - (\mathbf{x}_i - \boldsymbol{\mu}) (\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} \right)$$

- 估计 Σ （接上页）

$$\frac{\partial H(\boldsymbol{\mu}, \boldsymbol{\Sigma})}{\partial \boldsymbol{\Sigma}} = \mathbf{0} \Rightarrow -\frac{1}{2} \hat{\boldsymbol{\Sigma}}^{-1} \sum_{i=1}^n \left(\mathbf{I} - (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T \hat{\boldsymbol{\Sigma}}^{-1} \right) = \mathbf{0}$$

$$\Rightarrow \sum_{i=1}^n \left(\mathbf{I} - (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T \hat{\boldsymbol{\Sigma}}^{-1} \right) = \mathbf{0}$$

$$\Rightarrow \sum_{i=1}^n \left(\hat{\boldsymbol{\Sigma}} - (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T \right) = \mathbf{0}$$

$$\Rightarrow n\hat{\boldsymbol{\Sigma}} - \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T = \mathbf{0}$$

$$\Rightarrow \hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$$

- 例子2：高斯分布下的最大似然估计

- μ 、 Σ 均未知

$$\hat{\boldsymbol{\mu}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i, \quad \hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^T$$



一维：

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \hat{\sigma} = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2$$



(直接考虑以下问题也得到同样的结论)

$$\max \sum_{i=1}^n \ln p(x_i | \mu, \sigma), \quad \text{where } p(x | \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2} \frac{(x - \mu)^2}{\sigma^2}\right)$$

3.3 贝叶斯估计

- 贝叶斯估计与最大似然估计
 - **贝叶斯估计**是概率密度估计中另一类主要的参数估计方法。其结果在很多情况下与最大似然法十分相似，但是，两种方法对问题的处理视角是不一样的。
 - **最大似然估计**将待估计的参数视为**未知但固定的数**，其任务是根据观测数据估计其在参数空间中的取值。
 - 完全依赖数据，对数据需求量大
 - **贝叶斯估计**将待估计的参数**视为一个随机变量**，其任务是根据观测数据**对参数的分布进行估计**。
 - 利用先验知识，降低数据依赖

3.3 贝叶斯估计

- 基本方法

- 参数先验分布 $p(\theta)$ ：是指在没有任何数据时，有关参数 θ 的分布情况（根据领域知识或经验）
- 给定样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ ，数据独立采样，且服从数据分布：

$$p(D | \theta) = p(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n | \theta) = \prod_{i=1}^n p(\mathbf{x}_i | \theta)$$

- 利用贝叶斯公式计算参数的后验分布 $p(\theta | D)$ ：

$$p(\theta | D) = \frac{p(D | \theta)p(\theta)}{p(D)}$$

$p(\theta | D)$ 中融合了先验知识和数据信息

$$p(x | \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2}\left(\frac{x - \mu}{\sigma}\right)^2\right)$$

- 基本方法

- $p(D)$ 是与参数 θ 无关的归一化因子，根据全概率公式：

连续： $p(D) = \int_{\theta} p(D, \theta) d\theta = \int_{\theta} p(D | \theta) p(\theta) d\theta$

离散： $p(D) = \sum_i p(D, \theta_i) = \sum_i p(D | \theta_i) p(\theta_i)$

对于一般情况，计算 $p(D)$ 十分困难

- 可得贝叶斯参数估计中的后验概率密度函数：

$$p(\theta | D) = \frac{p(D | \theta) p(\theta)}{\int_{\theta} p(D | \theta) p(\theta) d\theta} = \frac{\prod_{i=1}^n p(\mathbf{x}_i | \theta) p(\theta)}{\int_{\theta} \prod_{i=1}^n p(\mathbf{x}_i | \theta) p(\theta) d\theta} = \alpha \prod_{i=1}^n p(\mathbf{x}_i | \theta) p(\theta)$$

3.3 贝叶斯估计

- 我们的目的是根据样本集 D 估计数据 $\mathbf{x}$ 的分布
 - 比如，假定观测样本服从正态分布 $p(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma})$ ，给定 D ，可以估计得到具体的 $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 的取值，代入如下公式可得关于样本的密度分布函数：

$$p(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

- 但 $p(\boldsymbol{\theta} \mid D)$ 只是关于 $\boldsymbol{\theta}$ 的后验分布，并没有像最大似然估计那样获得 $\boldsymbol{\theta}$ 的具体取值。

3.3 贝叶斯估计

- 如何使用 $p(\theta | D)$ 获得关于数据的分布？
 - 方法一：最大后验估计(Maximum A Posteriori estimation, MAP)

$$\hat{\theta} = \arg \max p(\theta | D)$$

选择使 $p(\theta | D)$ 取值最大的 θ ，作为参数的估计

$$\hat{\theta} = \arg \max p(\theta | D)$$

$$\Leftrightarrow \hat{\theta} = \arg \max p(D | \theta) p(\theta)$$

$$\Leftrightarrow \hat{\theta} = \arg \max \ln p(D | \theta) + \ln p(\theta)$$

PR/ML方法中普遍使用的L2正则 $\|\theta\|^2$ ，等价于假设参数 θ 服从 $N(0, \mathbf{I})$

- **方法二：数据的后验分布（完整的贝叶斯方法）**

- 获得了参数的后验分布 $p(\theta | D)$ ，如何估计数据的后验分布 $p(\mathbf{x}|D)$ ？

考虑全概率公式： $p(\mathbf{x} | D) = \int_{\theta} p(\mathbf{x}, \theta | D) d\theta$

$$= \int_{\theta} \frac{p(\mathbf{x}, \theta, D)}{p(D)} d\theta$$

$$= \int_{\theta} \frac{p(\mathbf{x} | \theta, D) p(\theta, D)}{p(D)} d\theta$$

$$= \int_{\theta} p(\mathbf{x} | \theta, D) p(\theta | D) d\theta$$

给定参数 θ 时， $\mathbf{x}$ 的分布与训练集 D 无关

$$= \int_{\theta} p(\mathbf{x} | \theta) p(\theta | D) d\theta$$

不同参数下的密度函数的加权平均

- 积分通常很难计算，使用近似方法：

$$\hat{p}(\mathbf{x} | D) = \frac{1}{M} \sum_{i=1}^M p(\mathbf{x} | \theta_i) \quad \theta_i \sim p(\theta | D) \quad i = 1, \dots, M$$

M 个不同参数的密度函数的平均

- 正态分布下的贝叶斯参数估计
 - 考虑一维情形，假定 $X \sim N(\mu, \sigma^2)$ ，且仅 μ 未知
 - 假定参数 μ 的先验概率也服从正态分布：

$$\mu \sim N(\mu_0, \sigma_0^2)$$

- 第一个任务：给定样本集 D ，在上述条件下，估计关于参数 μ 的后验分布 $p(\mu | D)$
- 回顾我们前面得到的公式：

$$p(\boldsymbol{\theta} | D) = \frac{p(D | \boldsymbol{\theta})p(\boldsymbol{\theta})}{p(D)} = \frac{\prod_{i=1}^n p(\mathbf{x}_i | \boldsymbol{\theta})p(\boldsymbol{\theta})}{p(D)} = \alpha \prod_{i=1}^n p(\mathbf{x}_i | \boldsymbol{\theta})p(\boldsymbol{\theta})$$

- 正态分布下的贝叶斯参数估计：一维

- $p(x | \mu) = N(\mu, \sigma^2)$, $p(\mu) = N(\mu_0, \sigma_0^2)$

$$p(\boldsymbol{\theta} | D) = \alpha \prod_{i=1}^n p(\mathbf{x}_i | \boldsymbol{\theta}) p(\boldsymbol{\theta}) \quad (\text{应用后验估计})$$



$$\begin{aligned} p(\mu | D) &= \alpha \prod_{i=1}^n p(\mathbf{x}_i | \mu) p(\mu) \\ &= \alpha \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2}\right) \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left(-\frac{1}{2} \frac{(\mu - \mu_0)^2}{\sigma_0^2}\right) \\ &= \alpha' \exp\left\{-\frac{1}{2} \left(\sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2} + \frac{(\mu - \mu_0)^2}{\sigma_0^2} \right)\right\} \\ &= \alpha'' \exp\left(-\frac{1}{2} \left(\left(\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2} \right) \mu^2 - 2 \left(\frac{1}{\sigma^2} \sum_{i=1}^n x_i + \frac{\mu_0}{\sigma_0^2} \right) \mu \right)\right) \end{aligned}$$

- 正态分布下的贝叶斯参数估计：一维

$$p(\mu | D) = \alpha'' \exp \left(-\frac{1}{2} \left(\left(\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2} \right) \mu^2 - 2 \left(\frac{1}{\sigma^2} \sum_{i=1}^n x_i + \frac{\mu_0}{\sigma_0^2} \right) \mu \right) \right)$$

- $p(\mu|D)$ 是关于 μ 的二次函数的exp函数，因此，也是一个正态分布密度函数。
- $p(\mu|D)$ is said to be **reproducing density**, because this is true for any number of training samples, $p(\mu|D)$ remains **normal** as the number of **n** of samples is increased

- 正态分布下的贝叶斯参数估计：一维

- As $p(\mu | D)$ is a normal density function, we can rewrite it as follows:

$$p(\mu | D) \sim N(\mu_n, \sigma_n^2) = \frac{1}{\sqrt{2\pi\sigma_n^2}} \exp\left(-\frac{1}{2} \frac{(\mu - \mu_n)^2}{\sigma_n^2}\right)$$

- But, at the same time, we also get its formulation as

$$p(\mu | D) = \alpha'' \exp\left(-\frac{1}{2} \left(\left(\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2} \right) \mu^2 - 2 \left(\frac{1}{\sigma^2} \sum_{i=1}^n x_i + \frac{\mu_0}{\sigma_0^2} \right) \mu \right)\right)$$



$$\frac{1}{\sigma_n^2} = \frac{n}{\sigma^2} + \frac{1}{\sigma_0^2}, \quad \frac{\mu_n}{\sigma_n^2} = \frac{n}{\sigma^2} \hat{\mu}_n + \frac{\mu_0}{\sigma_0^2}, \quad \text{where } \hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n x_i$$

- 正态分布下的贝叶斯参数估计：一维

$$\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n x_i$$

- 进一步可解得:

$$\mu_n = \frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2} \hat{\mu}_n + \frac{\sigma^2}{n\sigma_0^2 + \sigma^2} \mu_0, \quad \sigma_n^2 = \frac{\sigma_0^2 \sigma^2}{n\sigma_0^2 + \sigma^2}$$

- These equations show how **the prior information** is combined with **the empirical information** in the samples to obtain the **a posterior density** $p(\mu | D)$.
 - μ_n : represents our best guess for μ after obtaining n samples.
 - σ_n^2 : **measures the uncertainty about the guess of μ .**
 - Because σ_n^2 decreases **monotonically with n** , each additional observation will help decrease our uncertainty about the true value of μ .



(这种先验起到了平滑的效果，导致了更加鲁棒的估计)

• 正态分布下的贝叶斯参数估计：一维

- Because $(\sigma_n)^2$ decreases monotonically with n , each additional observation will help decrease our uncertainty about the true value of μ . As n increase, $p(\mu | D)$ becomes more and more sharply peaked, approaching a Dirac delta function as n approaches infinity.

$$\mu_n = \frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2} \hat{\mu}_n + \frac{\sigma^2}{n\sigma_0^2 + \sigma^2} \mu_0,$$

$$\sigma_n^2 = \frac{\sigma_0^2 \sigma^2}{n\sigma_0^2 + \sigma^2}$$



- 正态分布下的贝叶斯参数估计：一维
 - 现在，我们希望获得后验数据分布

$$p(\mathbf{x} | D) = \int_{\theta} p(\mathbf{x} | \theta) p(\theta | D) d\theta$$

$$\begin{aligned}
 p(x | D) &= \int_{\mu} p(x | \mu) p(\mu | D) d\mu \\
 &= \int_{\mu} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \frac{(x - \mu)^2}{\sigma^2}\right) \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left(-\frac{1}{2} \frac{(\mu - \mu_n)^2}{\sigma_n^2}\right) d\mu \\
 &= \frac{1}{2\pi\sigma\sigma_n} \exp\left(-\frac{1}{2} \frac{(x - \mu_n)^2}{\sigma^2 + \sigma_n^2}\right) f(\sigma, \sigma_n)
 \end{aligned}$$

$$\text{where } f(\sigma, \sigma_n) = \int_{\mu} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \frac{\sigma^2 + \sigma_n^2}{\sigma^2 \sigma_n^2} \left(\mu - \frac{\sigma_n^2 x + \sigma^2 \mu_n}{\sigma^2 + \sigma_n^2}\right)^2\right) d\mu$$

3.4 正态分布下的贝叶斯估计

- 贝叶斯估计与最大似然估计

贝叶斯估计: $p(x|D) \sim N(\mu_n, \sigma^2 + \sigma_n^2)$

最大似然估计: $p(x|D) \sim N(\hat{\mu}_n, \sigma^2)$

$$\mu_n = \frac{n\sigma^2}{n\sigma_0^2 + \sigma^2} \hat{\mu}_n + \frac{\sigma^2}{n\sigma_0^2 + \sigma^2} \mu_0, \quad \hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\sigma_n^2 = \frac{\sigma_0^2 \sigma^2}{n\sigma_0^2 + \sigma^2},$$

3.4 正态分布下的贝叶斯估计

- 正态分布下的贝叶斯参数估计
 - 多元情形（高维情形）：

$$p(\mathbf{x} | \boldsymbol{\mu}) \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}), \quad p(\boldsymbol{\mu}) \sim N(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0)$$

$$\begin{aligned} p(\boldsymbol{\theta} | D) &= \alpha \prod_{i=1}^n p(\mathbf{x}_i | \boldsymbol{\theta}) p(\boldsymbol{\theta}) \\ &= \alpha' \exp \left(-\frac{1}{2} \left(\boldsymbol{\mu}^T (n\boldsymbol{\Sigma}^{-1} + \boldsymbol{\Sigma}_0^{-1}) \boldsymbol{\mu} - 2\boldsymbol{\mu}^T \left(\boldsymbol{\Sigma}^{-1} \sum_{i=1}^n \mathbf{x}_i + \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0 \right) \right) \right) \\ &= \alpha'' \exp \left(-\frac{1}{2} (\boldsymbol{\mu} - \boldsymbol{\mu}_n)^T \boldsymbol{\Sigma}_n^{-1} (\boldsymbol{\mu} - \boldsymbol{\mu}_n) \right) \end{aligned}$$

- 进一步，我们有：

$$p(\boldsymbol{\mu} | D) = \alpha'' \exp\left(-\frac{1}{2}(\boldsymbol{\mu} - \boldsymbol{\mu}_n)^T \boldsymbol{\Sigma}_n^{-1} (\boldsymbol{\mu} - \boldsymbol{\mu}_n)\right) \Rightarrow p(\boldsymbol{\mu} | D) \sim N(\boldsymbol{\mu}_n, \boldsymbol{\Sigma}_n)$$

$$\Rightarrow \boldsymbol{\Sigma}_n^{-1} = n\boldsymbol{\Sigma}^{-1} + \boldsymbol{\Sigma}_0^{-1}, \quad \boldsymbol{\Sigma}_n^{-1} \boldsymbol{\mu}_n = n\boldsymbol{\Sigma}^{-1} \hat{\boldsymbol{\mu}}_n + \boldsymbol{\Sigma}_0^{-1} \boldsymbol{\mu}_0 \quad \hat{\boldsymbol{\mu}}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

$$\boldsymbol{\mu}_n = \boldsymbol{\Sigma}_0 \left(\boldsymbol{\Sigma}_0 + \frac{1}{n} \boldsymbol{\Sigma} \right)^{-1} \hat{\boldsymbol{\mu}}_n + \frac{1}{n} \boldsymbol{\Sigma} \left(\boldsymbol{\Sigma}_0 + \frac{1}{n} \boldsymbol{\Sigma} \right)^{-1} \boldsymbol{\mu}_0$$

$$\boldsymbol{\Sigma}_n = \boldsymbol{\Sigma}_0 \left(\boldsymbol{\Sigma}_0 + \frac{1}{n} \boldsymbol{\Sigma} \right)^{-1} \frac{1}{n} \boldsymbol{\Sigma}$$

$$\because (\mathbf{A}^{-1} + \mathbf{B}^{-1})^{-1} = \mathbf{A}(\mathbf{A} + \mathbf{B})^{-1} \mathbf{B} = \mathbf{B}(\mathbf{A} + \mathbf{B})^{-1} \mathbf{A}$$

- **Data posterior distribution:**

$$p(\mathbf{x} | D) = \int_{\boldsymbol{\mu}} p(\mathbf{x} | \boldsymbol{\mu}) p(\boldsymbol{\mu} | D) d\boldsymbol{\mu} \sim N(\boldsymbol{\mu}_n, \boldsymbol{\Sigma} + \boldsymbol{\Sigma}_n)$$

3.5 贝叶斯学习

- 一般情形下的贝叶斯估计（总结）

- The basic assumption are summarized as follows:

- The form of the density $p(\mathbf{x}|\boldsymbol{\theta})$ is assumed to be known, but the value of the parameter vector is not known exactly.
- Our initial knowledge about $\boldsymbol{\theta}$ is assumed to be contained in a known prior density $p(\boldsymbol{\theta})$
- The rest knowledge about $\boldsymbol{\theta}$ is contained in a set D of n samples $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ drawn independently according to the unknown probability density $p(\mathbf{x})$

- **The basic problem** is to compute the posterior density $p(\boldsymbol{\theta}|D)$ about parameter $\boldsymbol{\theta}$ and the posterior density $p(\mathbf{x}|D)$ about data.

3.5 贝叶斯学习

$$p(\boldsymbol{\theta}), p(\mathbf{x}|\boldsymbol{\theta}) \rightarrow p(\boldsymbol{\theta} | D) \rightarrow p(\mathbf{x}|D)$$

- 一般情形下的贝叶斯估计（总结）

- The basic problem is to compute the posterior density $p(\boldsymbol{\theta}|D)$ about the parameter $\boldsymbol{\theta}$. By Bayes formula we have:

$$p(\boldsymbol{\theta} | D) = \frac{p(D | \boldsymbol{\theta})p(\boldsymbol{\theta})}{p(D)} = \frac{p(D | \boldsymbol{\theta})p(\boldsymbol{\theta})}{\int p(D | \boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}}$$

where $P(D | \boldsymbol{\theta}) = P(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n | \boldsymbol{\theta}) = \prod_{i=1}^n p(\mathbf{x}_i | \boldsymbol{\theta})$

- After that, we can obtain $p(\mathbf{x}|D)$ as follows:

$$p(\mathbf{x} | D) = \int_{\boldsymbol{\theta}} p(\mathbf{x}|\boldsymbol{\theta})p(\boldsymbol{\theta} | D)d\boldsymbol{\theta}$$

3.5 贝叶斯学习

- 遇到的困难

- 除了一些特殊的分布(共轭分布), 对于一般情形, 积分很难计算, 需要近似求解:

$$p(\boldsymbol{\theta} | D) = \frac{p(D | \boldsymbol{\theta})p(\boldsymbol{\theta})}{\int p(D | \boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}}$$

$$p(\mathbf{x} | D) = \int_{\boldsymbol{\theta}} p(\mathbf{x} | \boldsymbol{\theta})p(\boldsymbol{\theta} | D)d\boldsymbol{\theta}$$

- 参数先验 $p(\theta)$ 怎么选取? 对结果有何影响?
- 给定 D , 我们真的能通过 $p(\mathbf{x}|D)$ 将 $p(\mathbf{x})$ 估计得很好吗? 或者说, 随着 D 中样本的增多, $p(\mathbf{x}|D)$ 收敛于 $p(\mathbf{x})$ 吗?

- 贝叶斯学习的迭代计算公式

- 记 $D^n = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ ，由于样本是独立选样，则：

$$p(D^n | \boldsymbol{\theta}) = p(\mathbf{x}_n | \boldsymbol{\theta})p(D^{n-1} | \boldsymbol{\theta}) = p(\mathbf{x}_n | \boldsymbol{\theta})p(\mathbf{x}_{n-1} | \boldsymbol{\theta})p(D^{n-2} | \boldsymbol{\theta}) = \dots$$

- 于是有如下迭代公式：

$$\begin{aligned} p(\boldsymbol{\theta} | D^n) &= \frac{p(D^n | \boldsymbol{\theta})p(\boldsymbol{\theta})}{\int p(D^n | \boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}} = \frac{p(\mathbf{x}_n | \boldsymbol{\theta})p(D^{n-1} | \boldsymbol{\theta})p(\boldsymbol{\theta})}{\int p(\mathbf{x}_n | \boldsymbol{\theta})p(D^{n-1} | \boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}} \\ &= \frac{p(\mathbf{x}_n | \boldsymbol{\theta})}{\int p(\mathbf{x}_n | \boldsymbol{\theta}) \frac{p(D^{n-1} | \boldsymbol{\theta})p(\boldsymbol{\theta})}{\int p(D^{n-1} | \boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}} d\boldsymbol{\theta}} \cdot \frac{p(D^{n-1} | \boldsymbol{\theta})p(\boldsymbol{\theta})}{\int p(D^{n-1} | \boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}} \\ &= \frac{p(\mathbf{x}_n | \boldsymbol{\theta})p(\boldsymbol{\theta} | D^{n-1})}{\int p(\mathbf{x}_n | \boldsymbol{\theta})p(\boldsymbol{\theta} | D^{n-1})d\boldsymbol{\theta}} \end{aligned}$$

一个固定的数

$$\left(\because p(\boldsymbol{\theta} | D^{n-1}) = \frac{p(D^{n-1} | \boldsymbol{\theta})p(\boldsymbol{\theta})}{\int p(D^{n-1} | \boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}} \right)$$

3.5 贝叶斯学习

- 参数迭代学习方法

- 为统一表示，记参数先验分布 $p(\theta)$ 为 $p(\theta|D^0)$ ，表示没有样本情形下的参数概率密度估计。
- 记 $D^n = \{x_1, x_2, \dots, x_n\}$ ，随着样本的增加，可以得到一系列对参数概率密度函数的估计：

$$p(\theta), p(\theta|x_1), p(\theta|x_1, x_2), \dots, p(\theta|x_1, x_2, \dots, x_n), \dots$$

- 一般来说，随着样本的数目的增加，上述序列函数逐渐尖锐，逐步趋向于以 θ 的真实值为中心的一个尖峰。当样本无穷多时，此时将收敛于一个脉冲函数（参数真值）。

3.6 贝叶斯估计：一个例子

- 一个例子

- 假设一维随机变量 X 服从 $[0, \theta]$ 上的均匀分布:

$$p(x | \theta) = U(0, \theta) = \begin{cases} 1/\theta, & 0 \leq x \leq \theta \\ 0, & \text{otherwise} \end{cases}$$

基于先验知识，我们知道 $0 < \theta < 10$ ，并希望利用迭代的贝叶斯方法从样本 $\{4, 7, 2, 8\}$ 中，估计参数 θ 。

3.6 贝叶斯估计：一个例子

- 一个例子

- Before any data arrive, we have $p(\theta|D^0)=p(\theta)=U(0,10)$.
- When our first data point $x_1=4$ arrives, then

$$p(\theta | D^1) = \frac{p(x_1 | \theta)p(\theta | D^0)}{\int p(x_1 | \theta)p(\theta | D^0)d\theta} = \alpha p(x_1 | \theta)p(\theta | D^0) = \alpha \frac{1}{\theta} \cdot \frac{1}{10} \propto \frac{1}{\theta}$$

$$p(\theta | D^1) \propto \begin{cases} 1/\theta, & 4 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases}$$

where throughout we will ignore the normalization.

因为 θ 一定要大于等于观测值 x

3.6 贝叶斯估计：一个例子

- 一个例子

- When the next data point $x_2=7$ arrives, we have

$$p(\theta | D^2) \propto p(x_2 | \theta)p(\theta | D^1) = \frac{1}{\theta^2} \Rightarrow p(\theta | D^2) \propto \begin{cases} 1/\theta^2, & 7 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases}$$

- When the next data point $x_3=2$ arrives, we have

$$p(\theta | D^3) \propto p(x_3 | \theta)p(\theta | D^2) = \frac{1}{\theta^3} \Rightarrow p(\theta | D^3) \propto \begin{cases} 1/\theta^3, & 2 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases}$$

- When the next data point $x_4=8$ arrives, we have

$$p(\theta | D^4) \propto p(x_4 | \theta)p(\theta | D^3) = \frac{1}{\theta^4} \Rightarrow p(\theta | D^4) \propto \begin{cases} 1/\theta^4, & 8 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases}$$

.....


- When data point x_n arrives, we have

$$p(\theta | D^n) \propto p(x_n | \theta)p(\theta | D^{n-1}) = \frac{1}{\theta^n} \Rightarrow p(\theta | D^n) \propto \begin{cases} 1/\theta^n, & \max\{D^n\} \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases}$$

一个例子

关于参数 θ 的分布 的调整过程:

$$D = \{ 4, 7, 2, 8 \}$$



比如:

$$p(\theta | D^2) = \alpha \times \begin{cases} 1/\theta^2, & 7 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases}$$

$$\alpha = \frac{1}{\int_7^{10} \frac{1}{\theta^2} d\theta} = \frac{1}{1/7 - 1/10} = 23.3100$$

$$p(\theta | D^4) \propto \begin{cases} 1/\theta^4, & 8 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases}$$




$$p(\theta | D^3) \propto \begin{cases} 1/\theta^3, & 7 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases}$$



$$p(\theta | D^0) \propto \begin{cases} 1/10, & 0 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases} \Rightarrow p(\theta | D^1) \propto \begin{cases} 1/\theta, & 4 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases} \Rightarrow p(\theta | D^2) \propto \begin{cases} 1/\theta^2, & 7 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases}$$

- 一个例子

- 参数 θ 的最后估计结果：



$$p(\theta | D^4) = \alpha \times \begin{cases} 1/\theta^4, & 8 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases} \quad \alpha = \frac{1}{\int_8^{10} \frac{1}{\theta^4} d\theta} = \frac{1}{\frac{1}{3} \left(\frac{1}{8^3} - \frac{1}{10^3} \right)} = 3147.5$$

$$p(\theta | D^4) = \begin{cases} 3147.5/\theta^4, & 8 \leq \theta \leq 10 \\ 0, & \text{otherwise} \end{cases}$$

- 一个例子

- 数据的后验分布

$$p(\mathbf{x} | D) = \int_{\theta} p(\mathbf{x} | \theta) p(\theta | D) d\theta$$

$$p(x | D) = \begin{cases} 0.1134, & 0 \leq x \leq 8 \\ 786.875 \left(\frac{1}{x^4} - \frac{1}{10^4} \right), & 8 < x \leq 10 \end{cases}$$

3.6 贝叶斯估计：一个例子


• 一个例子

- 我们再来看最大似然估计，对于数据 $\{x_1, x_2, x_3, x_4\}$ ，其似然函数为：

$$l(\theta) = p(x_1, x_2, x_3, x_4 \mid \theta) = \frac{1}{\theta^4}$$

显然， $l(\theta)$ 单调递减， θ 越小， $l(\theta)$ 越大。但同时， θ 一定要大于等于最大观测数据。在现有样本 $\{4, 7, 2, 8\}$ 中，使似然函数 $l(\theta)$ 取值最大的 θ 只能等于 8。所以由于是均匀分布，所以 θ 的最大似然估计为 8。

- 一个例子
 - 样本的后验分布



Whereas the maximum-likelihood approach estimates a point in θ space, the Bayesian approach instead estimates a distribution. This figure illustrates the difference of these estimations finally on the data density.

下次课内容

- 第3章
 - 期望最大法
 - 隐马尔可夫模型

致谢

- PPT由向世明老师提供

Thank All of You!
(Questions?)

张燕明

ymzhang@nlpr.ia.ac.cn

people.ucas.ac.cn/~ymzhang

模式分析与学习课题组 (PAL)

中科院自动化研究所· 模式识别国家重点实验室