

(请大家预习)

第7章第2讲

特征变换与特征选择

Feature Extraction and Feature Selection

张 燕 明

ymzhang@nlpr.ia.ac.cn


peopleucas.ac.cn/~ymzhang

模式分析与学习课题组 (PAL)

多模态人工智能系统实验室 中科院自动化所

助教： 杨 奇 (yangqi2021@ia.ac.cn)
张 涛 (zhangtao2021@ia.ac.cn)

上讲内容回顾



Traditional Pattern Recognition

上讲内容回顾

- 特征提取的目的

- 提取观测数据的内在特性（稳定性强、判别性好）
- 减少噪声影响

- 特征变换的目的

- 降低特征空间的维度，增加数据密度、降低过拟合风险
- 便于分析和减少后续步骤的计算量
- 有利于分类
- 线性特征变换：PCA, LDA

7.7 多维缩放

- 多维缩放(Multiple Dimensional Scaling, MDS)
 - 假设 n 个样本 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\} \subset R^m$ 在原始空间的距离矩阵为 $\mathbf{D} \in R^{n \times n}$, 其第 i 行 j 列的元素为样本 $\mathbf{x}_i$ 到 $\mathbf{x}_j$ 的距离, 记为 $\mathbf{D}_{ij}$
 - 目标: 获得这 n 个样本在 d ($d < m$) 维空间中的向量表示 $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_n] \in R^{d \times n}$, 使得降维后的样本仍保持两两之间的距离:

$$\mathbf{D}_{ij} \approx \left\| \mathbf{z}_i - \mathbf{z}_j \right\|_2^2, \quad i, j = 1, 2, \dots, n$$

7.7 多维缩放

- **MDS**

— 基于低维空间的样本表示 $\mathbf{Z} \in R^{d \times n}$ ，计算样本间距离 $\tilde{\mathbf{D}} \in R^{n \times n}$ ：

$$\begin{aligned}\tilde{\mathbf{D}} &= \begin{pmatrix} \tilde{d}_{11}^2 & \tilde{d}_{12}^2 & \cdots & \tilde{d}_{1n}^2 \\ \tilde{d}_{21}^2 & \tilde{d}_{22}^2 & \cdots & \tilde{d}_{2n}^2 \\ \vdots & \vdots & \ddots & \vdots \\ \tilde{d}_{n1}^2 & \tilde{d}_{n2}^2 & \cdots & \tilde{d}_{nn}^2 \end{pmatrix} = \begin{pmatrix} \|\mathbf{z}_1 - \mathbf{z}_1\|_2^2 & \|\mathbf{z}_1 - \mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_1 - \mathbf{z}_n\|_2^2 \\ \|\mathbf{z}_2 - \mathbf{z}_1\|_2^2 & \|\mathbf{z}_2 - \mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_2 - \mathbf{z}_n\|_2^2 \\ \vdots & \vdots & \ddots & \vdots \\ \|\mathbf{z}_n - \mathbf{z}_1\|_2^2 & \|\mathbf{z}_n - \mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_n - \mathbf{z}_n\|_2^2 \end{pmatrix} \\ &= \begin{pmatrix} 0 & \|\mathbf{z}_1\|_2^2 + \|\mathbf{z}_2\|_2^2 - 2\mathbf{z}_1^T \mathbf{z}_2 & \cdots & \|\mathbf{z}_1\|_2^2 + \|\mathbf{z}_n\|_2^2 - 2\mathbf{z}_1^T \mathbf{z}_n \\ \|\mathbf{z}_1\|_2^2 + \|\mathbf{z}_2\|_2^2 - 2\mathbf{z}_1^T \mathbf{z}_2 & 0 & \cdots & \|\mathbf{z}_2\|_2^2 + \|\mathbf{z}_n\|_2^2 - 2\mathbf{z}_2^T \mathbf{z}_n \\ \vdots & \vdots & \ddots & \vdots \\ \|\mathbf{z}_1\|_2^2 + \|\mathbf{z}_n\|_2^2 - 2\mathbf{z}_1^T \mathbf{z}_n & \|\mathbf{z}_2\|_2^2 + \|\mathbf{z}_n\|_2^2 - 2\mathbf{z}_2^T \mathbf{z}_n & \cdots & 0 \end{pmatrix}\end{aligned}$$

• MDS（接上页）

- 基于低维空间的样本表示 $\mathbf{Z} \in R^{d \times n}$ ，计算样本间距离 $\tilde{\mathbf{D}} \in R^{n \times n}$ ：

$$\tilde{\mathbf{D}} = \begin{pmatrix} \|\mathbf{z}_1\|_2^2 & \|\mathbf{z}_1\|_2^2 & \cdots & \|\mathbf{z}_1\|_2^2 \\ \|\mathbf{z}_2\|_2^2 & \|\mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_2\|_2^2 \\ \vdots & \vdots & \ddots & \vdots \\ \|\mathbf{z}_n\|_2^2 & \|\mathbf{z}_n\|_2^2 & \cdots & \|\mathbf{z}_n\|_2^2 \end{pmatrix} + \begin{pmatrix} \|\mathbf{z}_1\|_2^2 & \|\mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_n\|_2^2 \\ \|\mathbf{z}_1\|_2^2 & \|\mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_n\|_2^2 \\ \vdots & \vdots & \ddots & \vdots \\ \|\mathbf{z}_1\|_2^2 & \|\mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_n\|_2^2 \end{pmatrix} - 2 \begin{pmatrix} \mathbf{z}_1^T \mathbf{z}_1 & \mathbf{z}_1^T \mathbf{z}_2 & \cdots & \mathbf{z}_1^T \mathbf{z}_n \\ \mathbf{z}_2^T \mathbf{z}_1 & \mathbf{z}_2^T \mathbf{z}_2 & \cdots & \mathbf{z}_2^T \mathbf{z}_n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{z}_n^T \mathbf{z}_1 & \mathbf{z}_n^T \mathbf{z}_2 & \cdots & \mathbf{z}_n^T \mathbf{z}_n \end{pmatrix}$$

- **MDS**

- 令矩阵 **B** 为样本点在新表示下的内积：

$$\mathbf{B} = \mathbf{Z}^T \mathbf{Z} \in R^{n \times n}$$

- 令向量 **c** 为样本点在新表示下模长的平方：

$$\mathbf{c} = \left[\|\mathbf{z}_1\|_2^2, \|\mathbf{z}_2\|_2^2, \dots, \|\mathbf{z}_n\|_2^2 \right]^T \in R^n$$

- 我们有：

$$\tilde{\mathbf{D}} = \mathbf{c}\mathbf{e}^T + \mathbf{e}\mathbf{c}^T - 2\mathbf{B}$$

$$\mathbf{e} = [1, 1, \dots, 1]^T \in R^n$$

$$\tilde{\mathbf{D}} = \begin{pmatrix} \|\mathbf{z}_1\|_2^2 & \|\mathbf{z}_1\|_2^2 & \cdots & \|\mathbf{z}_1\|_2^2 \\ \|\mathbf{z}_2\|_2^2 & \|\mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_2\|_2^2 \\ \vdots & \vdots & \ddots & \vdots \\ \|\mathbf{z}_n\|_2^2 & \|\mathbf{z}_n\|_2^2 & \cdots & \|\mathbf{z}_n\|_2^2 \end{pmatrix} + \begin{pmatrix} \|\mathbf{z}_1\|_2^2 & \|\mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_n\|_2^2 \\ \|\mathbf{z}_1\|_2^2 & \|\mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_n\|_2^2 \\ \vdots & \vdots & \ddots & \vdots \\ \|\mathbf{z}_1\|_2^2 & \|\mathbf{z}_2\|_2^2 & \cdots & \|\mathbf{z}_n\|_2^2 \end{pmatrix} - 2 \begin{pmatrix} \mathbf{z}_1^T \mathbf{z}_1 & \mathbf{z}_1^T \mathbf{z}_2 & \cdots & \mathbf{z}_1^T \mathbf{z}_n \\ \mathbf{z}_2^T \mathbf{z}_1 & \mathbf{z}_2^T \mathbf{z}_2 & \cdots & \mathbf{z}_2^T \mathbf{z}_n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{z}_n^T \mathbf{z}_1 & \mathbf{z}_n^T \mathbf{z}_2 & \cdots & \mathbf{z}_n^T \mathbf{z}_n \end{pmatrix}$$

7.7 多维缩放

- **MDS**

- 不失一般性，假设新表示下的样本是零均值化的，即：

$$\sum_{i=1}^n \mathbf{z}_i = \mathbf{0} \in R^d$$

- 引入数据零均值化矩阵： $\mathbf{H} = \mathbf{I} - \frac{1}{n} \mathbf{e} \mathbf{e}^T \in R^{n \times n}$ （ $\mathbf{I}$ 为单位矩阵）

我们有：
$$\mathbf{Z} \mathbf{H} = \mathbf{Z} \left(\mathbf{I} - \frac{1}{n} \mathbf{e} \mathbf{e}^T \right) = \mathbf{Z} - \frac{1}{n} \mathbf{Z} \mathbf{e} \mathbf{e}^T = \mathbf{Z} \in R^{d \times n}$$

$$\mathbf{H}^T \mathbf{B} \mathbf{H} = \mathbf{H}^T \mathbf{Z}^T \mathbf{Z} \mathbf{H} = \mathbf{Z}^T \mathbf{Z} = \mathbf{B}$$

- MDS

- 进一步，我们有：

$$\mathbf{H} = \mathbf{I} - \frac{1}{n} \mathbf{e} \mathbf{e}^T \in R^{n \times n}$$

$$\tilde{\mathbf{D}} = \mathbf{c} \mathbf{e}^T + \mathbf{e} \mathbf{c}^T - 2\mathbf{B}$$



$$\mathbf{H}^T \tilde{\mathbf{D}} \mathbf{H} = \mathbf{H}^T (\mathbf{c} \mathbf{e}^T + \mathbf{e} \mathbf{c}^T - 2\mathbf{B}) \mathbf{H}$$

$$= \mathbf{H}^T \mathbf{c} \mathbf{e}^T \left(\mathbf{I} - \frac{1}{n} \mathbf{e} \mathbf{e}^T \right) + \left(\mathbf{I} - \frac{1}{n} \mathbf{e} \mathbf{e}^T \right) \mathbf{e} \mathbf{c}^T \mathbf{H} - 2\mathbf{H}^T \mathbf{B} \mathbf{H}$$

$$= \mathbf{H}^T \mathbf{c} \mathbf{e}^T - \frac{1}{n} \mathbf{H}^T \mathbf{c} \mathbf{e}^T \mathbf{e} \mathbf{e}^T + \mathbf{e} \mathbf{c}^T \mathbf{H} - \frac{1}{n} \mathbf{e} \mathbf{e}^T \mathbf{e} \mathbf{c}^T \mathbf{H} - 2\mathbf{H}^T \mathbf{B} \mathbf{H}$$

$$\left(\because \mathbf{e}^T \mathbf{e} = n \right) = \mathbf{H}^T \mathbf{c} \mathbf{e}^T - \mathbf{H}^T \mathbf{c} \mathbf{e}^T + \mathbf{e} \mathbf{c}^T \mathbf{H} - \mathbf{e} \mathbf{c}^T \mathbf{H} - 2\mathbf{H}^T \mathbf{B} \mathbf{H}$$

$$= -2\mathbf{H}^T \mathbf{B} \mathbf{H}$$

$$= -2\mathbf{B}$$

7.7 多维缩放

- MDS

- 于是有: $\mathbf{B} = -\frac{1}{2}\mathbf{H}^T\tilde{\mathbf{D}}\mathbf{H}$
- 基于MDS的目标, 可令 $\tilde{\mathbf{D}} = \mathbf{D}$, 从而计算得到 $\mathbf{B}$
- 获得矩阵 $\mathbf{B}$ 之后, 因为 $\mathbf{B} = \mathbf{Z}^T\mathbf{Z} \in R^{n \times n}$, 且 $\mathbf{B}$ 是对称矩阵, 对其特征值分解有: $\mathbf{B} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^T$,

$$\mathbf{Z} = \mathbf{\Lambda}_d^{1/2}\mathbf{U}_d^T \in R^{d \times n}$$

$$\mathbf{\Lambda}_d^{1/2} = \text{diag}(\sqrt{\lambda_1}, \sqrt{\lambda_2}, \dots, \sqrt{\lambda_d}) \in R^{d \times d}, \quad \mathbf{U}_d = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_d] \in R^{n \times d}$$

其中, $\mathbf{\Lambda}_d^{1/2}$ 表示由矩阵 $\mathbf{B}$ 的前 d 个最大的特征值开根号后对应的对角矩阵; $\mathbf{U}_d$ 由前 d 个最大的特征值对应的特征向量组成。

7.7 多维缩放


MDS算法步骤:

- 1 计算数据的距离矩阵 $\mathbf{D} \in R^{n \times n}$
- 2 计算内积矩阵 $\mathbf{B} = -\frac{1}{2} \mathbf{H}^T \mathbf{D} \mathbf{H}$;
- 3 对内积矩阵 $\mathbf{B}$ 进行特征值分解: $\mathbf{B} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^T$;
- 4 $\mathbf{Z} = \mathbf{\Lambda}_d^{1/2} \mathbf{U}_d^T \in R^{d \times n}$;

输出: $\mathbf{Z}$

7.8 流形学习

- What are manifolds



- ✓ **定义**：流形上的每一个点的开邻域与欧氏空间的开集同胚。
- ✓ **几何**：流形是一块一块欧氏空间拼装而成的弯曲空间。
- ✓ **直观**：流形是高维空间中的几何对象，其在全局范围可能具有复杂的拓扑结构，但局部特性与欧式空间相似。

The surface of a sphere is a two-dimensional manifold as it can be represented by a collection of two-dimensional maps.

(image from: <http://en.wikipedia.org/wiki/Manifold>)


7.8 流形学习

- **Mathematical definition**
 - A manifold is a mathematical space that **on a small enough scale resembles the Euclidean space of a specific dimension.**
 - **Local region can be coordinatized!**

在数学上，流形用于描述一个几何形体，它在局部具有欧氏空间的性质。即可以应用欧氏距离来描述局部区域，但在全局欧氏距离不成立。

7.8 流形学习


- What are manifolds
 - 一个直观的例子




400张360度全角度拍摄的图片会排列成一个圆！

7.8 流形学习

- What are manifolds
 - Swiss roll surface

$$\begin{cases} x = h \\ y = t \cos(t) \\ z = t \sin(t) \end{cases}$$





Swiss roll surface is a 2D manifold

7.8 流形学习

- 非线性维数缩减


- Problem formulation in machine learning: in view of dimensionality reduction



通过线性投影将高维数据降到低维将难以展开非线性结构！

7.8 流形学习

- Problem Formulation



7.8 流形学习

- 一些假定

- smooth manifold: $(f: \mathbf{C} \subset \mathbf{R}^d \rightarrow \mathbf{R}^m)$

- densely sampling:

- no self-intersections:



- 基本思想:

- 高维空间相似的数据点，映射到低维空间也是相似的


- 经典算法

- Isomap, LLE, Laplacian Eigenmaps, HLLE, MVU, LTSA, LSE, t -SNE(stochastic neighbor embedding), etc


7.8 流形学习--Isomap

- Isometric feature mapping (Isomap)


- 基本思想：给定数据集，通过最近邻等方式构造一个数据图(data graph)。然后，计算任意两个点之间的最短路径（即测地距离）。对于所有的任意两个点对，期望在低维空间中保持其测地距离。



data set



k NN data graph



Dijkstra shortest path


Isomap算法步骤:

- 1 Given data $\mathbf{X}=[\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n] \subset R^{m \times n}$, 近邻参数 k , 低维空间 d
- 2 for $i=1, 2, \dots, n$
- 3 确定 $\mathbf{x}_i$ 的 k 个近邻;
- 4 $\mathbf{x}_i$ 与近邻点之间的距离设定为欧氏距离, 与非近邻点的距离设置为无穷大
- 5 end for
- 6 调用最短路径算法计算任意两样本点 $\mathbf{x}_i$ 与 $\mathbf{x}_j$ 之间的距离 d_{ij} , 由此构造距离矩阵
- 7 调用MDS算法

输出: MDS算法的计算结果作为低维嵌入

J. B. Tenenbaum, V. de Silva, and J. C. Langford, "A global geometric framework for nonlinear dimensionality reduction," Science, vol. 290, pp. 2319–2323, 2000.

7.8 流形学习--Isomap





J. B. Tenenbaum, V. de Silva, and J. C. Langford, "A global geometric framework for nonlinear dimensionality reduction," *Science*, vol. 290, pp. 2319–2323, 2000.

7.8 流形学习--LLE

- Locally linear embedding (LLE)

- 基本思想：给定数据集，通过最近邻等方式构造一个数据图(data graph)。在每一个局部区域，高维空间中的样本线性重构关系在低维空间中均得以保持



$$\mathbf{x}_i \approx \sum_{j=1}^k w_{i,i_j} \mathbf{x}_{i_j}$$

$$\mathbf{y}_i \approx \sum_{j=1}^k w_{i,i_j} \mathbf{y}_{i_j}$$

- LLE

- 最优线性表示系数

$$\min_{\mathbf{w}_i} \left\| \mathbf{x}_i - \sum_{j=1}^k w_{i,j} \mathbf{x}_{i_j} \right\|_2^2, \quad \text{s.t.} \quad \sum_{j=1}^k w_{i,j} = 1$$

通过拉格朗日乘子法，可得线性表示系数的解：

$$\mathbf{w}_i = \frac{(\mathbf{X}_i^T \mathbf{X}_i)^{-1} \mathbf{e}}{\mathbf{e}^T (\mathbf{X}_i^T \mathbf{X}_i)^{-1} \mathbf{e}} \quad (\text{自己推导})$$

$$\mathbf{w}_i = [w_{i,i_1}, w_{i,i_2}, \dots, w_{i,i_k}]^T \in R^k,$$

$$\mathbf{X}_i = [\mathbf{x}_{i_1} - \mathbf{x}_i, \mathbf{x}_{i_2} - \mathbf{x}_i, \dots, \mathbf{x}_{i_k} - \mathbf{x}_i] \in R^{m \times k},$$

$$\mathbf{e} = [1, 1, \dots, 1]^T \in R^k$$

防止矩阵奇异

$$\mathbf{w}_i = \frac{(\mathbf{X}_i^T \mathbf{X}_i + \lambda \mathbf{I})^{-1} \mathbf{e}}{\mathbf{e}^T (\mathbf{X}_i^T \mathbf{X}_i + \lambda \mathbf{I})^{-1} \mathbf{e}}$$

- LLE

- 全局嵌入：利用在原始空间中获得的局部线性重构关系，在低维空间中重构对应的样本点

$$\mathbf{y}_i \approx \sum_{j=1}^k w_{i,i_j} \mathbf{y}_{i_j}, \quad i=1,2,\dots,n$$

- 考虑所有新样本点的重构误差，得到全局嵌入的目标函数：

$$\min_{\mathbf{Y}} \sum_{i=1}^n \left\| \mathbf{y}_i - \sum_{j=1}^k w_{i,i_j} \mathbf{y}_{i_j} \right\|_2^2 = \left\| \mathbf{Y} - \mathbf{Y}\mathbf{W}^T \right\|_2^2 = \text{tr} \left(\mathbf{Y}(\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W}) \mathbf{Y}^T \right)$$

where $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n] \in R^{d \times n}$.

$\mathbf{W} \in R^{n \times n}$ 为权重矩阵，其第 i 行记录样本 $\mathbf{x}_i$ 的 k 个权重，只有在对应的邻居位置 $i_1, i_2, \dots, i_k$ 处才有值，其余全为零。

7.8 流形学习--LLE

- LLE

- 全局嵌入学习模型：



$$\min_{\mathbf{Y}} \operatorname{tr}(\mathbf{Y}(\mathbf{I}-\mathbf{W})^T(\mathbf{I}-\mathbf{W})\mathbf{Y}^T), \quad \text{s.t.} \quad \mathbf{Y}\mathbf{Y}^T = \mathbf{I}$$

- 求解：通过求矩阵 $(\mathbf{I}-\mathbf{W})^T(\mathbf{I}-\mathbf{W})$ 的特征值分解得到

- 取出该矩阵最小的 $d+1$ 个特征值对应的特征向量；
 - 丢弃特征值零对应的分量全相等的特征向量；
 - 即采用第2至第 $d+1$ 个最小的特征值对应的特征向量组成样本的新的坐标。

S. Roweis and L. Saul, “Nonlinear dimensionality reduction by locally linear embedding,” Science, vol. 290, pp. 2323–2326, 2000.

• LLE计算流程:



线性表示

$$\mathbf{x}_i \approx \sum_{j=1}^k w_{i,i_j} \mathbf{x}_{i_j}$$

$$\text{s.t. } \sum_{j=1}^k w_{i,i_j} = 1$$

保持表示

$$\mathbf{y}_i \approx \sum_{j=1}^k w_{i,i_j} \mathbf{y}_{i_j}$$

全局误差

$$E(\mathbf{Y}) = \text{tr}(\mathbf{Y}(\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W}) \mathbf{Y}^T)$$

低维嵌入

$$\min E(\mathbf{Y}), \quad \text{s.t. } \mathbf{Y}\mathbf{Y}^T = \mathbf{I}$$

对每个样本点，找出其 k 个近邻


几乎所有的流形学习方法都需要首先构建一个关于数据的图

LLE算法步骤:

- 1 Given Data $\mathbf{X}=[\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n] \subset R^{m \times n}$, 近邻参数 k , 低维空间 d
 - 2 for $i=1, 2, \dots, n$
 - 3 确定 $\mathbf{x}_i$ 的 k 个近邻;
 - 4 对 $\mathbf{x}_i$ 进行线性最优表示, 获取近邻重构权重
 - 5 end for
 - 6 构造权重矩阵 $\mathbf{W}$;
 - 7 求解: $\min_{\mathbf{Y}} \text{tr}(\mathbf{Y}(\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W}) \mathbf{Y}^T)$, s.t. $\mathbf{Y} \mathbf{Y}^T = \mathbf{I}$
 - 8 采用第2至第 $d + 1$ 个最小的特征值对应的特征向量组成新坐标
-
- 9 输出嵌入结果
-

S. Roweis and L. Saul, "Nonlinear dimensionality reduction by locally linear embedding," Science, vol. 290, pp. 2323–2326, 2000.

- LLE的一些结果:





$$n=1965, m=560, d=2, k=12$$

7.8 流形学习--LE

- **Laplacian Eigenmaps (LE)**

- **基本思想：** 给定数据集，通过最近邻等方式构造一个数据图(data graph)。在每一个局部区域，计算点与点之间的相似度，期望点对相似度在低维空间中也得到保持。




7.8 流形学习--LE

- **LE**

- 如何计算点对相似度?
- 图构造 $G(V, E)$

$$w_{i,i_j} = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_{i_j}\|_2^2}{2\sigma^2}\right)$$



$$\Rightarrow \mathbf{W} = \begin{pmatrix} 0 & w_{12} & w_{13} & \cdots & w_{1n} \\ w_{21} & 0 & w_{23} & \cdots & w_{2n} \\ w_{31} & w_{32} & 0 & \cdots & w_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & w_{n3} & \cdots & 0 \end{pmatrix}_{n \times n}$$

$\mathbf{W} \in R^{n \times n}$ 为权重矩阵，其第 i 行记录样本 $\mathbf{x}_i$ 的 k 个权重，只有在对应的邻居位置 $i_1, i_2, \dots, i_k$ 处才有值，其余全为零。


为了保证 $\mathbf{W}$ 矩阵的对称性，可以令 $\mathbf{W} = (\mathbf{W}^T + \mathbf{W})/2$

7.8 流形学习--LE

- **LE**

- 如何在低维空间保持相似度？构造如下目标函数：

$$E(\mathbf{Y}) = \sum_{i,j} w_{ij} \|\mathbf{y}_i - \mathbf{y}_j\|_2^2$$



7.8 流形学习--LE

- **LE:** 考虑目标函数 $E(\mathbf{Y}) = \sum_{i,j} w_{ij} \|\mathbf{y}_i - \mathbf{y}_j\|_2^2$
 - 对任意向量 $\mathbf{f} = [f_1, f_2, \dots, f_n]^T \in R^n$, 有如下结论:

令

$$\mathbf{D} = \begin{pmatrix} d_1 & & & \\ & d_2 & & \\ & & \ddots & \\ & & & d_n \end{pmatrix}$$

$$d_i = \sum_{j=1}^k w_{i,j}, \quad i = 1, \dots, n$$



$$\begin{aligned} & \sum_{i,j=1}^n w_{ij} (f_i - f_j)^2 \\ &= \sum_{i=1}^n d_i f_i^2 - 2 \sum_{i,j=1}^n f_i f_j w_{ij} + \sum_{j=1}^n d_j f_j^2 \\ &= 2 \left(\sum_{i=1}^n d_i f_i^2 - \sum_{i,j=1}^n f_i f_j w_{ij} \right) \\ &= 2 \mathbf{f}^T (\mathbf{D} - \mathbf{W}) \mathbf{f} \end{aligned}$$

D: 度矩阵; **W:** 相似度矩阵; **D-W:** 图拉普拉斯矩阵

7.8 流形学习--LE

- **LE:** 考虑目标函数 $E(\mathbf{Y}) = \sum_{i,j} w_{ij} \|\mathbf{y}_i - \mathbf{y}_j\|_2^2$

$$\text{Let } \mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n] = \begin{pmatrix} y_{11} & y_{12} & \cdots & y_{1n} \\ y_{21} & y_{22} & \cdots & y_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ y_{d1} & y_{d2} & \cdots & y_{dn} \end{pmatrix} = \begin{pmatrix} \mathbf{f}_1^T \\ \mathbf{f}_2^T \\ \vdots \\ \mathbf{f}_d^T \end{pmatrix} \in R^{d \times n}$$

where, $\mathbf{f}_i = [y_{i1}, y_{i2}, \dots, y_{in}]^T \in R^n$, $i = 1, 2, \dots, d$

$$\begin{aligned} E(\mathbf{Y}) &= \sum_{i,j} w_{ij} \|\mathbf{y}_i - \mathbf{y}_j\|_2^2 = \sum_{i,j} w_{ij} \left((y_{\textcolor{red}{1}i} - y_{\textcolor{red}{1}j})^2 + \cdots + (y_{\textcolor{red}{d}i} - y_{\textcolor{red}{d}j})^2 \right) \\ &= 2\mathbf{f}_1^T (\mathbf{D} - \mathbf{W})\mathbf{f}_1 + 2\mathbf{f}_2^T (\mathbf{D} - \mathbf{W})\mathbf{f}_2 + \cdots + 2\mathbf{f}_d^T (\mathbf{D} - \mathbf{W})\mathbf{f}_d \\ &= 2\text{tr}(\mathbf{Y}(\mathbf{D} - \mathbf{W})\mathbf{Y}^T) \end{aligned}$$

7.8 流形学习--LE

- **LE**

- 学习模型

$$\min E(\mathbf{Y}) = \text{tr}(\mathbf{Y}(\mathbf{D} - \mathbf{W})\mathbf{Y}^T), \quad s.t. \mathbf{Y}\mathbf{Y}^T = \mathbf{I}$$

- 令 $\mathbf{L} = \mathbf{D} - \mathbf{W}$

- $\mathbf{L}$ 有一个特征值为零，对应的特征向量全为1：

$$\mathbf{L}\mathbf{e} = (\mathbf{D} - \mathbf{W})\mathbf{e} = (\mathbf{D} - \mathbf{W}) \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = \begin{pmatrix} d_1 - \sum_{j=1}^k w_{1,1_j} \\ d_2 - \sum_{j=1}^k w_{2,1_j} \\ \vdots \\ d_n - \sum_{j=1}^k w_{n,n_j} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \in R^n$$



$$\mathbf{L}\mathbf{e} = \mathbf{0}\mathbf{e}$$

7.8 流形学习--LE

- LE算法步骤

LE算法步骤:

- 1 Given data $\mathbf{X}=[\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n] \subset R^{m \times n}$, 近邻参数 k , 低维空间 d
- 2 确定 $\mathbf{x}_i$ 的 k 个近邻; 确定亲合度矩阵 $\mathbf{W}$, 计算度矩阵 $\mathbf{D}$
- 3 求解模型 $\min E(\mathbf{Y}), \text{ s.t. } \mathbf{Y}\mathbf{Y}^T = \mathbf{I}$
- 4 采用 $\mathbf{D}-\mathbf{W}$ 第2至第 $d+1$ 个最小的特征值对应的特征向量组成低维嵌入 $\mathbf{Y}$

输出: $\mathbf{Y} \in R^{d \times n}$

M. Belkin and P. Niyogi, "Laplacian eigenmaps for dimensionality reduction and data representation," Neural Computation, vol. 15, no. 6, pp. 1373–1396, 2003

7.8 流形学习--LPP

- **Locality preserving projections (LPP)**
 - 是LE的线性近似，但同时具备流形学习方法和线性降维方法的优点。
 - 由浙江大学何晓飞教授(2002年于芝加哥大学)提出，一种著名的线性降维方法，在机器学习、模式识别、数据挖掘中得到广泛应用。

Xiaofei He and Partha Niyogi. Locality Preserving Projections. NIPS, 2003.

7.8 流形学习--LPP


- **LPP算法思想**

- 构建原空间中各样本点对之间的相似度关系，并在线性投影中保持这种相似度。
- 在降维的同时保留原空间中样本的局部结构，即尽量避免样本集在投影空间中发散，保持原来的近邻结构。
- 在低维空间中最小化近邻样本间的距离加权平方和。

7.8 流形学习--LPP

• 算法描述

- 对样本集 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\} \subset R^m$, 引入一个线性变换:
$$\mathbf{y} = \mathbf{V}^T \mathbf{x}, \quad \text{where } \mathbf{x} \in R^m, \mathbf{V} \in R^{m \times d}, \mathbf{y} \in R^d, d < m$$
- 在该线性变换下, 希望保持样本的原来的近邻关系:



7.8 流形学习--LPP

- 算法描述

- 回顾LE: $\min_{\mathbf{Y}} \text{tr}(\mathbf{Y}(\mathbf{D} - \mathbf{W})\mathbf{Y}^T), \text{ s.t. } \mathbf{Y}\mathbf{Y}^T = \mathbf{I}$

- 引入线性变换 $\mathbf{V} \in R^{m \times d}$, 对 n 个数据点我们有:

$$\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n] = \mathbf{V}^T \mathbf{X} = \mathbf{V}^T [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n] \in R^{d \times n}$$


- 于是, 得到LPP的学习模型:

$$\begin{aligned} \min_{\mathbf{V}} \quad & \text{tr}(\mathbf{V}^T \mathbf{X}(\mathbf{D} - \mathbf{W})\mathbf{X}^T \mathbf{V}) \\ \text{s.t.} \quad & \mathbf{V}^T \mathbf{V} = \mathbf{I} \end{aligned}$$

7.8 流形学习

- 其它流形学习思想


- 处理好局部关系是构造新的流形学习算法的关键



7.8 流形学习[以下内容略]

• 局部切空间对齐 (LTSA)

- **基本思想**: 对每一个数据, 在局部引入一个线性变换, 将其近邻点映射到低维坐标系中的对应近邻点
 - 在最优局部线性变换下, 可以计算映射误差。然后将所有局部领域中计算的误差进行累加, 获得全局购入的目标函数,
 - 这就是LTSA算法 (浙江大学数学系张振跃老师提出)




Z. Zhang and H. Zha. “Principal manifolds and nonlinear dimensionality reduction via tangent space alignment,” SIAM Journal on Scientific Computing, vol. 26, no. 1, pp. 313–338, 2004.

7.8 流形学习

• 局部样条嵌入

- 对每一个数据，局部引入一个非线性变换，将其近邻点映射到低维坐标系中的对应近邻点
 - 在**最优局部样条**映射下，可以计算映射误差。然后将所有局部邻域中计算的误差进行累加，获得全局购入的目标函数，
 - 这就是局部样条嵌入(local spline embedding, LSE)



Shiming Xiang, et al.. Nonlinear Dimensionality Reduction with Local Spline Embedding. IEEE Transactions on Knowledge and Data Engineering, vol. 21, no. 9, pp. 1285-1298, 2009

7.8 流形学习

- 其它流形学习方法

- Hessian LLE
- Maximum variance unfolding
- Relative distance comparison preserving
- Stochastic neighbor embedding


- ✓ K. Q. Weinberger, F. Sha, and L. K. Saul, “Learning a kernel matrix for nonlinear dimensionality reduction,” in International Conference on Machine learning, Banff, Canada, 2004, pp. 888–905.
- ✓ D. L. Donoho and C. Grimes, “Hessian eigenmaps: locally linear embedding techniques for highdimensional data,” Proceedings of the National Academy of Arts and Sciences, vol. 100, no. 10, pp. 5591–5596, 2003.
- ✓ Van der Maaten L, Hinton G. Visualizing data using t-SNE. Journal of Machine Learning Research, 9(2579-2605): 85, 2008.

7.8 流形学习

- 性能对比




(a) Data




(b) Isomap




(c) LLE




(d) LE



(e) HLLE



(f) LTSA




(g) LSE

7.8 流形学习


- 性能对比




(a) Data




(b) Isomap




(c) LLE




(d) LE



(e) HLLE




(f) LTSA




(g) LSE

7.8 流形学习


- 性能对比



(a) Isomap




(b) LLE




(c) LE



(d) HLLE




(e) LTSA



(f) LSE

7.8 流形学习


- 性能对比




(a) Isomap




(b) LLE




(c) LE



(d) HLLE




(e) LTSA




(f) LSE

7.8 流形学习



风格



姿态+光照

Shiming Xiang, et al.. [Nonlinear Dimensionality Reduction with Local Spline Embedding](#). IEEE Transactions on Knowledge and Data Engineering, vol. 21, no. 9, pp. 1285-1298, 2009

7.8 流形学习

- 统一的学习模型

- ✓ 目标：给定高维数据 $\{\mathbf{x}_i\}_{i=1}^n \subset R^m$ 寻找其低维表示

- ✓ 学习模型： $\{\mathbf{y}_i\}_{i=1}^n \subset R^d$ ($d < m$)

图拉普拉斯矩阵

对M 进
行特征
值分解

$$\begin{aligned} \min_{\mathbf{Y}} \quad & \text{trace}(\mathbf{Y}\mathbf{M}\mathbf{Y}^T) \\ \text{s.t.} \quad & \mathbf{Y}\mathbf{Y}^T = \mathbf{I} \quad (\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n] \in R^{d \times n}) \end{aligned}$$




任务：构造 $\mathbf{M}$ 矩阵——与数据图构造和局部描述紧密相关！

7.8 流形学习

• 流形学习中的一些挑战性问题

- 低维本质维数的确定
- 如何构建一个好的数据图
- 如何将新样本嵌入到已有的低维结构中去，即所谓的 out-of-sample problem
- 超大规模计算


比如：1千万个数据，意味着需要对
1千万x1千万大小的矩阵进行特征值
分解！



流形学习应用



基于图的半监督分类



Shiming Xiang, et al., Semi-Supervised Classification via Local Spline Regression, T-PAMI, 2010.

第二部分：特征选择

7.9 特征选择--引言

回顾特征变换：

对一组已有特征进行变换，得到新特征的过程：

- 降低特征空间的维度，缓解“维数灾难”，减少计算量
- 减少特征之间可能存在的相关性，降低分类器学习的难度
- 处理高维数据的两大主流技术之一

线性特征变换（子空间分析）：采用线性变换将原特征变换至一个新的空间（通常维度更低），PCA、LDA

非线性特征变换：采用非线性变换将原特征变换至一个新的空间（通常性能更好），KPCA、KLDA

7.9 特征选择--引言

- **特征选择任务：**

- 给定一个学习任务，对于给定的数据特征集，从中选出与任务相关（对学习任务有利）的特征子集。

- **特征选择目的：**

- 处理高维数据的两大主流技术之一；
- 减少数据维度，缓解“维数灾难”，减少计算量；
- 通过**去除与任务不相关特征、冗余特征**、或者关联性较小的特征，降低学习任务的难度；
- 通过选择与任务相关的特征，提高分类器性能。

特征变换和特征选择是处理高维数据的两大主流技术

7.9 特征选择--引言

- 特征选择的总体技术路线：子集搜索+子集评价
 - 子集搜索(subset search)：从特征集合 $\{x_1, x_2, \dots, x_d\}$ 中搜索最优的特征子集。
 - 子集评价(subset evaluation)：对给定的特征子集，依据某种评价准则，对其优劣进行评价。
 - 通常基于类别可分性来进行特征子集评价。
 - 常用的判定准则包括：信息增益、信息熵等。

7.9 特征选择--引言

- **特征子集评价判据：**评价一组特征性能好坏的标准
 - **直接判据：**分类器的分类错误率
 - **间接判据：**与分类器的分类性能存在一定关系的判据
 - 不同类别数据的**可分程度**
 - 不同类别数据**分布的差异性**
 - 特征对于分类的**不确定性程度**
 - **评价准则**
 - 基于距离的准则（Distance-based criterion）
 - 基于分布的准则（Distribution-based criterion）
 - 基于熵的准则（Entropy-based criterion）

- 什么是“理想的”评价准则？

- 对分类任务，评价准则 J_{ij} 反映在一组特征下，第*i*和第*j*类的可分程度
- 理想的评价准则应满足：
 - 与分类错误率具有正相关性，以反映特征的分类性能
 - 对于独立特征，评价标准应具有可加性

$$J_{ij}(\mathbf{x}) = J_{ij}(x_1, x_2, \dots, x_d) = \sum_{k=1}^d J_{ij}(x_k)$$

- 是特征数目的单调函数，即新加入特征不会减少可分度：

$$\left\{ \begin{array}{ll} J_{ij} > 0, & \text{for } i \neq j \\ J_{ij} = 0, & \text{for } i = j \\ J_{ij} = J_{ji} \\ J_{ij}(x_1, x_2, \dots, x_d) \leq J_{ij}(x_1, x_2, \dots, x_d, x_{d+1}) \end{array} \right.$$

7.9 特征选择--引言

- 基于距离的评价准则

- 记 $\mathbf{x}_k^{(i)} \in R^d$ 和 $\mathbf{x}_l^{(j)} \in R^d$ 分别为类别 ω_i 和 ω_j 的两个样本
- 记两者之间的距离为: $d(\mathbf{x}_k^{(i)}, \mathbf{x}_l^{(j)})$
- 定义所有类别上的总距离为:

$$J_d(\mathbf{x}) = \frac{1}{2} \sum_{i=1}^c P_i \sum_{j=1}^c P_j \frac{1}{n_i n_j} \sum_{k=1}^{n_i} \sum_{l=1}^{n_j} d(\mathbf{x}_k^{(i)}, \mathbf{x}_l^{(j)})$$

P_i : 第*i*类的先验概率
 n_i : 第*i*类的样本数

- 若采用平方欧氏距离: $d(\mathbf{x}_k^{(i)}, \mathbf{x}_l^{(j)}) = (\mathbf{x}_k^{(i)} - \mathbf{x}_l^{(j)})^T (\mathbf{x}_k^{(i)} - \mathbf{x}_l^{(j)})$

⇒
$$J_d(\mathbf{x}) = \sum_{i=1}^c P_i \left[\frac{1}{n_i} \sum_{k=1}^{n_i} (\mathbf{x}_k^{(i)} - \mathbf{m}_i)^T (\mathbf{x}_k^{(i)} - \mathbf{m}_i) + (\mathbf{m} - \mathbf{m}_i)^T (\mathbf{m} - \mathbf{m}_i) \right]$$

$\mathbf{m}_i$: 第*i*类的中心

$\mathbf{m}$: 所有数据点的中心

7.9 特征选择--引言

- 基于距离的评价准则
 - 利用散度矩阵，可将上式整理成更简单的形式
 - 定义类间散度如下：

$$\mathbf{S}_b = \sum_{i=1}^c P_i (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^T$$

- 定义类内散度如下：

$$\mathbf{S}_w = \sum_{i=1}^c P_i \frac{1}{n_i} \sum_{k=1}^{n_i} (\mathbf{x}_k^{(i)} - \mathbf{m}_i)(\mathbf{x}_k^{(i)} - \mathbf{m}_i)^T$$

- 则有：

$$J_d(\mathbf{x}) = \text{tr}(\mathbf{S}_b + \mathbf{S}_w)$$

特别地，上述计算可以定义在任何特征子集上！

7.9 特征选择--引言

- 基于距离的评价准则

- 类似于线性判别准则，可定义如下的评价准则，其核心思想是使类内散度尽可能小，类间散度尽可能大。
- 常用的5个判据：

$$J_1(\mathbf{x}) = \text{tr}(\mathbf{S}_b + \mathbf{S}_w), \quad J_2(\mathbf{x}) = \text{tr}(\mathbf{S}_w^{-1} \mathbf{S}_b),$$

$$J_3(\mathbf{x}) = \frac{\text{tr}(\mathbf{S}_b)}{\text{tr}(\mathbf{S}_w)}, \quad J_4(\mathbf{x}) = \frac{|\mathbf{S}_b|}{|\mathbf{S}_w|}, \quad J_5(\mathbf{x}) = \frac{|\mathbf{S}_b + \mathbf{S}_w|}{|\mathbf{S}_w|}$$

7.9 特征选择--引言

- 基于分布的评价准则：基于类条件概率密度函数
 - 假设定义了有关类条件概率密度函数 $p(\mathbf{x}|\omega_i)$ 和 $p(\mathbf{x}|\omega_j)$ 之间的一个“距离”函数：
 - 该“距离”函数应该是非负的；
 - 该距离应反映这两个条件分布之间的重合程度；
 - 当这两个条件分布不重叠时，该距离函数取得最大值
 - 当这两个条件分布一样时，该距离函数应该取零值

7.9 特征选择--引言

- 基于分布的评价准则：基于类条件概率密度函数
 - 定义 $\mathbf{x}$ 点处的对数似然比： $L_{ij}(\mathbf{x}) = \ln \frac{p(\mathbf{x}|\omega_i)}{p(\mathbf{x}|\omega_j)}$
 - KL散度：也称为相对熵(relative entropy), 定义为对数似然比的数学期望：

$$KL_{ij} \triangleq E[L_{ij}(\mathbf{x})] = \int p(\mathbf{x}|\omega_i) \ln \frac{p(\mathbf{x}|\omega_i)}{p(\mathbf{x}|\omega_j)} d\mathbf{x}$$

- 注意，KL散度不是一个度量： $KL_{ij} \neq KL_{ji}$
- 可将其变成一个度量：

$$J_{ij} = KL_{ij} + KL_{ji} = \int \left[p(\mathbf{x}|\omega_i) - p(\mathbf{x}|\omega_j) \right] \ln \frac{p(\mathbf{x}|\omega_i)}{p(\mathbf{x}|\omega_j)} d\mathbf{x}$$

7.9 特征选择--引言

- 基于熵的评价准则：基于类后验概率分布
 - 后验概率 $p(\omega_i | \mathbf{x})$ 反映特征 $\mathbf{x}$ 刻画类别 i 的有效性
 - 两个极端例子：
 - 如果后验概率对于所有的类别都一样，即 $p(\omega_i | \mathbf{x}) = 1/c$ ，则说明该特征对类别没有任何鉴别性；
 - 如果后验概率对于类别 i 为1，对其他类别均为0，即 $p(\omega_i | \mathbf{x}) = 1$ ，则说明特征非常有效；
 - 对于某个给定特征，样本属于各类的后验概率越平均，越不利于分类；如果越集中于某一类，则越有利于分类。
 - 因此，可利用后验概率的信息熵来度量特征对类别的可分性。

7.9 特征选择--引言

- 基于熵的评价准则：基于类后验概率分布

- 信息熵

- 可用来衡量一个随机事件发生的不确定性，不确定越大，信息熵越大

- 香农熵：

$$H(\mathbf{x}) = -\sum_{i=1}^c P(w_i | \mathbf{x}) \log_2 P(w_i | \mathbf{x})$$

- 平方熵：

$$H(\mathbf{x}) = 2 \left[1 - \sum_{i=1}^c \left(P(w_i | \mathbf{x}) \right)^2 \right]$$

- 使用时要求期望

$$E[H(\mathbf{x})] = \int p(\mathbf{x}) H(\mathbf{x}) d\mathbf{x}$$

7.9 特征选择--引言

- 子集搜索

- 任务：从给定的特征集合中选择最优的特征子集
- 子集搜索是典型的组合问题 (组合爆炸)。若从 d 个特征中选择 m 个，则特征的组合数目为：

$$\frac{d!}{(d-m)!m!}$$

7.9 特征选择--引言

- 子集搜索

- 根据子集搜索策略不同：

- 穷举法：搜索所有的特征组合，可保证找到最优解。
 - 前向搜索策略：在特征选择的迭代过程中，**每次只加入一个新特征**，并对得到的特征子集进行评价，直到不会显著增加特征子集性能为止。
 - 后向搜索策略：从完整特征集合开始，**每次迭代去掉一个无关特征**，并对得到的特征子集进行评价，直到会显著降低特征子集性能为止。
 - 双向搜索策略：将前向特征选择和后向特征选择相结合。
 - 随机搜索策略：使用随机策略进行子集搜索，然后对得到的特征子集进行评价。

7.10 最优特征选择方法

- 最优方法之一：穷举法

- 从给定的 d 个特征中，挑选出 m 个特征，若采用穷举法，需要遍历 $\frac{d!}{(d-m)!m!}$ 个子集。当 d 很大时，该方法计算量巨大。能否有更聪明的搜索方法？

- 最优方法之二：分支定界法(Branch and Bound)


- 基本思想：将所有可能的特征组合以树的形式进行表示，采用分枝定界方法对树进行搜索，使得搜索过程尽早达到最优解，而不必搜索整个树。
- 基本前提：特征评价准则对特征具有单调性，即特征增多时，判据值不会减少：

$$X_1 \subset X_2 \subset \cdots \subset X_m \Rightarrow J(X_1) \leq J(X_2) \leq \cdots \leq J(X_m)$$

基于KL散度和基于信息熵的评价准则满足上述要求

7.10 最优特征选择方法

- 分支定界法：特征子集的树表示
 - 根节点包含全部特征；
 - 每一个节点，在父节点基础上去掉一个特征，并将去掉的特征序号写在节点的旁边；
 - 对 d 维特征，若选择 m 个特征，每一级去掉一个特征，则需要 $d-m$ 层达到所需特征数量，即树的深度为 $d-m$ 。
 - 比如，可能形成如下一棵树：



$$d=4, m=2$$

7.10 最优特征选择方法


- 树的生长过程（树的构造）
 - 1. 将所有特征组成根节点，根节点记为第0层；
 - 2. 对于第1层，分别计算“去掉上一层节点单个特征后”剩余特征的评价判据值，按判据值从小到大进行排序，按从左到右的顺序生成第1层的节点；
 - 3. 对于第2层，针对上一层最右侧的节点开始，重复第2步；
 - 4. 依次类推，直到第 $d-m$ 层，到达叶子结点，记录对应的判据值 J ，同时记录对应的特征选择集合
- 回溯：从第一个叶子结点开始，对树进行回溯


7.10 最优特征选择方法

• 树的生长过程—细节解释

- 树的生长：同一层左侧节点对应的特征集合的判据值 J 小于右侧节点的判据值。
- 如果去掉某个特征后，准则函数的损失（即 J 的减少量）最大，则该特征最不可能被去掉，因此将其放在该层的最左侧。
- 根据评价判据的单调性：下层节点对应的特征集合判据值小于上层节点。
- 在同一节点 D_i 下：至多生成 $|D_i| - m + 1$ 个子节点。
- 在建立下一层时：从最右侧节点开始生长，已在左侧的节点上的特征在本节点之下不再舍弃。
- 当到达叶节点时：计算当前到达的准则函数值，记作界限 B 。

树的构造






- **树的回溯**：从树的最右侧开始，当到达**叶子节点**时向上回溯。每回溯一步将相应节点上舍弃的特征回收回来。
- **遇到最近的分枝节点时停止回溯**，从该节点向下搜索左侧最近的一个分枝（从该分枝的右侧子枝开始）
- 在搜索到某一个节点时，**准则函数值若小于界限 B** ，则说明最优解不可能在本节点之下，停止沿本树枝的搜索，从此节点重新向上回溯。
- 若搜索到一个新的叶子节点，且准则函数值更大，则更新 B 的值，向上回溯。
- **最后一次更新 B 时**，取得的特征组合则为特征选择的最后结果。

- 树的回溯的总体思路：对树搜索时进行分枝限界，从右到左、从上到下
- 算法步骤：
 - 1. 从某个节点开始向面对树进行回溯，直到遇见分枝节点，搜索分枝节点最右侧未处理的一个分枝
 - 2. 对于该分枝下每一层节点，计算对应特征集合的判据值 V
 - 3. 如果 $V < B$ ，根据判据的单调性，该节点以下的判据值都小于 V ，无需往下搜索，往上回溯，转到第1步；否则继续往下搜索，转第2步；若遇见叶节点，转第4步
 - 4. 计算叶节点对应特征集合的判据值 B' ，如果 $B' > B$ ，更新 B 和相应的特征选择集合。转第1步；否则，算法终止（如果回溯过程中遇到根节点，且根据界限 B 不能再向下搜索其它树枝；或 J 值不能大于当前值为止）

示例：共有5个特征，从中选择2个



7.11 特征选择的次优方法

- 主要方法

- 过滤式特征选择方法(Filter methods)

- 单独特征选择法
 - 顺序前进特征选择法
 - 顺序后退特征选择法
 - 增 l 减 r 特征选择法

- 包裹式特征选择法(Wrapper methods)

- 嵌入式特征选择方法(Embedded methods)

次优算法：贪心策略

7.11.1 过滤式选择方法

- **基本思想：**
 - 过滤式方法先对数据集进行特征选择，再训练分类器。
- **核心任务：**
 - 如何定义特征的评价准则和搜索策略
- **算法特点：**
 - 特征选择过程与后续学习器无关；
 - 启发式特征选择方法，无法获得最优子集；
 - 与包裹式选择方法相比，计算量降低了很多。

7.11.1.1 单独特征选择法

- 基本假设

- 特征相互独立，子集的性能等于其所包含的各个特征的性能之和。因此，单独作用时性能最优的特征，它们组合起来性能也是最优的

单独特征选择法

输入：数据集、特征集合、待选择特征个数 m

输出：选择的特征集合 Φ

1. 计算每个特征的性能评价准则；
2. 根据特征的性能评价准则，对所有特征排序
3. 取前 m 个特征加入特征选择集合 Φ


7.11.1.1 单独特征选择法：Relief 方法

- 设计“相关统计量”来度量特征的重要性。考虑二类分类问题：
 - 对于样本 x_i ，定义它的“猜中近邻” (nearest-hit) 为其同类样本中的最近邻 $x_{i,nh}$ ；定义它的“猜错近邻” (nearest-miss) 为其不同类样本中的最近邻 $x_{i,nm}$ 。
 - Relief采用如下的特征性能判据：

$$\delta^j = \sum_{i=1}^n \text{dis}(x_i^j, x_{i,nm}^j)^2 - \text{dis}(x_i^j, x_{i,nh}^j)^2$$

表示第 i 个样本的第 j 个属性

度量样本属性差异： $\text{dis}(x_a^j, x_b^j) = |x_a^j - x_b^j|$



- ✓ 若样本与其猜中(同类)近邻在属性 j 上的距离小于其猜错(类间)近邻的距离，则说明属性 j 对区分同类和异类样本有益。

7.11.1.1 单独特征选择法：Relief 方法

考虑多类问题：

- 对于样本 $\mathbf{x}_i$ ，记“猜中近邻” (nearest-hit) 为它在同类样本中的最近邻 $\mathbf{x}_{i,nh}$ ；记“猜错近邻” (nearest-miss) 为它在每个不同类样本中的最近邻 $\mathbf{x}_{i,k,nm}$ 。多类Relief (Relief-F) 采用如下的特征性能判据：

$$\delta^j = \sum_{i=1}^n \left\{ \left[\sum_{k \neq c(\mathbf{x}_i)} P_k \times \text{dis}(\mathbf{x}_i^j, \mathbf{x}_{i,k,nm}^j)^2 \right] - \text{dis}(\mathbf{x}_i^j, \mathbf{x}_{i,nh}^j)^2 \right\}$$

第 k 类样本在数据集中所占的比例

• 优点：

- 为加快计算速度，Relief只需在数据集的采样上而不是整个数据集上进行
- 因此，Relief的时间开销随采样次数以及原始特征数线性增长，运行效率很高。

7.11.1.1 单独特征选择法：Relief 方法

Algorithm 1 Pseudo-code for the original Relief algorithm

n : number of training instances

d : number of features

m : number of random training instances out of n used to update δ

initialize all feature weights $\delta[j]:=0$

for $i:=1$ **to** m **do**

 randomly select a ‘target’ instance $\mathbf{x}_i$

 find a nearest hit $\mathbf{x}_{i, nh}$ and nearest miss $\mathbf{x}_{i, nm}$

for $j := 1$ **to** d **do**

$\delta[j] := \delta[j] - \text{dis}(\mathbf{x}_i^j, \mathbf{x}_{i, nh}^j) + \text{dis}(\mathbf{x}_i^j, \mathbf{x}_{i, nm}^j)$

end for

end for

return the vector δ of feature scores that estimate the quality of features

7.11.1.2 顺序前进特征选择法

顺序前进特征选择法

输入：数据集、特征集合、待选择特征个数 m

输出：已选择特征集合 Φ

1. 计算每个特征的性能评价准则，选择最优的特征加入特征选择集合 Φ
2. 对于每个剩余特征，分别计算它与已选择特征组合在一起的性能评价准则
3. 根据评价准则，选择最优的特征加入特征选择集合 Φ
4. 重复2-3步，直到已选择特征数量达到预定数量

- ✓ **优点：**相比单独特征选择法更鲁棒一些，考虑了一定的特征组合因素；计算速度依然很快。
- ✓ **缺点：**特征一旦入选，就无法被剔除。

7.11.1.3 顺序后退特征选择法

顺序后退特征选择法

输入：数据集、特征集合、待选择特征个数 m

输出：已选择特征集合 Φ

1. 将所有特征加入特征选择集合 Φ
2. 对于已选择特征集合 Φ 中的每一个特征，计算去掉该特征后**剩余特征的性能评价准则**
3. 根据评价准则，**选择使得准则最优所对应的特征**，将其从特征选择集合 Φ 中去除
4. 重复2-3步，直到已选择特征数量达到预定数量

缺点：

- ✓ 自顶向下的方法，相对顺序前进法（自底向上），**计算量更大**，因为大部分计算都在高维空间（特征个数从最大逐渐较少）；
- ✓ 特征一旦剔除，就无法再加入。

7.11.1.4 前向-后向特征选择法

增 l 减 r 特征选择法 ($l > r$) :

- 基本思想：
 - 为了使已选择或者剔除的特征有机会重新被考虑，将顺序前进特征选择法和顺序后退特征选择法相结合。
- 基本步骤：
 - 采用 l 次顺序前进特征选择，选择 l 个特征；
 - 对已选择特征集合，采用 r 次顺序后退特征选择；
 - 重复上述特征选择和剔除过程，直到选择到所需数目的特征。

注意：顺序前进步骤和顺序后退步骤可以对调，此时， $r > l$ ，对应减 r 增 l 法。

7.11.2 包裹式特征选择方法

- 过滤式特征选择方法：

- 先对数据集进行特征选择，然后再训练分类器；特征选择过程与分类单独进行，特征选择评价判据间接反应分类性能。

- 包裹式特征选择方法：

- 特征选择过程与分类性能相结合，特征评价判据为分类器性能。对给定分类方法，选择最有利于提升分类性能的特征子集。
- 通常采用交叉验证来评价选取的特征子集的好坏
 - K 折交叉验证(k -fold cross validation)， 留一法(Leave-one-out)
- 包裹式特征选择方法对分类器的基本要求：
 - 分类器能够处理高维特征向量；
 - 特征维度很高、样本个数较少时，分类器依然可以取得较好的效果。

7.11.2 包裹式特征选择方法

- 主要方法

- 直观方法：给定特征子集，训练分类器模型，以分类器错误率为特征性能判据，进行特征选择。
 - 需要大量尝试不同的特征组合，**计算量大**。
- 替代方法(递归策略)：首先利用所有的特征进行分类器训练，然后考查各个特征在分类器中的贡献，逐步剔除贡献小的特征。
 - 递归支持向量机（R-SVM: Recursive SVM）
 - 支持向量机递归特征剔除（SVM-RFE）
 - Adaboost

7.11.2 包裹式特征选择方法

- 直观方法 (General framework):
 - 1. Initialize $F = \emptyset$.
 - 2. Repeat:
 - (a) For $i = 1, \dots, d$ if $i \notin F$, let $F_i = F \cup \{i\}$, and use some version of cross validation to evaluate features F_i :
 - train your learning algorithm using only the features in F_i , and estimate its generalization error.
 - (b) Set F to be the best features (subset) found on step (a).
 - 3. Select and output the best feature subset that was evaluated during the entire search procedure.

可见:

- 启发式方法, 无法保证得到最优子集
- 需频繁调用学习算法进行候选特征子集的评价
- 通常特征选择效果很好, 但计算量很大

7.11.2 包裹式特征选择方法

- 替代方法的技术路线(以支持向量机为例)：

1. 用当前所有特征训练线性支持向量机。
2. 评估每个特征在支持向量机中的相对贡献，按照相对贡献大小进行排序。
3. 根据事先确定的递归选择特征的数目，选择出排序靠前的特征，用这组特征构成新特征。
4. 重复1-3步，直到达到规定的特征选择数目。

- 特征选择的递归策略：

- 每次选择固定比例的特征
- 人为给定一个逐级减少的特征数目序列

7.11.2 包裹式特征选择方法

线性SVM的决策函数：

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b$$

N : 支撑向量的个数
 $y_i \in \{-1, 1\}$: $\mathbf{x}_i$ 的类别
 α_i : SVM在对偶空间的参数

- ✓ R-SVM根据每个特征在数据上的分离程度定义特征的相对贡献。
- ✓ SVM-RFE根据每个特征对SVM预测误差的贡献定义特征的相对贡献。

7.11.2 包裹式特征选择方法

方法1：利用线性SVM的类分离度 (Recursive SVM)

$$\mathbf{m}^+ = \frac{1}{n_1} \sum_{\mathbf{x}^+ \in \omega_1} \mathbf{x}^+, \quad \mathbf{m}^- = \frac{1}{n_2} \sum_{\mathbf{x}^- \in \omega_2} \mathbf{x}^-,$$

$$S = \frac{1}{n_1} \sum_{\mathbf{x}^+ \in \omega_1} f(\mathbf{x}^+) - \frac{1}{n_2} \sum_{\mathbf{x}^- \in \omega_2} f(\mathbf{x}^-) = \mathbf{w}^T (\mathbf{m}^+ - \mathbf{m}^-) + \left(\frac{1}{n_1} - \frac{1}{n_2} \right) \times b = \sum_{j=1}^d \boxed{w_j (m_j^+ - m_j^-)} + \left(\frac{1}{n_1} - \frac{1}{n_2} \right) \times b$$



特征 j 的贡献: $s_j = w_j (m_j^+ - m_j^-)$

方法2：利用线性SVM的预测误差 (SVM-RFE)

$$\mathbf{r}^+ = \sum_{\mathbf{x}_i^+: \text{SVs in } \omega_1} \alpha_i \mathbf{x}_i^+, \quad \mathbf{r}^- = \sum_{\mathbf{x}_i^-: \text{SVs in } \omega_2} \alpha_i \mathbf{x}_i^-$$

$$S = f(\mathbf{r}^+) - f(\mathbf{r}^-) = \mathbf{w}^T \left(\sum_{\mathbf{x}_i: \text{SVs in both classes}} \alpha_i y_i \mathbf{x}_i \right) = \mathbf{w}^T \mathbf{w}$$



特征 j 的贡献: $s_j = w_j^2$

7.11.2 包裹式特征选择方法

方法3：利用核SVM的目标函数

核SVM对偶问题的目标函数值：

$$Q = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

去掉第 k 维特征，目标函数值：

$$Q(k) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i^{(-k)}, \mathbf{x}_j^{(-k)})$$

$\mathbf{x}_i^{(-k)}$ 表示第 i 个数据去掉第 k 维特征后的新数据。

$$DQ(k) = Q - Q(k) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \left(K(\mathbf{x}_i, \mathbf{x}_j) - K(\mathbf{x}_i^{(-k)}, \mathbf{x}_j^{(-k)}) \right)$$

- **方法4: Adaboost for feature selection:** [略, 下次课内容]



- Input: given $\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_1), \dots, (\mathbf{x}_n, y_n)\}, y_i \in \{1, -1\}$.
- Output: The features ranked by their weights
 - **Initialize:** $\mathbf{W}_1(i) = 1/n$
 - for $t = 1, 2, \dots, T$
 - Normalize the weights $\mathbf{W}_t$
 - $\forall$ **feature j** (or those in the remainder features), train weak classifier $h_j(\mathbf{x})$, and obtain its error e_j
 - Choose the classifier h_t with the lowest e_t
 - Set $\beta_t = e_t / (1 - e_t)$, and $\alpha_t = -\log \beta_t$
 - Update the data distribution:

$$\mathbf{W}_{t+1}(i) = \begin{cases} \mathbf{W}_t(i)\beta_t, & \text{if } h_t(\mathbf{x}_i) = y_i \\ \mathbf{W}_t(i), & \text{otherwise} \end{cases}$$

- end
- Return: a strong classifier: $H(\mathbf{x}) = \text{sgn}\left(\sum_{i=1}^T \alpha_t h_t(\mathbf{x})\right)$

7.11.2 包裹式特征选择方法

- 基于Haar特征的人脸检测



Haar特征可很好地描述人脸眼部区域的灰度分布情况

7.12 嵌入式特征选择--基于 L_1 范数的特征选择

考虑线性分类方法：

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$$

- $w_i = 0$ ，第 i 个特征对分类没有影响
- $w_i \neq 0$ ，第 i 个特征属于有用特征

基本思路：在学习 $\mathbf{w}$ 的时候，对 $\mathbf{w}$ 进行限制，使其不仅能满足训练样本的误差要求，同时**使得 $\mathbf{w}$ 中非零元素尽可能少**（只使用少数特征）。

7.12 嵌入式特征选择--基于 L_1 范数的特征选择

• 模型扩展：稀疏学习

– 向量稀疏性度量：

- L_0 : $\|\mathbf{w}\|_0 = \mathbf{w}$ 中非零元素个数

例: $\mathbf{w}=[1.2, 0, -3, 0, 0]$, $\|\mathbf{w}\|_0=2$

- L_1 : $\|\mathbf{w}\|_1 = \sum_i |w_i|$

- 采用 L_1 来近似 L_0


– 矩阵稀疏性度量：

⇒
$$\|\mathbf{W}\|_1 = \sum_{i,j} |W_{ij}|$$

向量的 p 范数：



$$\|\mathbf{w}\|_p = \left(\sum_{i=1}^m |w_i|^p \right)^{\frac{1}{p}}$$

L_p 范数示意图（1维）



7.12 嵌入式特征选择--基于 L_1 范数的特征选择

- 什么是稀疏性？
 - 解向量的大部分位置值为零，只有少数部分位置的值不为零
- 最小化 L_1 范数可得到稀疏解



7.12 嵌入式特征选择--基于 L_1 范数的特征选择

- LASSO的基本形式:

$$\min_{\mathbf{w}, b} \frac{1}{n} \sum_{i=1}^n \left(\mathbf{w}^T \mathbf{x}_i + b - y_i \right)^2, \quad \text{s.t.} \quad \|\mathbf{w}\|_1 \leq t$$

- 样本 $\mathbf{x}_i$ 为 d 维向量
- n : 样本个数
- t : 指定的自由参数, 用于控制正则化的程度

LASSO (Least Absolute Shrinkage and Selection Operation)

7.12 嵌入式特征选择--基于 L_1 范数的特征选择

- 将上式可进一步写成对应的向量形式

$$\min_{\mathbf{w}, b} \quad \frac{1}{n} \|\mathbf{X}\mathbf{w} + \mathbf{b} - \mathbf{y}\|_2^2, \quad \text{s.t.} \quad \|\mathbf{w}\|_1 \leq t$$

其中, $X_{ij} = [\mathbf{x}_i]_j$

分量全为 b

- 注意到给定 $\mathbf{w}$ 后, b 的优化有闭合解:

$$b = \bar{y} - \mathbf{w}^T \bar{\mathbf{x}}$$

- 将其带入原目标函数, 进一步简化目标函数的形式。

7.12 嵌入式特征选择--基于 L_1 范数的特征选择

- 于是有：

$$\min_{\mathbf{w}} \quad \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2, \quad \text{s.t.} \quad \|\mathbf{w}\|_1 \leq t$$

规范化：分别减去均值


- 能够证明，上述最优化问题，可通过以下问题近似求解：

$$\min_{\mathbf{w}} \quad \frac{1}{n} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_1$$

LASSO (Least Absolute Shrinkage and Selection Operation)

7.12 嵌入式特征选择--基于 L_1 范数的特征选择

- 模型扩展: 从稀疏表示的角度来理解



$$y = 0.7x_1 + 0.0x_2 + 0.0x_3 + 0.0x_4 + 0.2x_5 + 0.0x_6 + 0.0x_7 + 0.1x_8 + 0.0x_9$$

L_1 -范数松弛



$$(p_0) \min_w \|w\|_0, \text{ subject to } Xw = y$$

$$(p_0) \min_w \|Xw - y\|_2^2, \text{ subject to } \|w\|_0 < t$$


$$(p_1) \min_w \|Xw - y\|_2^2, \text{ subject to } \|w\|_1 < t$$

$$(p_1) \min_w \|Xw - y\|_2^2 + \lambda \|w\|_1$$

LASSO算法!


7.12 嵌入式特征选择--基于 L_1 范数的特征选择

L_1 范数 VS L_2 范数:



7.12 嵌入式特征选择--基于 L_1 范数的特征选择

L_1 范数 VS L_2 范数:



7.12 嵌入式特征选择--基于 L_1 范数的特征选择

- 求解LASSO的几种常用方法：
 - 次梯度下降法(subgradient descent methods)
 - 梯度下降法的推广
 - 最小角度回归(least-angle regression, LARS)
 - 与LASSO模型密切相关
 - 近端梯度下降法(proximal gradient descent methods)
 - 目前非常流行，效果也是最好的
 - 半二次切分(half-quadratic splitting)

7.12 嵌入式特征选择--基于 L_1 范数的特征选择

- 算法总体特征

- 不能直接设置最终选择特征的个数 m ;
- 通过设置正则化系数 λ 来间接控制 m ;
- λ 值越大，模型越关注稀疏性，得到的非零系数个数越少；反之，非零系数个数越多；
- 可以设置一个选择特征个数的上限，通过设置不同 λ 值，得到满足要求的特征。
- 是一种嵌入式特征选择方法：将分类器学习与特征选择融为一体，分类器训练过程自动完成了特征选择。


7.13 基于稀疏学习的特征选择

- 稀疏学习

- 针对具体的学习问题，可在线性模型中引入恰当的稀疏约束条件或稀疏性度量。
 - 稀疏是一种先验（比如：服从拉普拉斯分布）。
 - 稀疏是对某种已知知识的描述。
 - 从结构化风险最小化的角度，引入稀疏约束条件是增加所学函数在假设空间的简单性，所学系数向量越稀疏，则函数越简单。
 - 从正则化的角度看，就是为了防止过拟合，提高线性最小二乘法所学模型的泛化能力。
 -

7.13 基于稀疏学习的特征选择

- 采用线性变换来实现特征选择




若列选择矩阵第*i*行全为零，则第*i*个特征分量不起作用！

7.13 基于稀疏学习的特征选择

$$\mathbf{W} = \begin{pmatrix} W_{11} & \cdots & W_{1m} \\ \vdots & \ddots & \vdots \\ W_{d1} & \cdots & W_{dm} \end{pmatrix}$$

- 矩阵行稀疏性度量：结构化稀疏



要求 $\mathbf{W}$ 的某行为零，只需要该行元素的平方和为零。因此，可以将行平方和开根号收集为一个向量，再考虑其零范数

$\|\mathbf{w}\|_0$ is NP hard! So we soft it as its L_1 norm $\|\mathbf{w}\|_1 \Rightarrow \|\mathbf{W}\|_{2,1}$

7.13 基于稀疏学习的特征选择

- 矩阵的 $L_{2,1}$ 范数:

$$\|\mathbf{W}\|_{2,1} = \|\mathbf{w}\|_1 = \sum_{i=1}^d \sqrt{\sum_j |W_{ij}|^2}$$

- The $L_{2,1}$ norm of matrix is **a true norm**

$$\mathbf{W} = \begin{pmatrix} W_{11} & \cdots & W_{1m} \\ \vdots & \ddots & \vdots \\ W_{d1} & \cdots & W_{dm} \end{pmatrix}$$

$$d(\mathbf{X}, \mathbf{Y}) = \|\mathbf{X} - \mathbf{Y}\|_{2,1}$$

满足：自反性、非负性、对称性和三角不等式关系

- 矩阵的 $L_{p,r}$ 范数(伪范数):

$$\|\mathbf{W}\|_{p,r} = \left(\sum_{i=1}^n \left(\sum_{j=1}^m |W_{ij}|^p \right)^{\frac{r}{p}} \right)^{\frac{1}{r}}$$

7.13 基于稀疏学习的特征选择

- 回顾：正则化线性回归

- 线性模型： $\mathbf{y} = \mathbf{W}^T \mathbf{x} + \mathbf{b}$, where $\mathbf{y} \in R^c$, $\mathbf{W} \in R^{d \times c}$, $\mathbf{b} \in R^c$

- 任务：对 n 个样本 $\{(\mathbf{x}_1, \mathbf{y}_1), (\mathbf{x}_2, \mathbf{y}_2), \dots, (\mathbf{x}_n, \mathbf{y}_n)\}$ ，希望：

$$\mathbf{XW} + \mathbf{e}_n \mathbf{b}^T \approx \mathbf{Y}, \text{ where } \mathbf{X} \in R^{n \times d}, \mathbf{Y} \in R^{n \times c}, \mathbf{e}_n \in [1, \dots, 1] \in R^n$$

- 参数学习：最小化“正则化的回归误差”

$$\min_{\mathbf{W}, \mathbf{b}} \sum_{i=1}^n \|\mathbf{W}^T \mathbf{x}_i + \mathbf{b} - \mathbf{y}_i\|_F^2 + \lambda \|\mathbf{W}\|_F^2 = \|\mathbf{XW} + \mathbf{e}_n \mathbf{b}^T - \mathbf{Y}\|_F^2 + \lambda \|\mathbf{W}\|_F^2$$

回归误差

正则项

$$\text{where } \mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_n]^T = \begin{pmatrix} x_{11} & \cdots & x_{1d} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nd} \end{pmatrix} \in R^{n \times d}$$

(每一行为一个样本)

7.13 基于稀疏学习的特征选择

线性回归模型

- 学习模型:

$$\min_{\mathbf{W}, \mathbf{b}} \left\| \mathbf{X}\mathbf{W} + \mathbf{e}_n \mathbf{b}^T - \mathbf{Y} \right\|_F^2 + \lambda \left\| \mathbf{W} \right\|_F^2$$



$$\min_{\mathbf{W}, \mathbf{b}} \left\| \mathbf{X}\mathbf{W} + \mathbf{e}_n \mathbf{b}^T - \mathbf{Y} \right\|_F^2 + \lambda \left\| \mathbf{W} \right\|_{2,1}$$

- 最后如何实现特征选择的目标? — 排序

$$\mathbf{W} = \begin{pmatrix} \blacksquare & \blacksquare & \blacksquare & \blacksquare & \blacksquare \\ \blacksquare & \blacksquare & \blacksquare & \blacksquare & \blacksquare \\ \blacksquare & \blacksquare & \blacksquare & \blacksquare & \blacksquare \\ \blacksquare & \blacksquare & \blacksquare & \blacksquare & \blacksquare \\ \blacksquare & \blacksquare & \blacksquare & \blacksquare & \blacksquare \end{pmatrix}$$

选择矩阵



$$\begin{pmatrix} \bullet \\ \bullet \\ \bullet \\ \bullet \\ \bullet \end{pmatrix} \begin{matrix} \leftarrow w_1 = \sqrt{\sum_j |W_{1j}|^2} \\ \leftarrow w_2 = \sqrt{\sum_j |W_{2j}|^2} \\ \leftarrow w_d = \sqrt{\sum_j |W_{dj}|^2} \end{matrix}$$



$$\mathbf{w} = [w_1, w_2, \dots, w_d]^T \in R^d$$

7.14 小结

特征选择的一般技术路线：

1. 确定特征子集
2. 评价特征子集性能

评价特征子集性能常用的可分性判据：

- ✓ 基于类内类间距离的可分性判据
- ✓ 基于熵的可分性判据
- ✓ 基于SVM模型的可分性判据

7.14 小结

确定特征选择子集的方法：

- 基于树的方法（**最优算法**）：基于分枝限界技术对特征子集的树表示进行遍历，只需要查找一小部分特征组合，即可找到全局最优的特征组合
- 遍历法（**次优算法**）：顺序前向法、顺序后退法、增减 r 法
- 稀疏约束

根据特征选择与分类器的结合程度：

- 过滤式特征选择方法：“选择”与“学习”独立
- 包裹式特征选择方法：“选择”依赖“学习”
- 嵌入式特征选择方法：“选择”与“学习”同时进行

致谢

- PPT由向世明老师提供

Thank All of You!
(Questions?)

张燕明

ymzhang@nlpr.ia.ac.cn

people.ucas.ac.cn/~ymzhang

模式分析与学习课题组 (PAL)

中科院自动化研究所·多模态人工智能系统实验室