

自然语言处理与大模型原理

2024 年真题解析及 2025 模拟试题库

复习资料整理

January 19, 2026

Contents

1 第一部分：2024 年期末考试真题还原	2
1.1 一、标注题	2
1.2 二、简答题	2
1.3 三、计算题	4
1.4 四、设计题	5
2 第二部分：2025 年模拟试题库 (涵盖 PPT 重点)	7
2.1 一、基础概念与统计 NLP	7
2.2 二、深度学习与预训练模型	7
2.3 三、大模型训练与微调 (重点)	8
2.4 四、计算题模拟	8
2.5 五、综合设计题	9

1 第一部分：2024 年期末考试真题还原

1.1 一、标注题

题目 1：文本：“2023 年 12 月，OpenAI 首席执行官山姆·奥特曼在旧金山发布了 GPT-4 Turbo。”

要求：对上述文本进行分词处理（用“/”隔开），并识别其中的命名实体，标注其实体类型（如 PER, LOC, ORG, TIME）。

【参考答案】

1. 分词结果：

2023 年/12 月/, /OpenAI/首席执行官/山姆·奥特曼/在/旧金山/发布/了/GPT-4/Turbo/。

2. 命名实体识别 (NER)：

- TIME (时间): 2023 年 12 月
- ORG (机构名): OpenAI
- PER (人名): 山姆·奥特曼 (Sam Altman)
- LOC (地名): 旧金山
- MISC (其他实体/产品名): GPT-4 Turbo

1.2 二、简答题

题目 1：解释一下如何对网络收集到的大规模数据进行去噪。

【参考答案】

网络数据（如 Common Crawl）包含大量噪声，去噪通常包含以下步骤（参考 PPT 第 8 章）：

1. 基于规则的过滤：

- 过滤过短、过长或困惑度 (Perplexity) 过高的文本。
- 过滤非目标语言（如仅保留英文/中文）文本。
- 过滤包含过多特殊符号（如 HTML 标签、乱码）的文本。

2. 基于分类器的过滤：

训练一个二分类模型（如基于 fastText），区分“高质量”与“低质量”内容，剔除广告、色情、暴力等低质网页。

3. 去重 (De-duplication)：

- 精确去重：使用 MD5 或 SHA-1 移除完全相同的文档。
- 模糊去重：使用 MinHash + LSH (局部敏感哈希) 算法，移除内容高度相似（如 Jaccard 相似度 > 0.8 ）的文档，防止模型背诵。

4. 隐私去除：

识别并掩盖 PII (个人身份信息)，如手机号、邮箱、IP 地址等。

题目 2：解释一下为什么现在的大模型都是 GPT 系列 (Decoder-only) 而不是类似于 BERT 的基于掩码 (Encoder-only) 的模型。

【参考答案】

1. **任务目标一致性**：GPT 的自回归 (Auto-regressive) 生成任务（预测下一个词）与自然语言生成的本质完全一致。而 BERT 的掩码语言模型 (MLM) 任务依赖于 [MASK] 标记，这种标记在微调和推理时并不存在，导致了**预训练-微调不一致 (Pre-train/Fine-tune Discrepancy)**。

2. **长文本生成能力**: Decoder-only 架构天然适合长文本生成,因为它可以利用已生成的 Token 作为上下文继续预测;BERT 更擅长理解和判别任务,不擅长从左到右的流式生成。
3. **Scaling Law (规模定律)**: 实验表明,在同等参数量和数据量下,Decoder-only 模型在零样本 (Zero-shot) 和少样本 (Few-shot) 泛化能力上表现出更强的涌现能力。
4. **计算效率**: Attention 机制在 Decoder 中可以使用 KV-Cache 进行推理加速,而 Encoder-Decoder 架构在生成时稍微复杂一些。

题目 3: 解释一下上下文示例 (In-Context Learning) 为什么能提高模型的生成质量。

【参考答案】

上下文示例 (Few-shot Prompting) 提高生成质量的原因主要有:

1. **任务定位**: 大模型在预训练中学到了海量任务,示例充当了“索引”,帮助模型在参数空间中快速定位到当前需要的具体任务模式。
2. **格式规范**: 示例明确了输入和输出的格式 (例如 JSON 格式、特定的问答风格),限制了模型的搜索空间,使其输出更符合预期。
3. **激活知识**: 示例中的相关信息可以激活模型在预训练阶段记忆的相关知识 (知识检索作用)。
4. **无需梯度更新**: 它不改变参数,而是通过改变输入分布 $P(y|x, examples)$ 来引导输出,避免了微调可能带来的灾难性遗忘。

题目 4: 模型为什么会有幻觉? RAG 怎么解决幻觉的? RAG 能彻底解决幻觉问题吗?

【参考答案】

1. **幻觉产生原因**:

- **数据源问题**: 预训练数据本身包含错误或过时信息。
- **压缩损耗**: 模型试图将海量知识压缩进有限的参数中,导致记忆模糊或拼接错误。
- **概率生成机制**: 模型本质是预测概率最大的下一个词,而非判断真理,容易一本正经地胡说八道。

2. **RAG (检索增强生成) 的解决方式**: RAG 在生成前先从外部知识库检索相关文档,将检索到的事实作为上下文输入给模型。这迫使模型基于提供的参考资料生成答案,而非仅凭内部记忆,从而显著降低幻觉。

3. **能否彻底解决? : 不能**。原因如下:

- **检索错误**: 如果检索到的文档是不相关的或错误的,模型会基于错误信息生成 (Garbage In, Garbage Out)。
- **模型忽视**: 模型可能忽略检索内容,仍然依靠内部记忆生成 (尤其当内部记忆非常强势时)。
- **冲突处理**: 当检索内容与内部知识冲突时,模型可能会产生混乱的回答。

题目 5: 想要使用大模型进行语义角色标注 (SRL) 任务,给出算法思路和过程。

【参考答案】

语义角色标注 (SRL) 是识别句子中谓词的论元 (如施事、受事、时间、地点)。使用大模型 (如 ChatGPT/LLaMA) 进行 SRL 的思路通常是**基于指令微调或提示工程**。

算法思路与过程:

1. **任务定义与 Schema 设计**: 确定需要抽取的语义角色标签 (如 Arg0/施事, Arg1/受事, ArgM-TMP/时间, ArgM-LOC/地点)。设计输出格式 (如 JSON 或元组列表)。
2. **构建提示词 (Prompt Design)**:
 - **Instruction**: ”你是一个语义分析专家,请识别句子中谓词的语义角色。”

- **Definition:** "Arg0 代表施事者, Arg1 代表受事者..."
 - **Input:** 待分析的句子。
3. **引入少样本示例 (Few-shot Examples):** 提供 1-3 个高质量的 SRL 标注样本。示例输入: 警察正在调查事故原因。示例输出: {"谓词": "调查", "Arg0": "警察", "Arg1": "事故原因", "ArgM-ADV": "正在"}
 4. **推理生成:** 将目标句子填入 Prompt, 送入 LLM 进行推理。
 5. **后处理 (Post-processing):** 解析模型输出的 JSON, 将其转换为标准的 BIO 序列标签或结构化数据, 进行评估计算 F1 值。

1.3 三、计算题

题目 1: 给出一段英文文本, 对其使用 BPE (Byte Pair Encoding) 算法进行子词压缩。

语料库: {"low": 5, "lower": 2, "newest": 6, "widest": 3}

初始词表: 所有字符集合。请写出前 2 轮的合并操作。

【参考答案】

初始状态 (拆分为字符):

- low : 5
- lower : 2
- newest : 6
- widest : 3

词表: {l, o, w, e, r, n, s, t, i, d}

第 1 轮迭代: 统计所有相邻字符对的频次:

- (e, s): 在 "newest" (6) + "widest" (3) = 9 次 → **最高**
- (s, t): 9 次 (也是最高, 假设选 es)
- (l, o): 5+2=7 次
- (o, w): 5+2=7 次

操作: 合并 (e, s) → "es"。更新语料:

- low : 5
- lower : 2
- newest : 6
- widest : 3

第 2 轮迭代: 统计频次:

- (es, t): 6+3=9 次 → **最高**
- (l, o): 7 次
- (o, w): 7 次

操作: 合并 (es, t) → "est"。更新语料:

- low : 5
- lower : 2
- newest : 6
- widest : 3

最终词表增加: es, est

题目 2: 计算 Transformer 模型的参数量和运算量。

假设模型层数 $L = 12$, 隐藏层维度 $H = 768$, 词表大小 $V = 30000$ 。仅估算 Transformer Block 部分的参数量 (不含 Embedding)。

【参考答案】

一个 Transformer Block 包含两个子层: Multi-Head Attention (MHA) 和 Feed-Forward Network (FFN)。

1. 参数量 (Parameters):

- **MHA 部分:** 包含 W^Q, W^K, W^V, W^O 四个矩阵, 每个矩阵形状为 $H \times H$ 。

$$P_{att} = 4 \times H^2 + 4H \text{ (bias)} \approx 4H^2$$

- **FFN 部分:** 通常中间层维度为 $4H$ 。两个线性层: $H \rightarrow 4H$ 和 $4H \rightarrow H$ 。

$$P_{ffn} = (H \times 4H) + (4H \times H) = 8H^2$$

- **LayerNorm:** 两个 LN 层, 参数为 $2 \times 2H = 4H$ (可忽略)。

单层总参数: $P_{layer} \approx 12H^2$ 。总参数量: $12 \times 12 \times (768)^2 \approx 85 \times 10^6 \approx 85M$ 。

2. 运算量 (FLOPs) 估算: 根据经验公式, 训练一个 Token 需要的 FLOPs 约为参数量的 6 倍 (2 倍 Forward, 4 倍 Backward), 推理时约为 2 倍。

1.4 四、设计题

题目 1: 题目: 多语言模型相关。现有的对齐工作 (RLHF/SFT) 使用的人类标注数据大多是英文的, 导致模型对低资源语言的对齐能力很差。请设计一个算法, 让模型在不损失原本英文对齐能力的同时, 增强对低资源语言的对齐能力。

【参考答案】

设计思路: 跨语言指令增强与混合训练策略

1. 问题分析:

- 挑战: 低资源语言缺乏高质量的 SFT 指令数据和 RLHF 偏好数据。
- 目标: 提升低资源语言能力 + 保持英文能力 (防止灾难性遗忘)。

2. 算法步骤:

步骤一: 数据增强 (翻译-校对机制)

- 利用高质量的机器翻译系统 (如 Google Translate 或强 LLM) 将现有的英文 SFT 数据集 (如 Alpaca, UltraChat) 翻译成目标低资源语言。
- 关键点: 引入“回译过滤”或“基于奖励模型的过滤”, 剔除翻译质量差的数据, 构建伪标签低资源数据集 D_{target} 。

步骤二: 跨语言混合微调 (Mixed SFT)

- 构建混合数据集 $D_{mix} = D_{en} \cup D_{target}$ 。
- 按照一定比例 (如 English:Target = 7:3) 进行采样训练。这能保证模型在学习目标语言指令格式的同时, 不忘记英文知识。

步骤三: 跨语言一致性正则化 (Cross-Lingual Consistency Loss)

- 在损失函数中加入正则项: 对于同一个指令的英文版 x_{en} 和目标语言版 x_{tgt} , 强制模型生成的 Embedding 或输出概率分布尽可能一致。

$$L = L_{SFT} + \lambda \cdot KL(P(y|x_{en}) || P(y|x_{tgt}))$$

步骤四：多语言奖励模型 (Multilingual RM)

- 如果进行 RLHF，同样需要将 Reward Model 的训练数据进行翻译。
- 训练一个多语言 RM，使其能对不同语言的回复给出一致的价值观评分，然后用 PPO 优化策略模型。

2 第二部分：2025 年模拟试题库 (涵盖 PPT 重点)

2.1 一、基础概念与统计 NLP

题目 M1: 简述 Zipf 定律 (齐夫定律) 及其在自然语言处理中的意义。【参考答案】

定义: 在自然语言语料库中, 一个单词出现的频率 f 与其排名 r 成反比, 即 $f \times r = C$ (常数)。**意义:** 它揭示了语言的**长尾效应 (Long Tail Effect)**。极少数高频词 (如 “的”、“是”) 覆盖了大部分文本, 而绝大多数词 (低频词) 很少出现。这对 NLP 的挑战是**数据稀疏**问题, 即大部分词在训练数据中出现次数不足, 难以从统计中学习准确规律, 需要使用**平滑技术**或**词向量**来缓解。

题目 M2: 最大熵模型 (MaxEnt) 和条件随机场 (CRF) 的主要区别是什么? CRF 解决了 HMM 的什么问题? 【参考答案】

- **MaxEnt vs CRF:** MaxEnt 通常用于分类问题 (如词义消歧), 是对数线性模型。CRF 是 MaxEnt 在序列标注任务上的扩展 (序列化的 MaxEnt), 引入了转移特征, 进行全局归一化。
- **CRF vs HMM:**
 1. **独立性假设:** HMM 是生成式模型, 假设观察值之间相互独立 (Output Independence), 难以利用上下文的长距离特征。CRF 是判别式模型, 没有该假设, 可以灵活利用任意的全局特征。
 2. **标注偏置:** 相比于 MEMM (最大熵马尔可夫模型), CRF 进行全局归一化, 解决了局部归一化导致的标注偏置 (Label Bias) 问题。

2.2 二、深度学习与预训练模型

题目 M3: BERT 的 [MASK] 预训练任务存在什么缺陷? 后续模型 (如 XLNet 或 GPT) 是如何改进的? 【参考答案】

缺陷: BERT 在预训练时使用 [MASK] 标记, 但在微调和实际推理时, 输入文本中并不存在 [MASK]。这种**预训练-微调不一致 (Discrepancy)** 会影响性能。且 BERT 假设被 Mask 的词之间是独立的, 忽略了被遮蔽词之间的依赖关系。**改进:**

- **GPT:** 采用自回归 (Auto-regressive) 方式, 不使用 Mask, 而是通过预测下一个词来训练, 天然符合生成式任务, 无不一致问题。
- **XLNet:** 采用排列语言模型 (Permutation LM), 通过打乱输入序列的因子分解顺序, 既保留了双向上下文能力, 又避免了引入 [MASK] 标记。

题目 M4: 请简述 Word2Vec 中 CBOW 和 Skip-gram 模型的区别, 并说明为什么需要负采样 (Negative Sampling)。【参考答案】

区别:

- **CBOW:** 根据上下文预测中心词。适合小规模数据, 训练快。
- **Skip-gram:** 根据中心词预测上下文词。适合大规模数据, 对低频词效果更好。

负采样原因: Word2Vec 的输出层是一个全词表的 Softmax, 计算分母需要遍历整个词表 (如 10 万 +), 计算量巨大。负采样将多分类问题转化为二分类问题 (判断是否为正样本), 每次只更新正样本和少量负样本的权重, 从而极大提高了训练效率。

2.3 三、大模型训练与微调 (重点)

题目 M5: 什么是 ZeRO (Zero Redundancy Optimizer) 技术? 简述 ZeRO-1, ZeRO-2, ZeRO-3 的区别。【参考答案】

ZeRO 是一种用于大模型分布式训练的显存优化技术, 核心思想是去除数据并行中的显存冗余。

- **ZeRO-1:** 切分优化器状态 (Optimizer States)。每张卡只保存一部分优化器参数。
- **ZeRO-2:** 在 ZeRO-1 基础上, 切分梯度 (Gradients)。每张卡只负责更新一部分梯度。
- **ZeRO-3:** 在 ZeRO-2 基础上, 切分模型参数 (Model Parameters)。每张卡只保存模型的一部分层, 计算时临时通信获取参数。

题目 M6: RLHF (Reinforcement Learning from Human Feedback) 的三个主要步骤是什么? 【参考答案】

1. **SFT (有监督微调):** 收集高质量的指令-回复对, 微调预训练模型, 使其具备基本的遵循指令能力。
2. **RM (奖励模型训练):** 收集人类偏好数据 (对同一 Prompt 的多个回复进行排序), 训练一个奖励模型, 使其能模拟人类的打分标准。
3. **PPO (强化学习优化):** 利用奖励模型作为环境反馈, 使用 PPO 算法优化语言模型策略, 使其生成的回复能获得更高的奖励分数, 同时通过 KL 散度约束防止模型偏离 SFT 模型太远。

题目 M7: 简述 FlashAttention 的核心原理及其解决的问题。【参考答案】

问题: 标准 Attention 的计算复杂度是 $O(N^2)$, 且显存占用大。更重要的是, 它频繁地在 GPU 的 HBM (高带宽显存) 和 SRAM (片上缓存) 之间读写数据, IO 访问成为瓶颈。**原理:** FlashAttention 通过分块计算 (Tiling) 和 重计算 (Recomputation) 技术, 在 SRAM 中进行 Attention 的局部计算, 显著减少了对 HBM 的访问次数。**效果:** 虽然计算量略增 (重计算), 但由于 IO 速度的大幅提升, 整体训练速度加快, 且显存复杂度降为线性。

2.4 四、计算题模拟

题目 M8 (困惑度计算): 假设一个 Unigram 语言模型, 词表中只有三个词: {"a": 0.5, "b": 0.25, "c": 0.25}。请计算句子 "a b c" 的概率以及该句子的困惑度 (Perplexity)。【参考答案】

1. **句子概率:** $P(a b c) = P(a) \times P(b) \times P(c) = 0.5 \times 0.25 \times 0.25 = 0.03125$
2. **困惑度 (PP):** 公式: $PP(S) = P(w_1 \dots w_N)^{-1/N}$ $N = 3$ 。 $PP = (0.03125)^{-1/3} = (\frac{1}{32})^{-1/3} = (32)^{1/3} \approx 3.17$

题目 M9 (TF-IDF 计算): 文档集合有两篇文档: D1: "中国北京" D2: "中国上海" 计算 "北京" 一词在 D1 中的 TF-IDF 值。(使用 $\log_{10}$ 计算 IDF) 【参考答案】

- **TF (词频):** 在 D1 中, "北京" 出现 1 次, 总词数 2。 $TF = 1/2 = 0.5$ (或直接按频次 1)。
- **IDF (逆文档频率):** 总文档数 $N = 2$ 。出现 "北京" 的文档数 $df = 1$ (仅 D1)。 $IDF = \log_{10}(N/df) = \log_{10}(2/1) \approx 0.301$ 。
- **TF-IDF:** $0.5 \times 0.301 = 0.1505$ 。

2.5 五、综合设计题

题目 M10: 题目: 设计一个垂直领域 (如医疗或法律) 的 RAG (检索增强生成) 系统, 请详细描述各个模块的关键技术选型及优化策略。 【参考答案】

设计方案: 医疗领域 RAG 系统

1. 索引模块 (Indexing):

- **数据清洗:** 清洗医疗指南、药品说明书。去除无关页眉页脚。
- **分块策略 (Chunking):** 由于医疗建议依赖上下文, 采用 “滑动窗口” 切分, 并增加 Overlap。或采用 “Small-to-Big” 策略 (索引小块句子, 检索后召回对应的整段窗口), 保证语义完整性。
- **元数据增强:** 为 Chunk 增加元数据 (如科室、适用人群、年份), 便于过滤。

2. 检索模块 (Retrieval):

• 混合检索 (Hybrid Search):

- **关键词检索 (BM25):** 精确匹配药品名、病名 (避免 Embedding 对专有名词理解偏差)。
- **语义检索 (Dense Vector):** 匹配症状描述的语义相似性。
- 加权融合两者得分。

- **重排序 (Re-ranking):** 使用 Cross-Encoder 对初排的 Top-50 文档进行精细打分, 筛选 Top-5, 显著提升准确率。

3. 生成模块 (Generation):

- **提示词工程:** 使用 CoT (思维链), 引导模型 “先分析病情, 再参考文档, 最后给出建议”。
- **拒答机制:** 如果检索到的文档相关性分数过低, 模型应回答 “无法根据现有资料回答”, 防止医疗幻觉。

4. **评估 (Evaluation):** 使用 RAGAS 框架, 重点评估 “忠实度 (Faithfulness)” (答案是否违背检索文档) 和 “答案相关性”。